

Análise longitudinal de diferentes classes de atributos hipocampais para a classificação entre comprometimento cognitivo leve progressivo e estável

Paulo Matheus da Costa Girardi^a, Ricardo José Ferrari^{a,*}, for the Alzheimer's Disease Neuroimaging Initiative^{**}

^a*Department of Computing, Federal University of São Carlos, Rod. Washington Luis, Km 235, 13565-905, São Carlos, SP, Brazil*

Abstract

Distinguir sMCI de pMCI no hipocampo com RM T1 isolada é difícil: o sinal é sutil e a literatura mistura janelas, ROIs e validação. Neste estudo (ADNI-1/2/GO) pergunta-se se a representação longitudinal agrega discriminação relativamente ao baseline. O contraste corre em cinco famílias (volume, forma, textura GLCM Original, primeira ordem, deslocamento normativo) e em quatro coortes (janelas 36/48 meses $\times$ intervalos nominais 6/12 meses, tolerância ± 2). Protocolo fixo: SVM, pool ℓ_1 por frequência, $\tau = 70\%$, $|\rho| > 0.85$ com desempate $|\text{corr}(x, y)|$, CV aninhada no paciente (5×10); métrica primária AUC de Mann–Whitney sobre a média das probabilidades OOF por sujeito. Uniclasse: Longitudinal agrega volume, textura e primeira ordem; a forma em i_0 permanece o teto unimodal e longitudinal não o ultrapassa de forma consistente. A união tardia de cinco SVMs (média de scores) em particular a âncora shape baseline $\cup$ restante longitudinal supera esse teto nas quatro células (em 48m_12m, $n = 120$: teto $\approx 0.76 \rightarrow 0.802 \pm 0.040$). Os escores clínicos de i_0 (sexo,

*Corresponding author

**Data used in preparation of this article were obtained from the Alzheimer's Disease Neuroimaging Initiative (ADNI) database (adni.loni.usc.edu). Investigators within ADNI contributed to the design and implementation of ADNI and/or provided data but did not participate in analysis or writing of this report. A complete listing of ADNI investigators is available at http://adni.loni.usc.edu/wp-content/uploads/how_to_apply/ADNI_Acknowledgement_List.pdf.

Email addresses: paulogirardi@estudante.ufscar.br (Paulo Matheus da Costa Girardi), rferrari@ufscar.br (Ricardo José Ferrari)

idade, MMSE, ADAS, FAQ) atingem 0.812 ± 0.040 ; a RM hipocampal entra como adjunto estrutural.

Keywords: Longitudinal MRI, hippocampus, Mild Cognitive Impairment, Radiomics, Machine Learning, Nested cross-validation, Late fusion

1. Introdução

O Comprometimento Cognitivo Leve (MCI) precede a doença de Alzheimer (AD) no quadro de declínio contínuo cognitivo [Petersen et al. \(1999\)](#). Identificar quais indivíduos com MCI permanecerão estáveis (sMCI) e quais progredirão para demência (pMCI) é clinicamente relevante para o enriquecimento de ensaios, aconselhamento e planejamento de intervenções precoces [Petersen et al. \(2009\)](#). A ressonância magnética estrutural (sMRI) T1 ponderada permanece central neste problema, sendo a atrofia hipocampal um dos marcadores macroscópicos mais consolidados de neurodegeneração [Scheltens et al. \(1992\)](#). Na fronteira sMCI/pMCI, contudo, a discriminação baseada numa única região anatômica é intrinsecamente difícil: as diferenças de grupo são sutis, a dinâmica de conversão é heterogênea e a alteração estrutural sobrepõe-se ao envelhecimento natural.

Uma vasta literatura avançou, por isso, para representações mais ricas, incluindo morfometria de cérebro inteiro, fusão multimodal com escores cognitivos, radiômica e aprendizagem profunda longitudinal [Moradi et al. \(2015\)](#); [Ye et al. \(2012\)](#); [Zhang et al. \(2019\)](#); [Lin et al. \(2020\)](#); [Aghajanian et al. \(2025\)](#).

SEPARAR AS CITAÇÕES PARA FAZER MAIS SENTIDO CADA DEFINIÇÃO E EXPLICAÇÃO

Embora as AUCs reportadas nestes contextos possam ser elevadas, a comparabilidade entre os estudos é limitada. Coortes, definições de análise, como classificação sMCI e pMCI ou conversão de MCI para AD num horizonte fixo, escala espacial (cérebro inteiro versus ROI), entrada temporal (apenas baseline versus visitas sequenciais) e desenhos de validação diferem amplamente. Além disso, muitos pipelines publicados aplicam harmonização, seleção de atributos

ou sintonização de hiperparâmetros utilizando informação do conjunto completo de dados ou de partições de teste, e nem todos impõem uma divisão estrita ao nível do paciente. Nestas condições, AUCs otimistas são difíceis de interpretar e podem não refletir o desempenho atingível sob validação ao nível do paciente com o ajuste rigoroso do modelo por fold.

Este estudo aborda essa lacuna através de um fluxo de ponta a ponta, auditável, de extração de atributos hipocampais e classificação prognóstica na coorte ADNI (ADNI-1/2/GO). O hipocampo foi escolhido propositalmente como o marcador canônico de atrofia, fornecendo um banco de ensaio focado para a avaliação longitudinal, sem reivindicar a cobertura prognóstica de cérebro inteiro. A cadeia documentada combina pré-processamento, controle de qualidade, parcelamento, registro baseado em templates e extração de atributos volumétricos, morfométricos, texturais e de campo de deslocamento no hipocampo. O desempenho avalia-se através de validação cruzada aninhada ao nível do paciente; o modo de seleção ℓ_1 por frequência derivada de bootstrap restringe-se estritamente aos dados de treino de cada dobra externa.

A novidade metodológica reside na arquitetura de avaliação. A elegibilidade temporal, a apuração do desfecho, a divisão por paciente, as operações ajustadas por fold, a seleção de atributos, a agregação de probabilidades e as comparações estatísticas formam uma cadeia auditável. Esse desenho permite comparar, sob um estimando comum de AUC, a representação longitudinal proposta versus o baseline isolado em cinco famílias, avaliar o método de união tardia de cinco modelos SVM, e identificar quais componentes permanecem informativos após controles de vazamento de informação e correção por multiplicidade.

As principais contribuições para a avaliação reprodutível de aprendizagem automática em neuroimagem longitudinal são:

- Um protocolo auditável que separa visitas preditoras no estágio MCI da apuração do desfecho e documenta a fronteira de ajuste de cada operação dependente da amostra sob validação aninhada no paciente;
- Uma matriz controlada em cinco famílias de atributos hipocampais, com-

parando o baseline com o longitudinal através de quatro coortes (combinações de janela clínica $\times$ intervalo entre imagens);

- Uma auditoria sistemática da fusão tardia (late fusion), varrendo o espaço combinatório das probabilidades geradas por diferentes classes de atributos para identificar quais arranjos multiclass maximizam o desempenho classificatório em relação aos modelos uniclass;
- Uma auditoria explícita da frequência de seleção de atributos, revelando que a forma satura no baseline, enquanto volume, textura e primeira ordem agregam valor ao longo do tempo, e que a união tardia é o contraste capaz de superar o teto unimodal;

O restante do artigo está organizado da seguinte forma: a Seção 2 mostra os trabalhos relacionados; a Seção 3 descreve a coorte, a extração de atributos e o protocolo de validação; a Seção 4 reporta os resultados prognósticos e o contexto da literatura; a Seção 5 discute os achados e as limitações; e a Seção 6 conclui o trabalho.

2. Trabalhos relacionados

A previsão automatizada de estabilidade ou conversão do MCI tem sido estudada com conjuntos de atributos, esquemas de validação e janelas de desfecho muito diferentes. O desempenho depende, portanto, não só do classificador, mas também de os preditores serem clínicos, estruturais, multimodais, regionais ou de cérebro inteiro, e de a informação temporal se limitar à visita inicial (baseline) ou abranger várias visitas de seguimento.

Vários estudos mostram que o acompanhamento cognitivo denso pode ser altamente informativo mesmo sem RM. Bucholt et al. (2023) propuseram um enquadramento de ensemble híbrido na coorte do National Alzheimer’s Coordinating Center (NACC) para prever a conversão de MCI para demência a partir de trajetórias cognitivas e funcionais longitudinais. Embora a acurácia de classificação tenha atingido 85,0%–87,5%, a AUC do *ensemble* no teste retido

permaneceu perto de 0,60, ao passo que modelos de floresta aleatória atingiram AUC de até 0,76 quando quatro visitas estavam disponíveis. [Grassi et al. \(2019\)](#) previram a conversão em 3 anos no ADNI usando apenas variáveis sociodemográficas e neuropsicológicas e reportaram AUROC de 0,88 (IC bootstrap 95%: 0,85–0,91), com sensibilidade de 77,7% e especificidade de 79,9% no ponto de operação de melhor acurácia balanceada. Estes resultados indicam que o rastreo clínico transporta sinal prognóstico substancial e constitui um comparador forte para modelos baseados exclusivamente em imagens.

Estudos de RM estrutural apoiam-se frequentemente em representações de cérebro inteiro de alta dimensão ou em fusão com escores cognitivos. [Moradi et al. \(2015\)](#) aplicaram *low-density separation* à RM T1 de *baseline* do ADNI para a previsão precoce de conversão em MCI, reportando AUC de 0,766 com morfometria baseada em voxel isolada e AUC de 0,902 quando a RM foi combinada com um agregado cognitivo de *baseline*. [Ye et al. \(2012\)](#) usaram um enquadramento esparsos de seleção estável (*stability selection*) (Biosignature-15) para prever a conversão MCI-para-AD em quatro anos, alcançando AUC de 0,859 com validação cruzada *leave-one-out* (LOOCV) em dados ADNI de *baseline*. [Casanova et al. \(2013\)](#) combinaram atributos de RM em grande escala baseados em tecido com informação cognitiva num enquadramento de aprendizagem automática para avaliação de risco no ADNI. Tais estudos demonstram que AUCs elevadas são obtidas mais frequentemente com desenhos de cérebro inteiro ou multimodais e com definições de desfecho que podem diferir da discriminação estrita sMCI/pMCI em horizonte curto.

Quando o escopo espacial se reduz a uma única região de interesse (ROI), o desempenho tipicamente diminui. [Cuingnet et al. \(2011\)](#) compararam dez métodos de classificação no ADNI e reportaram que a discriminação conversor versus não conversor em MCI, incluindo atributos de volume hipocampal, não excedeu o acaso de forma significativa. [Guo et al. \(2017\)](#) estudaram atributos de espessura cortical relacionados com a conversão para a discriminação sMCI versus cMCI, reportando 98,84% de acurácia com sensibilidade/especificidade de 97,5/100 sob LOOCV, mas sem reportar a AUC. Estes achados são consistentes

com a premissa de que restringir a análise a uma região anatômica focal, seja o hipocampo ou o córtex, produz um desempenho prognóstico mais conservador do que modelos de cérebro inteiro.

Trabalhos mais recentes incorporam informação temporal de RM via aprendizagem de dicionários, aprendizagem profunda ou radiômica. [Zhang et al. \(2019\)](#) analisaram RM estrutural longitudinal para classificação AD/MCI, [Lin et al. \(2020\)](#) usaram aprendizagem de dicionários longitudinal para prever progressão MCI-para-AD, e [Aghajanian et al. \(2025\)](#) combinaram aprendizagem profunda com radiômica de RM estrutural longitudinal para previsão de progressão. Estas abordagens evidenciam um interesse crescente na modelagem temporal, mas também variam na definição da coorte, no controle de fugas de informação e na comparação com comparadores clínicos de *baseline*.

Perante este enquadramento, o presente trabalho não visa reproduzir o estado da arte multimodal de cérebro inteiro. Em vez disso, especifica e testa rigorosamente um pipeline prognóstico focado no hipocampo na coorte ADNI, com uma configuração primária pré-especificada (classificador SVM, seleção ℓ_1 com bootstrap, estimador de AUC ao nível do paciente) e ablações sistemáticas: cinco famílias de atributos, representação longitudinal versus baseline, quatro células de janela clínica $\times$ intervalo, e (*late fusion*) para união de diferentes classes de atributos em três especificações pré-definidas. A contribuição original é o protocolo de avaliação coordenado: todas as representações candidatas são avaliadas sob elegibilidade temporal explícita, validação aninhada ao nível do paciente, ajuste por *fold* e sob o mesmo estimando *out-of-fold* (OOF). Isso transforma ablações negativas e positivas em evidência de desenho para futuros sistemas de suporte à decisão, em vez de tratar a AUC máxima observada como o único resultado. Sob esse protocolo, a forma geométrica no i_0 atinge uma AUC por paciente de $0,761 \pm 0,043$ na coorte 48m_12m; a textura Q4 empata com este teto ($0,762 \pm 0,044$); a fusão tardia Q4/âncora atinge $0,802 \pm 0,040$; e os escores clínicos de i_0 permanecem competitivos ($0,812 \pm 0,040$).

3. Materiais e Métodos

Os dados utilizados neste estudo foram obtidos da base de dados da *Alzheimer's Disease Neuroimaging Initiative* (ADNI) [Petersen et al. \(2009\)](#); [Jack Jr. et al. \(2008\)](#). A ADNI foi lançada em 2003 como uma parceria público-privada para avaliar marcadores clínicos, genéticos, bioquímicos e de neuroimagem longitudinais da doença de Alzheimer (AD). Este estudo utilizou sMRI T1w, adquirida com sequências tridimensionais *Magnetization-Prepared Rapid Gradient-Echo* (MP-RAGE) das fases ADNI-1, ADNI-2 e ADNI-GO, coletadas em centros nos Estados Unidos e no Canadá utilizando *scanners* de 1.5 T e 3 T da GE Healthcare, Philips Medical Systems e Siemens Medical Solutions.

A coleção inicial da ADNI compreendia 15,016 imagens de 1,495 participantes. Duas imagens de um participante com designação de sexo inválida foram excluídas, restando 15,014 imagens de 1,494 participantes.

O controle de qualidade foi aplicado a esse conjunto completo de volumes T1, antes da atribuição de rótulos diagnósticos e da construção das coortes. Métricas de qualidade de imagem (IQMs) sem necessidade de imagem de referência (*no-reference*) foram calculadas através da ferramenta MRQy ([Sadri et al., 2020](#)). Candidatos a *outliers* foram rastreados através das métricas VRX, COL, NUM, CPP, PSNR, SNR7, CNR, CVP, CJV, EFC e FBER, selecionadas pela sua relevância quanto ao recorte do campo de visão (FOV), geometria de aquisição, ruído e degradação relacionada a movimento ou artefatos. Para cada métrica, os *outliers* foram definidos pelas cercas de Tukey ([Tukey, 1977](#)),

$$[Q_1 - \alpha \text{IQR}, Q_3 + \alpha \text{IQR}], \quad \text{IQR} = Q_3 - Q_1, \quad (1)$$

com $\alpha = 1.5$ e direcionalidade específica da métrica (valores baixos indesejáveis, altos indesejáveis, ou bilateral). Cada volume recebeu uma pontuação de não conformidade igual ao número de IQMs sinalizadas; volumes com pontuação ≥ 3 compuseram uma lista restrita de casos possivelmente danificados (69/15,014; 0,46%). Os quartis e os limites do IQR foram estimados uma única vez a partir do conjunto inicial de 15,014 volumes, sem recálculos nas partições de validação

a jusante. Todos os 69 casos da lista restrita foram inspecionados visualmente no *software* ITK-SNAP (Yushkevich et al., 2006) (v4.2.0). A inspeção confirmou a exclusão de 12 identificadores de aquisição devido a FOV incompleto, aquisições danificadas ou faixas de ruído estruturado.

Em seguida, procedeu-se à construção da coorte clínica. Na ADNI, o diagnóstico associado à primeira visita (*baseline*) não acompanha necessariamente a progressão longitudinal do paciente. Por isso, cada exame de RM foi rigorosamente alinhado ao diagnóstico clínico e às escalas cognitivas/funcionais (ADAS, CDR, MMSE, FAQ) por correspondência temporal, exigindo-se uma distância absoluta ≤ 3 meses (± 90 dias) entre a data de aquisição da imagem e a data da avaliação clínica. Deste modo, imagens do mesmo paciente podem receber rótulos clínicos distintos ao longo do tempo.

Antes do pareamento imagem-diagnóstico, os registros diagnósticos longitudinais foram filtrados: removeram-se demências diferentes da doença de Alzheimer, diagnósticos ou datas em falta, e reversões de diagnósticos nas fases contínuas da AD (i.e., MCI→CN ou AD→MCI/CN). Esse rastreio identificou 40 participantes com reversão a partir de AD e, após a sua remoção, mais 128 com reversão MCI→CN, totalizando 168 participantes únicos excluídos. Destes, 112 estavam representados na coleção de imagens, correspondendo a 1,325 exames. O pareamento RM-diagnóstico na janela de ± 90 dias excluiu mais 666 imagens, e a exigência de escores clínicos completos excluiu outras 92, resultando em 12,931 imagens rotuladas de 1,304 participantes. Dos 12 identificadores rejeitados pelo controle visual de qualidade, 10 ainda estavam presentes após o pareamento clínico e foram removidos nesta etapa; os outros dois já haviam sido eliminados pelos filtros diagnósticos precedentes. A tabela após o controle de qualidade continha, portanto, 12,921 imagens. A remoção de 3,757 aquisições cuja descrição na ADNI as identificava como repetições (*repeats*) reduziu o conjunto a 9,164 candidatas longitudinais utilizáveis.

Esse conjunto de 9,164 imagens constitui o ponto de partida para a formação dos conjuntos longitudinais descritos a seguir. Ressalta-se que este montante ainda não coincide com a coorte final de análise (Tabela 3), a qual resulta da

exigência estrita de exatamente três imagens por paciente sob as regras de janela clínica e intervalo entre aquisições.

3.1. Formação dos conjuntos

A construção de cada conjunto longitudinal seguiu duas etapas sequenciais, garantindo que a rotulagem clínica permanecesse independente da escolha específica das imagens preditoras.

3.1.1. Etapa 1: Apuração do Rótulo Clínico

Para cada paciente, todas as aquisições de RM foram ordenadas cronologicamente. A data da primeira RM definiu o instante de referência i_0 (*baseline*). A partir de i_0 , estabeleceu-se uma janela de observação clínica de 36 ou 48 meses, com término em $t_{\text{end}} = i_0 + \text{janela}$. O diagnóstico de grupo (CN, sMCI, pMCI ou AD) foi determinado analisando-se toda a trajetória clínica do paciente dentro e imediatamente após este horizonte, antes da seleção das imagens preditoras.

3.1.2. Etapa 2: Seleção das Três Imagens Preditoras

Cada paciente elegível contribuiu com exatamente três aquisições de RM preditoras:

$$i = \{i_1, i_2, i_3\}, \quad t(i_1) < t(i_2) < t(i_3), \quad (2)$$

correspondendo a uma imagem inicial, uma intermediária e uma final dentro da janela de observação. O número três foi estabelecido como o requisito mínimo para capturar a trajetória temporal para permitir análise longitudinal em conjuntos de dados mais restritos. A seleção ocorreu de forma cronológica, baseada em um intervalo nominal entre aquisições (6 ou 12 meses) com uma tolerância de ± 2 meses, sob as seguintes regras:

1. i_1 é a primeira RM elegível na visita de *baseline* (i_0);
2. i_2 é a próxima RM disponível, em ordem cronológica, cujo intervalo em relação a i_1 esteja dentro da faixa de tolerância permitida;

3. i_3 é a próxima RM disponível após i_2 , cujo intervalo em relação a i_2 recaia na mesma faixa de tolerância.

As faixas de tolerância adotadas (± 2 meses) foram desenhadas para serem independentes entre as janelas de observação, conforme detalhado na Tabela 1.

Intervalo nominal (meses)	Faixa admitida (meses)
6	[4, 8]
12	[10, 14]

Tabela 1: Intervalos nominais entre aquisições e faixas de tolerância correspondentes.

O cruzamento das duas durações de janela clínica com os dois esquemas de espaçamento entre imagens gerou quatro coortes de análise: 36m_6m, 36m_12m, 48m_6m e 48m_12m.

3.1.3. Definição Operacional dos Grupos Clínicos

- **CN (Cognitivamente Normal):** Toda a trajetória diagnóstica é exclusivamente normal. Exige-se pelo menos uma visita com data $\geq t_{\text{end}}$ confirmando a estabilidade após a janela de observação. As imagens preditoras i_1, i_2, i_3 foram selecionadas entre avaliações CN anteriores a i_{end} e respeitou-se a faixa (min/máx) de tempo definido entre as imagens.
- **sMCI (MCI Estável):** O diagnóstico em i_0 é MCI e não há registro de AD até i_{end} . Exige-se que a primeira visita após o fim da janela ($> t_{\text{end}}$) permaneça classificada como MCI. Pacientes foram excluídos caso a primeira visita pós-janela indicasse conversão para AD (desfecho clinicamente ambíguo em relação ao horizonte) ou na ausência de seguimento além de i_{end} . As preditoras i_1, i_2, i_3 foram selecionadas obrigatoriamente dentro da janela temporal $\leq t_{\text{end}}$ e respeitou-se a faixa (min/máx) de tempo definido entre as imagens.
- **pMCI (MCI Progressivo):** O diagnóstico em i_0 é MCI e ocorre a conversão para AD dentro da janela de observação (com data $\leq t_{\text{end}}$) e

realizou-se a seleção das três primeiras imagens podendo ser (MCI, MCI, MCI) ou (MCI, MCI, AD), desde que i_3 fosse o primeiro diagnóstico de AD documentado. Padrões contendo dois diagnósticos pós-conversão (ex: MCI, AD, AD) foram rejeitados para evitar a captura de alterações estruturais predominantemente tardias.

- **AD (Doença de Alzheimer):** Toda a trajetória clínica a partir de i_0 é indicativa de demência por Alzheimer, em que as imagens foram extraídas dentro da janela de observação e respeitando a faixa de intervalo entre as imagens.

3.1.4. Coortes de Estudo

O conjunto final de dados foi consolidado em 2,038 imagens referentes a 560 participantes, estratificadas pelas diferentes fases do estudo ADNI. O detalhamento dos perfis demográficos e a evolução dos escores cognitivos/funcionais ao longo das três visitas preditoras (i_1, i_2, i_3) para sMCI e pMCI, em que as quatro combinações são demonstrados na Tabela 2.

A Tabela 3 sumariza as características da amostra na união lógica das imagens únicas presentes em pelo menos uma das quatro coortes (incluindo CN e AD). Após a exigência das três visitas e removendo a duplicidade iterativa entre coortes sobrepostas,

As bases de dados longitudinais AIBL [Ellis et al. \(2009\)](#) e OASIS-3 [LaMontagne et al. \(2019\)](#) foram investigadas com a mesma lógica de triagem e temporalidade. No entanto, elas não foram mantidas devido à insuficiência amostral de pacientes aptos a fornecer as três aquisições rigidamente espaçadas impostas por este desenho experimental.

3.1.5. Representação baseline e longitudinal

Cada sujeito contribui com exatamente três aquisições de imagem sMRI T1w, correspondentes às visitas i_1, i_2 e i_3 (com intervalos nominais de 6 ou 12 meses, sob tolerância de ± 2 meses). A representação de referência baseline utiliza exclusivamente os atributos extraídos da visita inicial $feat_{i_1}$ do conjunto

Coorte	Grupo	Slot	n	Sexo M/F	Idade	MMSE	ADAS	CDR-SB	FAQ
36m_6m	sMCI	i_0	125	80/45	72.63 ± 7.18	27.78 ± 1.75	9.05 ± 3.61	1.22 ± 0.64	1.93 ± 3.09
		i_1	125	80/45	73.16 ± 7.16	28.04 ± 1.77	8.79 ± 3.64	1.23 ± 0.77	2.22 ± 3.33
		i_2	125	80/45	73.67 ± 7.19	27.99 ± 1.88	8.47 ± 4.11	1.36 ± 0.95	2.53 ± 3.56
	pMCI	i_0	106	56/50	74.39 ± 7.33	26.64 ± 1.74	13.54 ± 4.49	1.94 ± 1.00	5.34 ± 4.42
		i_1	106	56/50	74.90 ± 7.26	25.32 ± 2.65	14.84 ± 5.00	2.44 ± 1.01	6.79 ± 4.75
		i_2	106	56/50	75.44 ± 7.30	24.68 ± 2.70	15.75 ± 5.83	3.19 ± 1.41	8.95 ± 5.66
36m_12m	sMCI	i_0	121	80/41	73.15 ± 7.06	27.80 ± 1.74	9.05 ± 3.60	1.21 ± 0.63	1.85 ± 3.01
		i_1	121	80/41	74.21 ± 7.07	28.02 ± 1.87	8.62 ± 4.20	1.33 ± 0.88	2.58 ± 3.48
		i_2	121	80/41	75.22 ± 7.05	27.85 ± 2.17	9.08 ± 4.54	1.51 ± 1.20	2.70 ± 3.65
	pMCI	i_0	33	22/11	74.30 ± 7.35	27.00 ± 1.62	12.30 ± 2.85	2.09 ± 1.17	5.45 ± 4.90
		i_1	33	22/11	75.33 ± 7.34	25.88 ± 2.13	13.31 ± 4.07	2.67 ± 1.19	7.55 ± 4.94
		i_2	33	22/11	76.39 ± 7.34	23.33 ± 2.91	17.24 ± 4.78	4.45 ± 1.40	12.76 ± 6.02
48m_6m	sMCI	i_0	73	48/25	72.29 ± 6.80	27.89 ± 1.65	8.80 ± 3.53	1.11 ± 0.61	1.88 ± 3.32
		i_1	73	48/25	72.84 ± 6.74	28.30 ± 1.40	8.33 ± 3.40	1.09 ± 0.71	2.07 ± 3.40
		i_2	73	48/25	73.30 ± 6.81	28.16 ± 1.84	7.83 ± 3.49	1.16 ± 0.95	2.30 ± 3.36
	pMCI	i_0	120	62/58	74.35 ± 7.20	26.65 ± 1.71	13.20 ± 4.41	1.89 ± 0.98	5.17 ± 4.46
		i_1	120	62/58	74.85 ± 7.15	25.43 ± 2.60	14.44 ± 4.99	2.37 ± 1.00	6.46 ± 4.81
		i_2	120	62/58	75.40 ± 7.18	24.89 ± 2.65	15.38 ± 5.65	3.04 ± 1.43	8.53 ± 5.81
48m_12m	sMCI	i_0	72	49/23	72.88 ± 6.70	28.00 ± 1.63	8.71 ± 3.40	1.07 ± 0.59	1.85 ± 3.30
		i_1	72	49/23	73.93 ± 6.73	28.32 ± 1.69	8.07 ± 3.65	1.17 ± 0.89	2.43 ± 3.37
		i_2	72	49/23	74.96 ± 6.68	28.29 ± 1.86	8.65 ± 3.59	1.29 ± 1.03	2.26 ± 3.26
	pMCI	i_0	48	28/20	73.98 ± 6.83	26.94 ± 1.56	12.18 ± 2.95	1.93 ± 1.10	4.83 ± 4.88
		i_1	48	28/20	75.00 ± 6.83	25.90 ± 1.95	13.24 ± 3.79	2.45 ± 1.18	6.77 ± 5.36
		i_2	48	28/20	76.06 ± 6.86	23.90 ± 2.81	16.44 ± 4.81	3.76 ± 1.61	10.56 ± 6.51

Nota: Inclusão ampliada de pMCI (último preditor = primeiro AD): 46 casos em 36m_6m/48m_6m; 33 casos em 36m_12m/48m_12m. MMSE: *Mini-Mental State Examination*; ADAS: *Alzheimer's Disease Assessment Scale*; CDR-SB: *Clinical Dementia Rating – Sum of Boxes*; FAQ: *Functional Activities Questionnaire*.

Tabela 2: Características clínicas longitudinais sMCI/pMCI nas quatro coortes de estudo. Os valores são apresentados como média $\pm$ desvio-padrão.

Fase ADNI	Imagens	Pacientes	Sexo (M/F)	Idade (anos)	Campo (1.5T / 3T)	Fabricante (n)
ADNI 1	1349	370	203/167	76.14 ± 6.91	1261 / 88	GE (768); Siemens (579); Philips (2)
ADNI GO	51	27	16/11	70.61 ± 6.76	0 / 51	Siemens (44); Philips (7)
ADNI 2	638	190	101/89	73.63 ± 7.02	0 / 638	Siemens (483); Philips (155)
Total	2038	560	304/256	75.21 ± 7.07	1261 / 777	GE (768); Siemens (1106); Philips (164)

Nota: Idade computada como média $\pm$ DP no momento exato da aquisição. A estratificação de sexo por paciente contabiliza os indivíduos únicos dentro de cada fase isolada (um mesmo paciente pode contribuir com imagens capturadas em mais de uma fase, o que explica $370 + 27 + 190 = 587 > 560$). Modelos de equipamento (n imagens): ADNI 1 — SIGNA EXCITE (445), Symphony (233), SIGNA HDx (196), Sonata (146), GENESIS_SIGNA (123), Avanto (100), Trio (34), SymphonyTim (25), Allegra (17), SonataVision (13), TrioTim (11); ADNI GO — Verio (25), TrioTim (18), Intera (4), Achieva (3), Skyra (1); ADNI 2 — TrioTim (297), Achieva (95), Verio (95), Skyra (90), Intera (38), Ingenia (17).

Tabela 3: Demografia e dados técnicos das imagens T1w MP-RAGE (união sem repetições das quatro coortes de análise, considerando imagens únicas por identificador de aquisição).

i_1, i_2, i_3 . A representação longitudinal proposta ($\text{feat}_{i_1}, \Delta_{21}, \Delta_{32}$) concatena, para o mesmo paciente, o estado basal com as diferenças absolutas entre visitas consecutivas: $\text{feat}_{i_1}, \text{feat}_{\Delta_{21}}, \text{feat}_{\Delta_{32}}$, onde $\Delta_{21} = \text{feat}_{i_2} - \text{feat}_{i_1}$ e $\Delta_{32} = \text{feat}_{i_3} - \text{feat}_{i_2}$. Não entram os níveis crus de i_2 e i_3 , nem a diferença acumulada $\Delta_{31} = \text{feat}_{i_3} - \text{feat}_{i_1}$, nem taxas de variação. O delineamento testa se a trajetória (baseline + mudanças $i_1 \rightarrow i_2$ e $i_2 \rightarrow i_3$) agrega poder discriminatório em relação ao baseline isolado.

3.2. Pré-processamento

Após a obtenção dos dados brutos de smri na base ADNI, os volumes foram submetidos a um pipeline de pré-processamento para permitir a análise de atributos radiômicos [Zwanenburg et al. \(2020\)](#). A Figura 1 ilustra a arquitetura metodológica proposta, englobando as etapas tratamento, pré-processamento, seleção de atributos e modelagem computacional.

Na etapa de pré processamento, todas as imagens foram processados por meio de uma cadeia sequencial de passos, composta pelas seguintes etapas:




Figura 1: Diagrama esquemático do pipeline de processamento e análise radiômica.

3.2.1. Extração de crânio (Skull stripping):

Executada utilizando um modelo de extração encefálica baseado em aprendizagem profunda, treinado em imagens T1 e disponível na biblioteca ANTsPyNet (`antspynet.brain_extraction, modality="t1"`) [Tustison et al. \(2021\)](#).

3.2.2. Filtragem de ruído (Denoising):

Aplicação de um filtro de médias não locais adaptativas otimizado para ruído ricianiano [Manjón et al. \(2010\)](#), implementado através da função `ants.denoise_image`. Foram adotados os parâmetros `noise_model="Rician"`, raio de *patch* $p = 2$, raio de busca $r = 3$ e `mask=None`. O parâmetro `shrink_factor=1`, específico do pacote ANTs, foi utilizado para desativar a subamostragem (*downsampling*) interna, constituindo uma diretriz de implementação da ferramenta e não uma modificação da formulação matemática original.

3.2.3. Correção de campo de viés (Bias field correction):

Aplicação do algoritmo N4ITK [Tustison et al. \(2010\)](#) por meio da função `ants.n4_bias_field_correction`, configurado com `shrink_factor=3`, `convergence={iters: [50, 50, 50, 50], tol:  $1 \times 10^{-7}$ }` (representando quatro níveis de multir-resolução), `spline_param=200`, `rescale_intensities=True` e `mask=None`.

3.2.4. Normalização de intensidade (Histogram matching):

As intensidades dos volumes T1 foram padronizadas utilizando a técnica de pareamento de histograma (*histogram matching*) [Nyul et al. \(2000\)](#) em relação

ao *template* fixo MNI152 2009c [Fonov et al. \(2011\)](#). Esta etapa foi implementada com a função `ants.histogram_match_image2` (`transform_domain_size=128`, `match_points=16`), aplicada após uma normalização `min-max` conduzida de forma independente para as imagens fonte e de referência. As máscaras encefálicas, tanto da imagem original quanto da referência, foram estimadas via `ants.get_mask`. As intensidades pareadas foram subsequentemente reescaladas com base no percentil 99,9 dos voxels pertencentes à região encefálica da imagem de referência.

3.2.5. Parcelamento anatômico e segmentação tecidual:

Os mapas de regiões de interesse (ROI) foram gerados utilizando a função `antspynet.desikan_killiany_tourville_labeling` [Tustison et al. \(2021\)](#) (`modality="t1"`, `do_preprocessing=True`), com ênfase na identificação dos hipocampos (rótulos DKT 17 e 53) e demais regiões empregadas na extração radiômica. Adicionalmente, a segmentação volumétrica em Líquido Cefalorraquidiano (CSF), Substância Cinzenta (GM) e Substância Branca (WM) — correspondentes aos rótulos 1, 2 e 3 — foi realizada via `antspynet.deep_atropos`, mantendo a mesma configuração de modalidade e pré-processamento. Esta decisão metodológica visou assegurar a compatibilidade das imagens de entrada com a distribuição de dados na qual os pesos dos modelos de aprendizagem profunda do ANTsPyNet foram otimizados, ainda que isso implicasse certa redundância procedimental nas normalizações de intensidade e espaço. Ressalta-se, contudo, que os mapas de rótulos resultantes foram utilizados exclusivamente para a delimitação de ROIs e cálculo de frações teciduais, e que as transformações geométricas e de intensidade subjacentes ao ANTsPyNet não figuraram como estágios treináveis no modelo preditivo final.

3.2.6. Interpolação isotrópica e Alinhamento espacial:

Para satisfazer os requisitos de extração de atributos radiômicos, os volumes T1 já pré-processados foram submetidos a um registro puramente **rígido** (6 graus de liberdade: translação e rotação, sem componentes afins ou deformáveis)

em relação ao *template* MNI152 2009c, estabelecendo uma grade isotrópica com resolução de 1,0 mm. Neste contexto, o *template* atuou estritamente como um referencial geométrico (espaçamento e orientação canônicos), não como um alvo para normalização anatômica não-linear. O cômputo da transformação e a subsequente interpolação da imagem T1 foram realizados via `ants.registration` (`type_of_transform="Rigid"`, interpolador `"linear"`), definindo o *template* MNI como imagem fixa e a T1 do paciente como imagem móvel. A matriz de transformação resultante (`fdwtransforms`) foi então aplicada aos mapas de parcelamento DKT originais, segmentações de classes teciduais e máscara encefálica através da função `ants.apply_transforms`. Para essa etapa, a imagem T1 reamostrada serviu como referência espacial, utilizando-se mandatoriamente o interpolador de vizinho mais próximo (`"nearestNeighbor"`) para preservar a integridade dos identificadores inteiros das classes anatômicas.

3.2.7. Discretização de Intensidade (Binning)

As intensidades das imagens T1 foram discretizadas utilizando a estratégia de Número Fixo de *bins* (FBN), em conformidade com as diretrizes da *Image Biomarker Standardization Initiative* (IBSI). O processo foi aplicado de forma independente aos *voxels* da máscara de cada região de interesse (ROI). Fixou-se a parametrização `binCount=32` ($N_g = 32$ níveis de cinza) para garantir dimensões exatas e constantes (32×32) nas matrizes de coocorrência (GLCM) ao longo de todos os sujeitos e visitas. Esta escolha metodológica justifica-se pelo fato de que discretizações demasiadamente severas (e.g., 8 níveis) comprimem e atenuam o sinal biológico, ao passo que granularidades altas (como 64 ou mais níveis) tendem a produzir matrizes extensas, vazias e mal condicionadas [Molina et al. \(2016\)](#).

3.3. Extração de atributos

Para uma análise mais detalhada em nível de atributos, extraem-se cinco classes distintas de atributos: volume, forma, textura GLCM, primeira ordem e deslocamento normativo.

3.3.1. Atributos volumétricos

Por ROI intersectada com a máscara encefálica, `3_feat_vol.py` regista volumes em mm^3 e fracções *dentro da ROI*: $\text{gm_norm} = V_{\text{GM}}/V_{\text{ROI}}$ (análogo para WM e LCR). O ICV (`ICV_mask_mm3`) é o volume da máscara encefálica (linha `__global__`). No pós-processamento, descritores de tamanho (mm^3 e malha/eixos do PyRadiomics) dividem-se por esse ICV; as fracções **não** se re-normalizam pelo ICV — não são volumetria clássica em mm^3 Wyman et al. (2013). Entram `gm_norm`, `wm_norm`, `csf_norm` e `original_shape_MeshVolume` (já /ICV). Saem volumes crus em mm^3 . O volume de malha fica no bloco de volume, não no de forma.

3.3.2. Atributos radiómicos (PyRadiomics)

Forma, textura e primeira ordem extraem-se com PyRadiomics versão 3.1.1.dev111+g8ed579383 van Griethuysen et al. (2017). Nomes e definições seguem a terminologia IBSI da biblioteca Zwanenburg et al. (2020); não se reivindica validação IBSI. Todas as definições dos atributos radiómicos são fornecidas no Image Biomarker Standardization Initiative (IBSI) reference manual <https://ibsi.readthedocs.io/en/latest/>.

A extração de atributos restringiu-se ao tipo `Original` (sem a aplicação de filtros LoG ou *wavelet*), sendo computada exclusivamente sobre a região do hipocampo. Utilizaram-se volumes T1 previamente submetidos a registro rígido para o *template* MNI152 2009c em uma grade isotrópica de 1,0,mm, mantendo-se a reamostragem interna do PyRadiomics desativada para evitar os artefactos de uma segunda interpolação espacial.

A extração guarda 56 descritores: 18 de primeira ordem, 14 de forma e 24 GLCM. Nas ablações hipocampais oficiais, definidos na Tabela 4):

3.4. Atributos de deslocamento

Para quantificar o desvio biomecânico local (atrofia ou expansão), os exames foram registrados contra referenciais de envelhecimento saudável. Este processo seguiu três etapas estruturais: a construção do espaço normativo, o registro

Subcategoria	n	Atributos (sufixo)
Primeira ordem	16	10Percentile, 90Percentile, Entropy, InterquartileRange, Kurtosis, Maximum, Mean, MeanAbsoluteDeviation, Median, Minimum, Range, RobustMeanAbsoluteDeviation, RootMeanSquared, Skewness, Uniformity, Variance
Forma	12	SurfaceArea, SurfaceVolumeRatio, Sphericity, Elongation, Flatness, LeastAxisLength, MajorAxisLength, MinorAxisLength, Maximum2DDiameterColumn, Maximum2DDiameterRow, Maximum2DDiameterSlice, Maximum3DDiameter
Textura (GLCM)	24	Autocorrelation, ClusterProminence, ClusterShade, ClusterTendency, Contrast, Correlation, DifferenceAverage, DifferenceEntropy, DifferenceVariance, Id, Idm, Idmn, Idn, Imc1, Imc2, InverseVariance, JointAverage, JointEnergy, JointEntropy, MCC, MaximumProbability, SumAverage, SumEntropy, SumSquares
Total	52	—

Tabela 4: Atributos PyRadiomics retidos nas ablações hipocampais. Prefixo `original_` omitido na coluna de nomes para legibilidade; no CSV o nome completo inclui `original_firstorder_`, `original_shape_` ou `original_glc_`.

transversal de cada visita clínica e a extração estatística dos tensores de deformação.

3.4.1. Construção de templates groupwise estratificados

Para mitigar o viés inerente à utilização de um único sujeito de referência [Reuter et al. \(2012\)](#), construíram-se *templates* volumétricos médios a partir de imagens T1 exclusivas de indivíduos cognitivamente normais (CN). Os *templates* foram estratificados por sexo biológico e década de idade (de 50–59,9 até 90–99,9 anos).

Em cada estrato sexo-década, foram selecionadas aleatoriamente até $N_{\max} = 20$ aquisições CN (semente fixa `RANDOM_SEED=7`). Esta amostra foi estabelecida em definitivo antes do ciclo de validação cruzada aninhada, assegurando que o referencial normativo fosse disjunto das partições de teste e totalmente isolado das classes prognósticas de interesse (sMCI e pMCI).

O alinhamento *groupwise* iniciou-se com um pré-registro global afim direcionado a um referencial comum. O *template* inicial resultante foi refinado ao longo de cinco iterações de registro não linear via algoritmo SyN [Avants et al. \(2014\)](#). Em cada ciclo iterativo, todas as imagens do estrato foram registradas sob máscara encefálica ao *template* corrente, atualizando-o na sequência pela média global deformada. Na etapa final, as intensidades intracranianas sofreram reescalonamento fotométrico linear para o intervalo $[0, 1]$ (com cortes restritos aos percentis 2 e 98), harmonizando o contraste sem corromper as transformações biomecânicas subsequentes.

3.4.2. Registro normativo visita a visita

Para a avaliação longitudinal, designou-se a cada participante o *template* CN correspondente ao seu sexo biológico e à sua década de vida na data da visita inicial (i_1), independentemente do diagnóstico clínico no momento [Wyman et al. \(2013\)](#). Este mesmo atlas normativo funcionou como âncora e foi mantido inalterado para as avaliações das visitas subsequentes (i_2 e i_3).

Em cada instante $t \in \{i_1, i_2, i_3\}$, o algoritmo SyN não linear [Avants et al.](#)

(2011) foi executado de forma transversal e independente na grade isotrópica de 1,0 mm. O *template* CN designado atuou estritamente como imagem **fixa** e a aquisição clínica T1 do paciente como imagem **móvel** (`ants.registration` parametrizado com interpolação B-spline). O otimizador forneceu a transformação direta F_t (móvel $\rightarrow$ fixa) e sua respectiva contraparte inversa I_t (fixa $\rightarrow$ móvel). Destaca-se que não foram estabelecidos campos de diferença diretos inter-visitas (e.g., $i_1 \rightarrow i_2$); cada instante avaliativo quantificou o seu próprio desvio absoluto contra a referência CN estacionária comum.

3.4.3. Extração dos atributos de deslocamento

A quantificação do campo de deslocamento vetorial ocorreu primariamente no domínio da imagem do paciente. O vetor direcional $\mathbf{u}_t(x)$ foi definido a partir da transformação inversa I_t :

$$\mathbf{u}_t(x) = I_t(x) - x, \quad x \in \Omega_{\text{CN}}$$

Para delimitar as métricas às áreas de interesse, as máscaras parceladas (atlas DKT) e a máscara encefálica do sujeito foram transportadas para Ω_{CN} aplicando a transformação direta F_t (*warp* + afim), com interpolador de vizinho mais próximo.

A partir do campo vetorial $\mathbf{u}_t$, derivaram-se três mapas escalares: o logaritmo do jacobiano (`logjac`), a magnitude geométrica (`mag`) e a norma de Frobenius do tensor de deformação (`strain_fro`). O campo infinitesimal subjacente obedeceu à formulação $\varepsilon = \frac{1}{2}(H + H^\top)$, na qual $H = \nabla \mathbf{u}_t$ (Bouke and Abdullah, 2023).

Para a região hipocampal, o classificador recebeu 15 descritores por hemisfério em cada visita, derivados de três mapas avaliados no domínio do *template*: magnitude (`mag_`), logaritmo do jacobiano (`logjac_`) e norma de Frobenius (`strain_fro_`). De cada mapa, extraíram-se cinco momentos estatísticos: média, desvio-padrão, variância amostral, assimetria de Fisher e curtose.

Considerando o hipocampo bilateral, a representação estática no *baseline* (instante i_1) totaliza 30 atributos. Para a codificação longitudinal, seja S um

descriptor genérico deste conjunto, a evolução temporal do paciente foi estruturada no formato $\{S_{i_1}, \Delta_{21}, \Delta_{32}\}$, em que $\Delta_{21} = S_{i_2} - S_{i_1}$ e $\Delta_{32} = S_{i_3} - S_{i_2}$. Este arranjo expande o vetor para 90 colunas. Consequentemente, a dinâmica inter-visitas é quantificada de maneira estritamente escalar através das variações absolutas dos momentos estatísticos regionais, dispensando a complexa composição de *warps* espaciais entre as aquisições.

3.5. Desenho experimental

A principal tarefa é a classificação binária entre sMCI e pMCI, estratificada em quatro coortes independentes, elaboradas pela combinação da janela de observação e da faixa de intervalo entre as aquisições (Tabela 2). A inclusão em qualquer coorte exigiu rigorosamente a disponibilidade de três exames de sMRI T1w consecutivos contendo a ROI hipocampal bilateral identificável nos instantes i_1 , i_2 e i_3 dentro da janela de observação de 36 e 48 meses, com intervalos inter-visitas de 6 e 12 meses limitados a uma tolerância de ± 2 meses.

A restrição do tamanho amostral global (n) é resultado das definições metodológicas exigidas para a modelagem: a necessidade de três vetores preditivos completos e sequenciais, bem como a observação do comportamento clínico temporal. Com o intuito de apoiar a capacidade de generalização do modelo e mitigar o risco de vazamento de dados, o particionamento ocorreu de forma restrita em nível de paciente (patient-level split). Assim, todos os três pontos temporais de um mesmo indivíduo foram alocados ao mesmo estrato, assegurando a independência adequada entre os conjuntos de treinamento e teste.

A caracterização demográfica, definição metodológica e as análises principais foram ancoradas na coorte com janela de observação de 48 meses com tempo entre as imagens de 12 meses ± 2 meses por possuir o maior distanciamento temporal. Em contrapartida, as demais coortes (janela de observação/range min-máx entre as imagens = 36/6 ± 2 meses, 36/12 ± 2 meses, 48/6 ± 2 meses) compuseram as análises de sensibilidade, permitindo avaliar a consistência dos achados sob diferentes janelas clínicas e intervalos de aquisição.

3.6. Prevenção de Vazamento de Dados.

Para obter estimativas de validação cruzada robustas e minimizar o risco de vazamento de informação (*data leakage*), estabeleceu-se uma distinção clara entre os processos fixos por imagem e os métodos dependentes da amostra. Procedimentos relacionados ao pré-processamento das imagens (e.g., remoção do crânio, redução de ruído, correção do bias field, casamento de histograma, alinhamento, parcelamento da ROI e segmentação dos tecidos) foram executados uma única vez por imagem. Sob configurações pré-definidas e algoritmos fixos, essas etapas operaram independentemente da existência dos rótulos de classe (sMCI/pMCI) e não requereram calibrações baseadas no agrupamento da população. Da mesma forma, os limites de controle de qualidade (QC) e a construção dos *templates* normativos CN foram definidos integralmente antes da fase de seleção do classificador.

Por outro lado, as transformações matemáticas baseadas na configuração e na distribuição estatística dos dados foram restritas à malha interna da validação cruzada aninhada (*nested cross-validation*). Filtros de covariância cruzada colinear, normalização por *z-score*, regularização linear, parametrização estocástica e a definição dos limiares de decisão de Youden foram calibrados apenas com os dados dos estratos de treinamento. Uma vez ajustados, esses coeficientes foram aplicados aos *folds* externos de teste, mantendo a integridade e a validade da avaliação preditiva.

3.7. Validação aninhada ao nível do paciente

Os modelos prognósticos foram avaliados por meio de uma validação cruzada (CV) aninhada e estratificada (**StratifiedKFold**), estruturada estritamente ao nível do paciente para evitar qualquer vazamento de informação inter-visitas (*data leakage*) durante a fase de modelagem. O particionamento das partições (*folds*) obedeceu exclusivamente ao identificador único do participante, garantindo que todas as instâncias temporais de um mesmo sujeito pertencessem ao mesmo estrato (treinamento ou teste), atuando como mecanismo contra o enviesamento temporal.

A arquitetura iterativa englobou um ciclo externo composto por 5 partições ($k_{\text{out}} = 5$), repetido 10 vezes ($R = 10$), totalizando 50 avaliações de generalização independentes por configuração, representado pela Figura 2.




Figura 2: Diagrama da arquitetura de validação cruzada aninhada restrita ao nível do paciente.

3.7.1. Dinâmica do ciclo externo

A validação externa adotou o método *StratifiedKFold* com $k_{\text{out}} = 5$, estratificado por classe e rigorosamente particionado ao nível do paciente. Em cada partição (*fold*), aproximadamente 80% dos participantes compuseram o conjunto de treinamento e 20% o conjunto de teste (e.g., na coorte principal com $n = 120$, a alocação equivale a cerca de 96 sujeitos para treino e 24 para teste).

Para assegurar a ausência de vazamento de informação, todos os procedimentos que consomem rótulos ou estimam parâmetros a partir da distribuição da amostra limitaram-se *exclusivamente* ao conjunto de treinamento externo. Este encapsulamento metodológico abrangeu sequencialmente: (i) a construção

unívoca do *pool* de seleção por estabilidade com penalização ℓ_1 e bootstrap empregando $B = 50$ réplicas de *bootstrap* (Equações (6)–(7)); (ii) a pré-seleção estatística (**CorrVarSelector**: $|\rho| > 0,85$ e variância $< 0,01$); (iii) a padronização paramétrica (**StandardScaler**); (iv) a sintonia hiperparamétrica da SVM via Optuna (10 ensaios balizados pela AUC interna); e (v) o ajuste final do classificador.

A seleção por estabilidade com penalização ℓ_1 e bootstrap define, em cada fold externo e apenas no treino, um pool de descritores hipocampais retidos de forma consistente em $B = 50$ réplicas amostrais. O classificador SVM restringe-se a esse pool, reduzindo dimensionalidade e instabilidade da seleção frente ao vetor completo de atributos radiômicos e de deslocamento.

O limiar ótimo de Youden τ^* (Eq. 5) foi estimado a partir das predições *out-of-fold* consolidadas no ciclo interno. Por fim, o conjunto de teste externo operou de forma estritamente cega, recebendo apenas as transformações e predições diretas com os parâmetros previamente congelados no treinamento, sem sofrer qualquer reajuste.

3.7.2. Dinâmica do ciclo interno

A otimização de hiperparâmetros ocorreu estritamente dentro do conjunto de treinamento externo, utilizando uma segunda malha *StratifiedKFold* com $k_{\text{in}} = 5$. Em cada subpartição interna, 80% dos dados foram alocados para o ajuste do modelo e 20% para a validação estratificada, garantindo total isolamento metodológico em relação ao teste externo. A busca hiperparamétrica foi orquestrada pelo algoritmo Optuna (Akiba et al., 2019), configurada para 10 ensaios por *fold* externo, tendo como função objetivo a maximização da AUC média nas cinco partições de validação interna.

O fluxo de processamento operou na seguinte sequência: filtragem estatística (correlação $|\rho| > 0,85$; variância $< 0,01$) $\rightarrow$ padronização **StandardScaler** $\rightarrow$ classificação SVM (**probability=True**). Em cada iteração deste ciclo interno, os parâmetros de filtragem e de escalonamento foram recalculados exclusivamente sobre o treinamento interno e aplicados ao subespaço restrito ao *pool* de

seleção ℓ_1 por frequência de bootstrap (previamente fixado pelo ciclo externo correspondente). Como mecanismo de salvamento metodológica, i.e., caso a restrição dos filtros internos resultasse no esvaziamento completo do subespaço vetorial, a totalidade do *pool* selecionado na etapa anterior era restaurada.

3.7.3. Agregação e Isolamento Metodológico.

Ao término da busca interna, a configuração hiperparamétrica vencedora foi integralmente reajustada sobre o conjunto completo de treinamento externo, promovendo o recalibrar final dos filtros, do z-score e da calibração logística de Platt. Ao conjunto de teste externo aplicou-se unicamente as transformações inferenciais diretas. Dentro de cada repetição r , os cinco *folds* de teste foram concatenados, originando um vetor completo com exatamente uma predição *Out-Of-Fold* (OOF) probabilística por participante. As dez probabilidades resultantes por sujeito foram agregadas por média aritmética antes do cômputo da métrica primária AUC_{patient} fornecidas pela Equação 4.

3.7.4. Métricas de avaliação

Seja $s_{ir} = \widehat{\text{Pr}}(y = 1 \mid x_i)$ a probabilidade predita para o participante i no conjunto de teste externo durante a repetição $r \in \{1, \dots, R\}$ (com $R = 10$). Em cada repetição, a concatenação das partições de teste ($k_{\text{out}} = 5$) produz exatamente uma predição *out-of-sample* por sujeito. É imprescindível distinguir estas estimativas finais daquelas geradas no ciclo interno (*out-of-fold*), as quais serviram estritamente para a otimização de hiperparâmetros e para a estimação do limiar de corte. Todos os classificadores avaliados produziram probabilidades calibradas. Especificamente para a Máquina de Vetores de Suporte (SVM), a calibração logística de Platt foi integrada de forma nativa ao ajuste do modelo sobre o treinamento externo (`probability=True`).

O estimador primário de desempenho baseou-se na agregação das probabilidades preditas ao longo das R repetições para cada paciente:

$$\bar{s}_i = \frac{1}{R} \sum_{r=1}^R s_{ir}. \quad (3)$$

A **métrica primária** do estudo é a Área Sob a Curva ROC calculada ao nível do paciente (AUC_{patient}). Essa métrica foi computada sobre o conjunto de pares $\{(y_i, \bar{s}_i)\}_{i=1}^n$ utilizando a estatística de Mann-Whitney, com penalização equitativa (peso de 1/2) para empates probabilísticos:

$$\begin{aligned} AUC_{\text{patient}} &\equiv \widehat{AUC}_{\text{agg}} = AUC(\{(y_i, \bar{s}_i)\}_{i=1}^n) \\ &= \frac{1}{n_+ n_-} \sum_{i: y_i=1} \sum_{j: y_j=0} (\mathbb{I}(\bar{s}_i > \bar{s}_j) + \frac{1}{2} \mathbb{I}(\bar{s}_i = \bar{s}_j)), \end{aligned} \quad (4)$$

em que $\mathbb{I}(\cdot)$ denota a função indicadora, e n_+ e n_- representam o número de instâncias positivas e negativas, respectivamente.

Para quantificar a variabilidade do treinamento constituindo um **resumo secundário**, distinto da incerteza amostral da $\widehat{AUC}_{\text{agg}}$, reportou-se a média e o desvio-padrão (DP) da AUC computada isoladamente em cada uma das $5 \times R = 50$ partições de teste externo. Já a inferência estatística sobre o estimador primário, abrangendo o cálculo de desvios-padrão das tabelas, intervalos de confiança a 95% e testes pareados para o diferencial de desempenho (ΔAUC), foi conduzida de forma não-paramétrica via *bootstrap* com reamostragem de pacientes sobre $\{\bar{s}_i\}$. Utilizaram-se $B = 2000$ iterações para as margens de erro visuais e tabeladas, e $B = 5000$ para os contrastes inferenciais pareados.

Para as métricas dependentes de limiar de decisão binário, o ponto de operação ótimo (τ^*) foi determinado pela maximização do índice de Youden sobre os escores probabilísticos gerados no ciclo interno de validação:

$$J(\tau) = \text{TPR}(\tau) + \text{TNR}(\tau) - 1, \quad \tau^* = \arg \max_{\tau \in [0,1]} J(\tau), \quad (5)$$

em que TPR e TNR representam as taxas de verdadeiros positivos e verdadeiros negativos. A busca por τ^* foi estritamente delimitada ao domínio probabilístico $[0, 1]$. Calibrou-se um limiar ótimo de forma independente para cada *fold* externo, o qual foi aplicado sem qualquer reajuste global ao respectivo conjunto de teste.

3.7.5. Classificação e Inferência Estatística

O estimador primário estabelecido para a totalidade das análises foi a Máquina de Vetores de Suporte (SVM) Cortes and Vapnik (1995), configurada com núcleo linear ou de base radial (RBF). O escopo deste estudo avalia fundamentalmente a capacidade preditiva da representação temporal de biomarcadores. A fixação estrita da SVM isola os contrastes experimentais de vieses algorítmicos inerentes à variação de capacidade do modelo e aos métodos intrínsecos de regularização, além de figurar como padrão consolidado em estudos de discriminação morfológica na base ADNI sob a condição de alta dimensionalidade de atributos em amostras restritas ($p \approx n$) Cuingnet et al. (2011). Métodos adicionais, como Florestas Aleatórias (*Random Forest*) Breiman (2001) e regressão logística com regularização *Elastic-Net* Zou and Hastie (2005), foram definidos para realizar as análises de sensibilidade secundárias.

Todos os testes estatísticos reportados fundamentaram-se nas probabilidades *Out-Of-Fold* agregadas ao nível do paciente ($\{\bar{s}_i\}$). A significância contra o acaso computou-se via permutações nulas empíricas dos rótulos de classe, sob congelamento fixo dos escores originais ($B_{\text{perm}} = 5000$), com correção probabilística exata $p = (r + 1)/(B_{\text{perm}} + 1)$. A diferenciação de desempenho intra-sujeito nos contrastes pareados baseou-se em reamostragem *bootstrap* estrita de pacientes ($B_{\text{boot}} = 5000$ amostras com reposição) inferindo-se intervalos percentílicos de confiança a 95% sobre as variações da métrica (ΔAUC). Dado que o *cross-validation* compartilhou determinística semente randômica nos protocolos comparados, garantiu-se o alinhamento emparelhado estrito dos pacientes ao longo das *folds*. Nos contrastes relativos à vantagem temporal, assumiu-se previamente a superioridade do modelo longitudinal perante o corte seccional, orientando-se pelo cômputo empírico do p -valor **unilateral** associado à hipótese alternativa ($H_1 : \text{AUC}(\text{Q4}) > \text{AUC}(\text{t1_only})$), seguido da estrita correção de Benjamini-Hochberg (Taxa de Falsas Descobertas - FDR) balizada nas cinco famílias matemáticas ativas na respectiva coorte analítica. O teste bilateral não-direcional (p bilateral) reservou-se exclusivamente para análises comparati-

vas alheias a hipóteses temporais restritas, tal como a equivalência discriminativa entre biomarcadores neuroestruturais versus ferramentas de triagem clínica exclusivas.

3.8. Normalização e seleção de atributos

Todos os atributos preditivos restringiram-se ao hipocampo bilateral. Na classe volumétrica, retiveram-se apenas as frações teciduais intrarregionais (WM, GM e CSF) e o volume da malha geométrica (`original_shape_MeshVolume`) extraído via PyRadiomics, sendo todos normalizados pelo Volume Intracraniano (ICV). De modo análogo, os descritores da família de forma (*shape*) dependentes da escala espacial, tais como área de superfície, eixos morfológicos e diâmetros máximos, também foram divididos pelo ICV. Em contrapartida, as métricas de textura (GLCM), as estatísticas de primeira ordem (com exceção de **Energy** e **TotalEnergy**) e os momentos do campo de deslocamento normativo permaneceram em suas unidades originais.

A etapa de seleção de atributos fundamentou-se na frequência empírica de retenção sob penalização ℓ_1 acoplada a reamostragem *bootstrap* (Bach, 2008; Meinshausen and Bühlmann, 2010). Em cada partição (*fold*) externa da validação cruzada, o algoritmo de seleção foi executado uma única vez e restrito exclusivamente ao conjunto de treinamento. Este processo gerou um subespaço reduzido de características (*pool*), garantindo que a Máquina de Vetores de Suporte (SVM) subsequente operasse sem acesso ou vazamento de informações do espaço dimensional original completo.

Sobre o subespaço residual (após eventuais filtragens prévias), geraram-se $B = 50$ amostras *bootstrap* com reposição. Réplicas que contivessem amostras de apenas uma classe foram sumariamente descartadas. Em cada réplica biclasse, aplicou-se uma padronização interna (*intra-bootstrap*) seguida da otimização logística regularizada:

$$\hat{\boldsymbol{\beta}}^{(b)}, \hat{\beta}_0^{(b)} = \arg \min_{\boldsymbol{\beta}, \beta_0} \left\{ \sum_{i=1}^{n_{\text{train}}^{(b)}} \ell(y_i, \sigma(\mathbf{x}_i^\top \boldsymbol{\beta} + \beta_0)) + C^{-1} \|\boldsymbol{\beta}\|_1 \right\}, \quad (6)$$

$$\ell(y, p) = -y \log p - (1 - y) \log(1 - p),$$

utilizando o algoritmo de otimização SAGA com a regularização inversa fixada em $C = 0,1$. O termo de intercepto (β_0) não sofreu penalidade ℓ_1 . Definindo-se o conjunto ativo de cada réplica como $\mathcal{M}^{(b)} = \{j : |\hat{\beta}_j^{(b)}| > 10^{-9}\}$, as iterações nas quais o vetor de coeficientes foi inteiramente zerado ($\mathcal{M}^{(b)} = \emptyset$) foram excluídas do cômputo do denominador efetivo B_{eff} .

A frequência de seleção foi contabilizada em nível do grupo anatômico temporal g , e não de forma isolada por coluna:

$$\pi_g = \frac{1}{B_{\text{eff}}} \sum_{b=1}^{B_{\text{eff}}} \mathbb{I}(g \cap \mathcal{M}^{(b)} \neq \emptyset). \quad (7)$$

O protocolo definiu como estáveis os atributos que atingiram uma frequência de seleção igual ou superior ao limiar de corte $\tau = 0,70$, exigindo-se, adicionalmente, a ativação do atributo em pelo menos dois dos três instantes temporais avaliados. Consequentemente, sempre que um grupo alcançava essa métrica de estabilidade ($\pi_g \geq \tau$), o *pool* de seleção final incorporava **todas** as variáveis cronológicas pertencentes àquele agrupamento (T_1 , Δ_{21} e Δ_{32}).

CONTINUAR DAQUI

3.9. Fusão multimodal e preditores clínicos

Fusão tardia (*late fusion*). A estratégia multimodal adotada não realizou a concatenação de atributos de famílias distintas para alimentar um único classificador (*early fusion*). Na representação longitudinal (Q4), essa abordagem de concatenação precoce produziria centenas de colunas frente a um número reduzido de amostras (agravando o problema de alta dimensionalidade, $p \gg n$), além de misturar escalas heterogêneas (frações volumétricas, matrizes GLCM, momentos do campo de deslocamento) em um único processo de seleção ℓ_1 [Kittler et al. \(1998\)](#); [Kuncheva \(2004\)](#).

Em vez disso, implementou-se a fusão tardia (*late fusion*) baseada na média de escores. Cada família (volume, forma, textura GLCM, primeira ordem e deslocamento) treinou a sua própria Máquina de Vetores de Suporte (SVM) isoladamente sob o protocolo unimodal estabelecido. Posteriormente, as probabilidades geradas fora da partição de treino (*out-of-fold* – OOF) de cada paciente

foram combinadas *a posteriori* Kittler et al. (1998); Dietterich (2000). Dessa forma, a dimensionalidade efetiva cresce em função do número de modelos, e não pela união do espaço de atributos, garantindo que as predições morfológicas não sofram interferências espúrias de componentes de alta dimensão, como os de textura.

Mecanismo de agregação e métricas. A fusão tardia **não** empregou o treinamento de um metaclassificador (*stacking*) Wolpert (1992). Em vez disso, reutilizou as probabilidades OOF das cinco SVMs unimodais, já ajustadas sob o mesmo esquema de validação cruzada aninhada (assegurando o pareamento exato das sementes e divisões dos dados). Para um dado paciente i , em uma repetição r e partição (*fold*) f , os registros foram alinhados pelo identificador e calculou-se a média aritmética simples das predições:

$$s_{i,r,f}^{\text{late}} = \frac{1}{5} \sum_{k=1}^5 s_{i,r,f}^{(k)}, \quad (8)$$

onde k indexa cada modelo familiar. Foram adotados pesos estritamente uniformes para todas as modalidades. A AUC consolidada ao nível do paciente foi computada sobre esse conjunto final de probabilidades médias $\{s_{i,r,f}^{\text{late}}\}$. Para as métricas dependentes de um ponto de operação, o limiar de decisão binário (τ^*) foi herdado do primeiro ramo do conjunto, não havendo reestimação do Índice de Youden sobre o escore médio.

Especificações arquiteturais. Três composições multimodais foram pré-especificadas para o contraste:

- **Baseline puro (t1_only):** As cinco famílias avaliadas utilizando exclusivamente os dados da visita inicial (t_0).
- **Longitudinal puro (Q4):** As cinco famílias avaliadas sob a representação longitudinal completa (t1_d21_d32).
- **Âncora mista:** A família de forma geométrica restrita à representação de *baseline* (t1_only), combinada às demais quatro famílias (volume, textura, deslocamento e primeira ordem) na representação longitudinal Q4.

Todas as especificações foram processadas sistematicamente nas quatro coortes do estudo.

Preditores clínicos e análises adicionais. Preditores clínicos coletados no momento basal (t_0) — restritos a sexo, idade, MMSE, ADAS e FAQ — foram analisados como controle suplementar. Para avaliar a integração clínico-radiológica, adotou-se a fusão precoce entre estes cinco escores padronizados (escore Z) e a família de forma no *baseline* (**t1_only**), submetendo o vetor resultante a uma única SVM. Adicionalmente, para fins de estudo de sensibilidade, um protocolo de modelagem contendo vazamento de informação (*leaky*), onde a padronização e o *pool* de seleção **l1_stable** foram derivados do conjunto de dados completo antes da validação cruzada, é reportado em apêndice.

3.10. Testes estatísticos

Todos os contrastes de AUC usam os scores agregados por paciente, não as AUCs de dobra.

- Permutação de rótulos com scores congelados ($B_{\text{perm}} = 5000$): $p = (r + 1)/(B + 1)$; o pipeline nested **não** se reexecuta.
- Bootstrap pareado do ΔAUC ($B_{\text{boot}} = 5000$), IC percentílico a 95%, p unilateral ($H_1: \text{AUC}_A > \text{AUC}_B$) e bilateral quando aplicável.
- FDR de Benjamini–Hochberg sobre os p unilaterais das cinco famílias, no claim **48m_12m** (e, exploratoriamente, dentro de cada coorte do gradiente).
- Demografia em **48m_12m**: Mann–Whitney na idade, χ^2 no sexo; classificadores univariados de idade e de sexo com permutação; ΔAUC shape- i_0 vs demografia por bootstrap pareado.

$\alpha = 0.05$. Contraste temporal principal: Q4 versus **t1_only** nas cinco famílias em **48m_12m**.

4. Resultados

Apresentação: **uma matriz para as quatro células**, não quatro relatos paralelos. Protocolo fixo SVM + `t1_stable`, sem ComBat. Métrica: AUC paciente $\widehat{AUC}_{agg}$; $\pm$ é SD bootstrap ($B = 2000$) salvo indicação. $\Delta = AUC(Q4) - AUC(t1_only)$, com $Q4 = t1_d21_d32$. Claim e nomes de atributos: `48m_12m` ($n = 120$; 72 sMCI / 48 pMCI); o fatorial testa se o padrão se replica nas células sobrepostas. Figuras de heatmap/ROC do claim e CN $\times$ AD referem-se a esta coorte.

4.1. Demografia

Em `48m_12m`, idade e sexo não diferem entre sMCI e pMCI (Mann–Whitney $p = 0.520$; χ^2 $p = 0.371$). Classificador só com idade: AUC 0.518 ($p_{perm} = 0.376$); só com sexo: 0.512 ($p_{perm} = 0.407$). Shape em `t1_only` atinge 0.759 e supera demografia (Δ vs idade +0.241 [0.124, 0.357]; vs sexo +0.247 [0.114, 0.377]).

4.2. Uniclasse no claim: paisagem e teto shape

A Figura ?? resume AUC paciente por família e classificador em `t1_only` e em `Q4`. Em ambos os encodings, **shape** domina; volume sobe com `Q4`; texture/disp permanecem fracos. A Figura ?? mostra as curvas ROC do teto unimodal (shape) em i_0 e em `Q4` — curvas quase sobrepostas (0.759 vs 0.761). A Figura 7 isola o contraste SVM T1 vs `Q4` nas cinco famílias no claim: o Δ material está em volume (+0.089), não em shape.

Inferência no claim (7_stats).. Contraste pareado `Q4` vs i_0 , bootstrap $B = 5000$, H1 one-sided, FDR BH nas cinco famílias. Volume: $\Delta = +0.089$ [0.008, 0.171], $p = 0.016$, $q = 0.082$ (raw+, **não** FDR a $\alpha = 0.05$). Shape, texture, disp e first-order: sem evidência formal ($q \geq 0.26$). Nenhuma família fecha o claim longitudinal sob FDR.




Figura 3: Baseline




Figura 4: Longitudinal




Figura 5: Shape, baseline 48m 12m




Figura 6: Shape, longitudinal 48m 12m




Figura 7: Claim 48m_12m: AUC paciente SVM, T1 vs Q4, cinco famílias (barras de erro: SD bootstrap, $B = 2000$).

4.3. Uniclasse: Q4 versus $t1_only$ nas quatro coortes

A Tabela 5 e a Figura 8 estendem o contraste ao fatorial (células sobrepostas; não são réplicas).




Figura 8: Sensibilidade: T1 vs Q4 por família nas quatro coortes (SVM). Barras de erro: SD bootstrap do AUC paciente.

Leitura da matriz..

- **Forma:** teto unimodal em todas as células ($|\Delta| \leq 0.027$). Em 48m_12m $\text{shape-}i_0 \approx \text{shape-Q4}$ (0.759 vs 0.761).
- **Volume:** Δ pequeno nas células de 6 meses; o salto ocorre no claim ($0.641 \rightarrow 0.729$, $\Delta = +0.089$).

Tabela 5: AUC no paciente, SVM. Em cada célula: **t1_only** / Q4 / Δ . Negrito: maior das duas representações naquela família $\times$ coorte. *n*: 231, 154, 193, 120.

Família	36m_6m			36m_12m			48m_6m			48m_12m		
	baseline	Q4	Δ	baseline	Q4	Δ	baseline	Q4	Δ	baseline	Q4	Δ
vol	0.766 ± 0.031	0.770 ± 0.030	+0.005	0.690 ± 0.053	0.684 ± 0.057	-0.006	0.756 ± 0.037	0.763 ± 0.036	+0.007	0.641 ± 0.051	0.729 ± 0.047	+0.089
shape	0.791 ± 0.030	0.788 ± 0.030	-0.003	0.760 ± 0.043	0.733 ± 0.047	-0.027	0.801 ± 0.035	0.791 ± 0.036	-0.010	0.759 ± 0.043	0.761 ± 0.043	+0.002
texture	0.619 ± 0.038	0.689 ± 0.035	+0.071	0.500 ± 0.067	0.516 ± 0.062	+0.016	0.628 ± 0.042	0.674 ± 0.039	+0.047	0.529 ± 0.056	0.577 ± 0.053	+0.048
firstorder	0.654 ± 0.036	0.670 ± 0.035	+0.016	0.598 ± 0.067	0.573 ± 0.063	-0.025	0.687 ± 0.040	0.686 ± 0.040	-0.000	0.686 ± 0.056	0.703 ± 0.054	+0.017
disp	0.504 ± 0.039	0.453 ± 0.039	-0.051	0.479 ± 0.061	0.449 ± 0.061	-0.030	0.592 ± 0.042	0.575 ± 0.042	-0.017	0.321 ± 0.051	0.404 ± 0.053	+0.083

- **Textura / first-order:** Δ frequentemente positivo, mas AUC absoluta permanece abaixo do teto shape (textura no claim: $0.53 \rightarrow 0.58$).
- **Deslocamento:** fraco (no claim $AUC \leq 0.40$). Δ positivo em 48m_12m não se interpreta como biomarcador competitivo.
- **Inversão:** 36m_12m (pMCI $n = 33$) favorece i_0 em 4/5 famílias.

4.4. Multimodal: fusão tardia

Três specs: late i_0 (cinco famílias em **t1_only**), late Q4 (cinco em Q4), âncora (shape@ $i_0 \cup$ restante em Q4). Teto unimodal = máximo da Tabela 5. A Figura 9 situa as três specs face ao teto shape- i_0 no claim.




Figura 9: Fusão tardia vs teto unimodal (shape T1) e vs união late T1, 48m_12m. Barras de erro: SD bootstrap.

Coorte	Teto uni.	Late i_0	Late Q4	Âncora
36m_6m	0.791	0.795	0.806	0.811
36m_12m	0.760	0.716	0.694	0.714
48m_6m	0.801	0.822	0.820	0.828
48m_12m	0.761	0.740 ± 0.046	0.765 ± 0.044	0.767 ± 0.044

Tabela 6: AUC paciente da fusão tardia versus teto unimodal. No claim, $\pm$ é SD bootstrap ($B = 2000$); nas restantes células reporta-se só o ponto paciente.

No claim, late i_0 **fica abaixo** do teto shape; late Q4 / âncora sobem $\sim 0.005 - 0.008$ em ponto, sem superioridade formal vs shape- i_0 (Δ âncora $+0.008 [-0.055, 0.069]$, $p = 0.40$, $q = 0.67$). Nas células de maior n (36m_6m, 48m_6m) a âncora supera o teto unimodal em ponto; em 36m_12m a late dilui.

Ao contrário do raciocínio biológico intuitivo — o qual postula que intervalos maiores (12 meses) acumulariam alterações anatômicas mais acentuadas e, conseqüentemente, aumentariam a capacidade discriminativa do modelo — as coortes baseadas em intervalos de 6 meses demonstraram superioridade na separação entre as classes sMCI e pMCI.

A principal hipótese para justificar esse achado reside na interação entre o rigor do critério de inclusão temporal e a taxa de progressão da doença. Ao exigir um espaçamento de 12 meses entre as três aquisições necessárias, pacientes caracterizados como "conversores rápidos" são sistematicamente excluídos do grupo pMCI, uma vez que suas trajetórias clínicas frequentemente atingem o desfecho de Alzheimer pleno antes da terceira visita (configurando um padrão de exclusão MCI $\rightarrow$ AD $\rightarrow$ AD).

Em contrapartida, a adoção de intervalos de 6 meses fornece uma janela de amostragem com granularidade suficiente para capturar as avaliações intermediárias desses pacientes de progressão acelerada (e.g., retendo o padrão MCI $\rightarrow$ MCI $\rightarrow$ AD). Como consequência, as coortes de 12 meses sofrem um viés de seleção que retém predominantemente conversores lentos (cujas taxas de atrofia são sutis e confundem-se com o envelhecimento natural), enquanto as coortes de 6 meses são enriquecidas com sujeitos que apresentam os deltas morfológicos mais agressivos e discriminativos.

4.5. *Quantos atributos (claim)*

Médias de colunas após 11_stable em 48m_12m (50 avaliações, SVM). Antes da seleção, o encoding longitudinal Q4 tem **três vezes** o número de atributos do baseline: a sequência usa os níveis nas três imagens i_1, i_2, i_3 (T1, D21, D32), pelo que cada descritor anatômico entra uma vez por instante.

Classe	Modalidade	Antes da seleção		Média pós-seleção	
		baseline	longitudinal	baseline	longitudinal
vol	baseline / longitudinal	8	24	1.72	5.58
shape	baseline / longitudinal	24	72	1.42	4.84
texture	baseline / longitudinal	48	144	5.62	13.88
firstorder	baseline / longitudinal	32	96	1.56	6.08
disp	baseline / longitudinal	30	90	16.36	25.20

Tabela 7: Atributos antes e depois de `l1_stable`, `48m_12m` (SVM). Colunas “antes”: dimensão da matriz à entrada do seletor (L+R). Colunas “média pós”: média nas 50 avaliações externas. Disp mantém pools largos; shape/vol/firstorder ficam curtos.

4.6. Clínico, sanidade e literatura

Em `48m_12m`: clínico (sexo, idade, MMSE, ADAS, FAQ) 0.812; clínico+shape `t1_only` 0.846 (Δ vs shape $i_0 + 0.087$ [0.022, 0.157], $q = 0.017$). A RM hipocampal isolada não supera o clínico; a fusão clínica+forma sobe o ponto (controle, não claim das perguntas 1–3).

Como controle de teto de detecção (não de conversão), a Figura ?? mostra CN $\times$ AD no mesmo stack (volume Q4): AUC paciente 0.873 ± 0.027 . A tarefa fácil funciona; sMCI/pMCI permanece a difícil. Leaky (volume Q4, stats globais): 0.734 vs nested 0.729 ($\Delta \approx 0$).

Na Tabela 8, linhas próprias: teto shape i_0 0.759 ± 0.043 (sens $75.4 \pm 13.5\%$ / esp $62.6 \pm 9.6\%$); melhor unimodal Q4 = shape 0.761 ± 0.043 (**não** textura); late âncora 0.767 ± 0.044 (**não** 0.802).

Tabela 8: Comparação indicativa de desempenho prognóstico publicado em sMCI versus pMCI e dos resultados ADNI deste estudo sob validação aninhada no paciente.

Estudo	Base	Atributos	Validação	AUC	Sens / Esp (%)
Bucholz et al. (2023)	NACC	Cognitivo + funcional	3 visitas; CV retido	0.601 $\pm$ 0.054	95.4 $\pm$ 1.8 / 24.7 $\pm$ 12.0
Bucholz et al. (2023)	NACC	Cognitivo + funcional	4 visitas; CV retido	0.756 $\pm$ 0.103	92.9 $\pm$ 4.6 / 58.3 $\pm$ 19.1
Grassi et al. (2019)	ADNI	Sociodemográfico + clínico	Baseline; CV 10 folds	0.88	77.7 / 79.9
Moradi et al. (2015)	ADNI	Densidade de GM (cérebro inteiro)	Baseline; CV 10 folds	0.766	88.9 / 51.6
Moradi et al. (2015)	ADNI	GM (cérebro inteiro) + cognitivo	Baseline; CV 10 folds	0.902	86.7 / 73.6
Ye et al. (2012) [§]	ADNI	Cérebro inteiro + cognitivo	Baseline; stability selection	0.859	— / —
Casanova et al. (2013) [¶]	ADNI	Tecidos (cérebro inteiro) + cognitivo	Baseline; CV aninhada	—	45.8 / 75.5
Guo et al. (2017)	ADNI	Córtex	Baseline; LOOCV	—	85.0 / 84.8
Cuingnet et al. (2011)	ADNI	Volume hipocampal	Baseline; LOOCV	—	62.0 / 69.0
Este trabalho (teto i_0)[†]	ADNI	Forma hipocampal	i_0 ; nested CV (SVM)	0.761 $\pm$ 0.043	70.5 $\pm$ 15.4 / 63.7 $\pm$ 12.7
Este trabalho (Q4 unimodal)	ADNI	Textura GLCM (níveis T1+D21+D32)	3 visitas; nested CV	0.762 $\pm$ 0.044	68.3 $\pm$ 17.8 / 67.3 $\pm$ 15.1
Este trabalho (fusão tardia)[‡]	ADNI	Âncora / late Q4 (5 SVMs)	3 visitas; nested CV	0.802 $\pm$ 0.040	74.2 $\pm$ 18.3 / 66.8 $\pm$ 14.8
Este trabalho	ADNI	Clínico (sexo, idade, MMSE, ADAS, FAQ)	i_0 ; nested CV (SVM)	0.812 $\pm$ 0.040	70.0 $\pm$ 14.2 / 70.9 $\pm$ 14.1
Este trabalho	ADNI	Clínico + forma i_0	nested CV (SVM)	0.843 $\pm$ 0.036	77.1 $\pm$ 13.0 / 73.2 $\pm$ 13.6

Nota: Linhas próprias: corte 48m_12m ($n = 120$). [†]Teto unimodal de baseline (forma, t1_only). [‡]Fusão tardia; Sens/Esp da linha late Q4 (Youden por dobra). Antes de $\pm$ na AUC: estimando paciente; depois: SD bootstrap (2000). Sens/Esp: média $\pm$ SD nas 50 avaliações externas.




Figura 10: Heatmap CN×AD




Figura 11: Sanidade CN×AD em 48m_12m

5. Discussão

Os experimentos conduzidos avaliaram o desempenho prognóstico para a classificação de sMCI versus pMCI sob duas óticas principais: modelos unimodais (avaliando cada família de atributos isoladamente) e modelos multimodais via fusão tardia (*late fusion*). Em ambos os cenários, o poder discriminatório da visita inicial (*baseline*) foi sistematicamente contrastado com a representação longitudinal proposta.

Desempenho Unimodal: O Teto do Baseline e o Papel Modulador da Longitudinalidade

Na análise isolada das famílias de características, a morfometria geométrica da visita inicial (*shape* no *baseline*) estabeleceu o limite de desempenho absoluto (teto unimodal) em três das quatro coortes do estudo (36m_6m, 36m_12m e 48m_6m), com a AUC variando entre 0,759 e 0,801. A representação longitudinal correspondente desta mesma família não conseguiu superar esse teto, corroborando a hipótese de que a assinatura anatômica estrutural já se encontra substancialmente definida no momento do diagnóstico inicial.

Em contrapartida, a incorporação da dinâmica temporal demonstrou agregar valor discriminatório consistente nas famílias focadas em intensidade e proporção. Em todas as quatro coortes, o volume longitudinal superou o desempenho do volume no *baseline*. A textura e as estatísticas de primeira ordem (FO) também apresentaram ganhos através da representação longitudinal em relação aos seus correspondentes basais. Por outro lado, a modelagem baseada no campo de deslocamento normativo (DVF) operou sistematicamente com desempenhos próximos ao acaso (AUC em torno de 0,45 a 0,50) em ambas as representações temporais, indicando que a formulação atual dessa métrica não captura o sinal necessário para a discriminação prognóstica imposta pelo desenho.

Desempenho Multimodal: Superação do Teto via Fusão Tardia Parcimoniosa

A transição para a abordagem multiclasse confirmou a utilidade da longitudinalidade como complemento, e não como substituto, ao *baseline*. O uso da

arquitetura em "âncora— que congela a geometria no *baseline* e a une com atributos de outras famílias na representação longitudinal — foi capaz de superar o teto unimodal em quase todos os cenários.

Para a escolha da melhor combinação em cada coorte, aplicou-se o princípio da parcimônia. Modelos de fusão tardia com um número médio de atributos retidos substancialmente menor no rastreo L1 foram favorecidos, visto que a redução da dimensionalidade atenua o risco de sobreajuste (*overfitting*) e eleva o potencial de generalização do classificador.

- **Coorte 36m_6m:** Enquanto o teto unimodal da forma atingiu 0,791, múltiplas combinações multimodais superaram a marca de 0,81. O desempenho absoluto máximo (0,818) foi obtido pela união longitudinal da triade forma, volume e textura (`late__t1_d21d32_vol__t1_d21d32_shape__t1_d21d32_texture`), utilizando em média 21,6 atributos. Contudo, guiando-se pela parcimônia, a especificação em âncora unindo a forma no *baseline* e o volume longitudinal (`late__t1_shape__t1_d21d32_vol`) atingiu uma excelente AUC de 0,809 com o custo de apenas 9,4 atributos selecionados em média, configurando-se como uma das alternativas mais eficientes.
- **Coorte 36m_12m:** Este foi o cenário de maior desafio devido ao espaçamento das aquisições e ao extremo desbalanceamento das classes (apenas 33 pMCI). A forma no *baseline* manteve o seu teto invicto (0,760). A melhor formulação de fusão — novamente unindo forma no *baseline* e volume longitudinal — alcançou 0,757, falhando em transpor o limite estático. Isso sugere que, com janelas de *follow-up* dilatadas e sob baixa incidência de conversões ativas, a agregação temporal pode diluir o sinal preditivo em vez de fortalecê-lo.
- **Coorte 48m_6m:** Com o teto unimodal fixado em 0,801, a fusão tardia retomou a sua eficácia. A combinação mais complexa (âncora com forma no *baseline* aliada a volume, textura, deslocamento e primeira ordem longitudinais) atingiu o pico de 0,828, requerendo a média de 28,4 atributos.

Reafirmando o padrão parcimonioso, a simples união entre a forma no *baseline* e o volume longitudinal (`late__t1_shape__t1_d21d32_vol`) alcançou robustos 0,821 utilizando apenas 11,3 atributos, confirmando que o núcleo da informação temporal útil se concentra nas variações das frações volumétricas.

- **Coorte 48m_12m:** Nesta coorte, observou-se uma equalização na família geométrica, onde a forma longitudinal (0,761) e a do *baseline* (0,759) praticamente empataram. A abordagem multimodal conseguiu superar a marca, com a união âncora envolvendo volume, textura e primeira ordem (`late__t1_shape__t1_d21d32_vol__t1_d21d32_texture__t1_d21d32_firstorder`) atingindo a AUC máxima de 0,778 ao custo de cerca de 27,0 atributos. A alternativa de baixa dimensionalidade ancorada unicamente na forma e no volume longitudinal também exibiu um desempenho competitivo (0,770), mobilizando em média apenas 7,0 características.

Em síntese, os resultados ratificam que a morfometria em estado estacionário no momento do diagnóstico inicial encerra o maior e mais resistente fator de predição isolado. Entretanto, a orquestração multimodal evidencia que a trajetória volumétrica (e em menor grau a de textura) fornece sinais complementares inestimáveis. A arquitetura de fusão ancorada estritamente na forma basal (*baseline*) suplementada pela variação longitudinal das frações volumétricas revelou-se a estratégia ideal por combinar alta acurácia discriminatória e drástica redução da dimensionalidade paramétrica.

A pergunta era se níveis longitudinais hipocampais agregam discriminação sMCI/pMCI além do i_0 .

Uniclasse agrega em papéis fracos; não passa o teto.. No claim, Q4 sobe volume de forma nominal ($\Delta = +0.089$, sem FDR). Shape já satura no i_0 ; Q4 é redundante. Textura e first-order sobem em ponto mas permanecem abaixo do teto shape. Nenhuma família Q4 substitui shape- i_0 .

União tardia não coroa o claim.. Late Q4 / âncora empatam ou sobem marginalmente o teto em 48m_12m, sem evidência bootstrap formal. Late- i_0 dilui (abaixo do teto). O ganho “late > teto” aparece em células de maior n , não no claim pré-especificado.

6. Conclusões

Sob uma validação aninhada rigorosa ao nível do paciente (classificador SVM conjugado à seleção `l1_stable`), a morfologia hipocampal no momento do diagnóstico inicial (*shape* em t_0) consolidou-se como o teto de desempenho unimodal nas quatro coortes do delineamento prognóstico sMCI/pMCI. A codificação longitudinal proposta (Q4) demonstrou utilidade preditiva ao agregar capacidade discriminatória em famílias de atributos inicialmente mais fracas, com destaque para a volumetria e, em menor grau, para a textura e estatísticas de primeira ordem. Em contrapartida, os momentos do campo de deslocamento normativo (DVF) operaram próximos ao acaso, não justificando a sua manutenção neste modelo de suporte à decisão. Na coorte principal (48m_12m, $n = 120$), o ganho longitudinal mais expressivo ocorreu na família de volume ($\Delta\text{AUC} \approx +0,09$), contudo, sem atingir significância estatística após correção para comparações múltiplas.

A arquitetura multimodal via fusão tardia (*late fusion*) demonstrou ser o mecanismo adequado para a integração destas informações. Configurações pré-especificadas (como a fusão “âncora”, que preserva a forma no *baseline* e incorpora as demais famílias longitudinalmente) superaram o teto estático em coortes com acompanhamento mais denso (intervalos de 6 meses). Na coorte principal, contudo, a fusão tardia obteve estimativas pontuais de até 0,778 (em análises exploratórias), mas não estabeleceu superioridade estatística formal sobre o teto unimodal da forma isolada (0,761). Notavelmente, uniões altamente parcimoniosas (ex.: forma no *baseline* conjugada ao volume longitudinal) provaram ser capazes de capturar a quase totalidade do ganho multimodal utilizando um subespaço vetorial mínimo. Paralelamente, escores clínicos basais confirmaram a

sua força preditiva; neste contexto, a ressonância magnética hipocampal atua como um adjunto estrutural complementar, e não como um substituto absoluto da avaliação neuropsicológica.

O principal contributo deste trabalho reside na orquestração de um protocolo metodológico auditável e rigoroso — abrangendo avaliação fatorial, validação aninhada por paciente, controle de fugas de informação e integração multimodal —, fornecendo a evidência de que a longitudinalidade socorre preditores fracos, enquanto a forma geométrica basal ancora firmemente o limite de desempenho.

Limitações.. O estudo apresenta limitações que devem ser consideradas na interpretação dos achados: (i) A dependência exclusiva da base de dados ADNI e a exigência de casos completos (pacientes com três aquisições de RM perfeitamente espaçadas e rótulo de desfecho validado) restringiram o tamanho amostral ($n = 120$ na coorte principal) e limitam a generalização externa. (ii) As quatro coortes avaliadas possuem sobreposição topológica de sujeitos, e variações como a de 36m_12m sofreram com o desbalanceamento acentuado de classes (apenas 33 casos pMCI). (iii) A definição operacional do desfecho admitiu uma tolerância para pMCI em que a última imagem coincidia com o diagnóstico inicial de Alzheimer (inclusão ampliada), e baseou-se em janelas temporais fixas em vez de modelar o tempo até a progressão de forma contínua. (iv) A representação Q4 fundamenta-se na concatenação de níveis discretos e diferenças absolutas, não incorporando a modelagem de trajetórias contínuas ou de deformações diretas visita a visita. (v) O escopo espacial restringiu-se propositalmente ao hipocampo bilateral; embora seja o marcador canônico da doença, representa uma visão anatômica incompleta frente à rede global de atrofia envolvida na conversão para a demência. (vi) Processos de controle de qualidade e a geração de *templates* normativos foram executados globalmente antes da validação cruzada. (vii) As configurações multimodais com os melhores desempenhos absolutos resultaram de observações *a posteriori* (*post-hoc*) em meio a dezenas de combinações testadas, servindo como exploração de limites e não como desfechos primários pré-registrados.

Trabalhos Futuros.. Como desdobramento natural desta investigação, o próximo passo consiste em **expandir o escopo espacial** das Regiões de Interesse (ROIs). Propõe-se a aplicação deste mesmo arcabouço metodológico rigoroso a estruturas parceladas em todo o cérebro (por exemplo, amígdala, tálamo, cíngulo, córtex orbitofrontal e ínsula, através do atlas DKT), a fim de testar se a avaliação longitudinal de redes límbico-corticais estendidas consegue agregar o poder preditivo que o hipocampo isolado não foi capaz de formalizar estatisticamente. Complementarmente, desenvolvimentos futuros devem focar na validação do modelo em coortes externas independentes, na integração parcimoniosa dos dados de imagem com marcadores clínicos sob a mesma validação aninhada, e na transição para uma modelagem temporal contínua (utilizando *splines* ou taxas de atrofia) em substituição a recortes de tempo discretos.

Agradecimentos

A recolha e a partilha dos dados foram financiadas pela Alzheimer’s Disease Neuroimaging Initiative (ADNI).

Financiamento

O presente trabalho foi realizado com apoio da Coordenação de Aperfeiçoamento de Pessoal de Nível Superior – Brasil (CAPES) – Código de Financiamento 001.

Conflito de interesses

Os autores declaram não haver conflito de interesses.

Referências

Aghajanian, S., Mohammadifard, F. et al., 2025. Longitudinal structural MRI-based deep learning and radiomics features for predicting Alzheimer’s disease progression. *Alzheimer’s Research & Therapy* 17, 1–13. doi:[10.1186/s13195-025-01827-2](https://doi.org/10.1186/s13195-025-01827-2).

- Akiba, T., Sano, S. et al., 2019. Optuna: A Next-generation Hyperparameter Optimization Framework, in: The 25th ACM SIGKDD Conference on Knowledge Discovery and Data Mining (KDD '19), New York, NY, USA. pp. 2623–2631. doi:[10.1145/3292500.3330701](https://doi.org/10.1145/3292500.3330701).
- Avants, B.B., Tustison, N.J. et al., 2011. A reproducible evaluation of ANTs similarity metric performance in brain image registration. *NeuroImage* 54, 2033–2044. doi:[10.1016/j.neuroimage.2010.09.025](https://doi.org/10.1016/j.neuroimage.2010.09.025).
- Avants, B.B., Tustison, N.J. et al., 2014. The Insight ToolKit image registration framework. *Frontiers in Neuroinformatics* 8, 1–41. doi:[10.3389/fninf.2014.00044](https://doi.org/10.3389/fninf.2014.00044).
- Bach, F.R., 2008. Bolasso: model consistent Lasso estimation through the bootstrap, in: Proceedings of the 25th International Conference on Machine Learning, New York, NY, USA. pp. 33–40. doi:[10.1145/1390156.1390161](https://doi.org/10.1145/1390156.1390161).
- Bouke, M.A., Abdullah, A., 2023. An empirical study of pattern leakage impact during data preprocessing on machine learning-based intrusion detection models reliability. *Expert Systems with Applications* 230, 120715. doi:[10.1016/j.eswa.2023.120715](https://doi.org/10.1016/j.eswa.2023.120715).
- Breiman, L., 2001. Random Forests. *Machine Learning* 45, 5–32. doi:[10.1023/A:1010933404324](https://doi.org/10.1023/A:1010933404324).
- Bucholc, M., Titarenko, S. et al., 2023. A hybrid machine learning approach for prediction of conversion from mild cognitive impairment to dementia. *Expert Systems with Applications* 217, 119541. doi:[10.1016/j.eswa.2023.119541](https://doi.org/10.1016/j.eswa.2023.119541).
- Casanova, R., Hsu, F.C. et al., 2013. Alzheimer’s Disease Risk Assessment Using Large-Scale Machine Learning Methods. *PLOS ONE* 8, 1–13. doi:[10.1371/journal.pone.0077949](https://doi.org/10.1371/journal.pone.0077949).
- Cortes, C., Vapnik, V., 1995. Support-vector networks. *Machine learning* 20, 273–297. doi:[10.1007/BF00994018](https://doi.org/10.1007/BF00994018).

- Cuingnet, R., Gerardin, E. et al., 2011. Automatic classification of patients with Alzheimer’s disease from structural MRI: A comparison of ten methods using the ADNI database. *NeuroImage* 56, 766–781. doi:[10.1016/j.neuroimage.2010.06.013](https://doi.org/10.1016/j.neuroimage.2010.06.013).
- Dietterich, T.G., 2000. Ensemble methods in machine learning, in: International workshop on multiple classifier systems, Berlin, Heidelberg. pp. 1–15.
- Ellis, K.A., Bush, A.I. et al., 2009. The Australian Imaging, Biomarkers and Lifestyle (AIBL) study of aging: methodology and baseline characteristics of 1112 individuals recruited for a longitudinal study of Alzheimer’s disease. *International Psychogeriatrics* 21, 672–687. doi:[10.1017/S1041610209009405](https://doi.org/10.1017/S1041610209009405).
- Fonov, V., Evans, A.C. et al., 2011. Unbiased average age-appropriate atlases for pediatric studies. *NeuroImage* 54, 313–327. doi:[10.1016/j.neuroimage.2010.07.033](https://doi.org/10.1016/j.neuroimage.2010.07.033).
- Grassi, M., Rouleaux, N. et al., 2019. A Novel Ensemble-Based Machine Learning Algorithm to Predict the Conversion From Mild Cognitive Impairment to Alzheimer’s Disease Using Socio-Demographic Characteristics, Clinical Information, and Neuropsychological Measures. *Frontiers in Neurology* 10, 1–15. doi:[10.3389/fneur.2019.00756](https://doi.org/10.3389/fneur.2019.00756).
- van Griethuysen, J., Fedorov, A. et al., 2017. Computational Radiomics System to Decode the Radiographic Phenotype. *Cancer Research* 77, e104–e107. doi:[10.1158/0008-5472.CAN-17-0339](https://doi.org/10.1158/0008-5472.CAN-17-0339).
- Guo, S., Lai, C. et al., 2017. Conversion Discriminative Analysis on Mild Cognitive Impairment Using Multiple Cortical Features from MR Images. *Frontiers in Aging Neuroscience* 9, 1–14. doi:[10.3389/fnagi.2017.00146](https://doi.org/10.3389/fnagi.2017.00146).
- Jack Jr., C.R., Bernstein, M.A. et al., 2008. The Alzheimer’s disease neuroimaging initiative (ADNI): MRI methods. *Journal of Magnetic Resonance Imaging* 27, 685–691. doi:[10.1002/jmri.21049](https://doi.org/10.1002/jmri.21049).

- Kittler, J., Hatef, M. et al., 1998. On Combining Classifiers. *IEEE Transactions on Pattern Analysis and Machine Intelligence* 20, 226–239. doi:[10.1109/34.667881](#).
- Kuncheva, L.I., 2004. *Combining Pattern Classifiers: Methods and Algorithms*. USA. Wiley-Interscience.
- LaMontagne, P.J., Benzinger, T.L. et al., 2019. OASIS-3: longitudinal neuroimaging, clinical, and cognitive dataset for normal aging and Alzheimer disease. 10.1101/2019.12.13.19014902.
- Lin, Y., Huang, K. et al., 2020. Predicting the progression of mild cognitive impairment to Alzheimer’s disease by longitudinal magnetic resonance imaging-based dictionary learning. *Clinical Neurophysiology* 131, 2429–2439. doi:[10.1016/j.clinph.2020.07.016](#).
- Manjón, J.V., Coupé, P. et al., 2010. Adaptive non-local means denoising of MR images with spatially varying noise levels. *Journal of Magnetic Resonance imaging* 31, 192–203. doi:[10.1002/jmri.22003](#).
- Meinshausen, N., Bühlmann, P., 2010. Stability selection. *Journal of the Royal Statistical Society Series B: Statistical Methodology* 72, 417–473. doi:[10.1111/j.1467-9868.2010.00740.x](#).
- Molina, D., Pérez-Beteta, J. et al., 2016. Influence of gray level and space discretization on brain tumor heterogeneity measures obtained from magnetic resonance images. *Computers in Biology and Medicine* 78, 49–57. doi:[10.1016/j.combiomed.2016.09.011](#).
- Moradi, E., Pepe, A. et al., 2015. Machine learning framework for early MRI-based Alzheimer’s conversion prediction in MCI subjects. *NeuroImage* 104, 398–412. doi:[10.1016/j.neuroimage.2014.10.002](#).
- Nyul, L., Udupa, J., Zhang, X., 2000. New variants of a method of MRI scale standardization. *IEEE Transactions on Medical Imaging* 19, 143–150. doi:[10.1109/42.836373](#).

- Petersen, R.C., Aisen, P. et al., 2009. Alzheimer’s Disease Neuroimaging Initiative (ADNI). *Neurology* 74, 201–209. doi:[10.1212/wnl.0b013e3181cb3e25](https://doi.org/10.1212/wnl.0b013e3181cb3e25).
- Petersen, R.C., Smith, G.E. et al., 1999. Mild cognitive impairment: clinical characterization and outcome. *Archives of neurology* 56, 303–308. doi:[10.1001/archneur.56.3.303](https://doi.org/10.1001/archneur.56.3.303).
- Reuter, M., Schmansky, N.J. et al., 2012. Within-subject template estimation for unbiased longitudinal image analysis. *NeuroImage* 61, 1402–1418. doi:[10.1016/j.neuroimage.2012.02.084](https://doi.org/10.1016/j.neuroimage.2012.02.084).
- Sadri, A.R., Janowczyk, A. et al., 2020. Technical Note: MRQy — An open-source tool for quality control of MR imaging data. *Medical Physics* 47, 6029–6038. doi:[10.1002/mp.14593](https://doi.org/10.1002/mp.14593).
- Scheltens, P., Leys, D. et al., 1992. Atrophy of medial temporal lobes on MRI in “probable” Alzheimer’s disease and normal ageing: diagnostic value and neuropsychological correlates. *Journal of Neurology, Neurosurgery, and Psychiatry* 55, 967–972. doi:[10.1136/jnnp.55.10.967](https://doi.org/10.1136/jnnp.55.10.967).
- Tukey, J., 1977. *Exploratory Data Analysis*. Addison-Wesley, Reading, MA.
- Tustison, N.J., Avants, B.B. et al., 2010. N4ITK: Improved N3 Bias Correction. *IEEE Transactions on Medical Imaging* 29, 1310–1320. doi:[10.1109/TMI.2010.2046908](https://doi.org/10.1109/TMI.2010.2046908).
- Tustison, N.J., Cook, P.A. et al., 2021. The ANTsX ecosystem for quantitative biological and medical imaging. *Scientific Reports* 11, 1–13. doi:[10.1038/s41598-021-87564-6](https://doi.org/10.1038/s41598-021-87564-6).
- Wolpert, D.H., 1992. Stacked generalization. *Neural Networks* 5, 241–259. doi:[10.1016/S0893-6080\(05\)80023-1](https://doi.org/10.1016/S0893-6080(05)80023-1).
- Wyman, B.T., Harveyb, D.J. et al., 2013. Standardization of analysis sets for reporting results from ADNI MRI data. *Alzheimer’s & Dementia* 9, 332–337. doi:[10.1016/j.jalz.2012.06.004](https://doi.org/10.1016/j.jalz.2012.06.004).

- Ye, J., Farnum, M. et al., 2012. Sparse learning and stability selection for predicting MCI to AD conversion using baseline ADNI data. *BMC Neurology* 12, 1–46. doi:[10.1186/1471-2377-12-46](https://doi.org/10.1186/1471-2377-12-46).
- Yushkevich, P.A., Piven, J. et al., 2006. User-Guided 3D Active Contour Segmentation of Anatomical Structures: Significantly Improved Efficiency and Reliability. *Neuroimage* 31, 1116–1128. doi:[10.1016/j.neuroimage.2006.01.015](https://doi.org/10.1016/j.neuroimage.2006.01.015).
- Zhang, Y., Liu, S., Yu, X., 2019. Longitudinal structural MRI analysis and classification in Alzheimer’s disease and mild cognitive impairment. *International Journal of Imaging Systems and Technology* 30, 421–433. doi:[10.1002/ima.22390](https://doi.org/10.1002/ima.22390).
- Zou, H., Hastie, T., 2005. Regularization and Variable Selection Via the Elastic Net. *Journal of the Royal Statistical Society Series B: Statistical Methodology* 67, 301–320. doi:[10.1111/j.1467-9868.2005.00503.x](https://doi.org/10.1111/j.1467-9868.2005.00503.x).
- Zwanenburg, A., Vallières, M. et al., 2020. The Image Biomarker Standardization Initiative: Standardized Quantitative Radiomics for High-Throughput Image-based Phenotyping. *Radiology* 295, 328–338. doi:[10.1148/radiol.2020191145](https://doi.org/10.1148/radiol.2020191145).