

Análise longitudinal de diferentes classes de atributos hipocampais para a classificação entre comprometimento cognitivo leve progressivo e estável

Paulo Matheus da Costa Girardi^a, Ricardo José Ferrari^{a,*}, for the Alzheimer’s Disease Neuroimaging Initiative^{**}

^a*Department of Computing, Federal University of São Carlos, Rod. Washington Luis, Km 235, 13565-905, São Carlos, SP, Brazil*

Abstract

Distinguir sMCI de pMCI no hipocampo com RM T1 isolada é difícil: o sinal é sutil e a literatura mistura janelas, ROIs e validação. Neste estudo (ADNI-1/2/GO) pergunta-se se a representação longitudinal **t1_d21_d32** (Q4: níveis T1, D21 e D32 — os mesmos descritores em T_1, T_2, T_3 , **não** diferenças $T_b - T_a$) agrega discriminação relativamente ao baseline **t1_only**. O contraste corre em cinco famílias (volume, forma, textura GLCM Original, primeira ordem, deslocamento normativo) e em quatro coortes (janelas 36/48 meses $\times$ intervalos nominais 6/12 meses, tolerância ± 2). Protocolo fixo: SVM, pool L1 por frequência (**11_stable**, $\tau = 70\%$, $|\rho| > 0.85$ com desempate $|\text{corr}(x, y)|$), CV aninhada no paciente (5×10); métrica primária AUC de Mann–Whitney sobre a média das probabilidades OOF por sujeito. Uniclasse: Q4 agrega volume, textura e primeira ordem; a forma em t_0 permanece o teto unimodal e Q4 **não** o ultrapassa de forma consistente. A união tardia de cinco SVMs (média de scores) — em particular a âncora $\text{forma}@t_0 \cup$ restante Q4 — supera esse teto nas quatro célu-

*Corresponding author

**Data used in preparation of this article were obtained from the Alzheimer’s Disease Neuroimaging Initiative (ADNI) database (adni.loni.usc.edu). Investigators within ADNI contributed to the design and implementation of ADNI and/or provided data but did not participate in analysis or writing of this report. A complete listing of ADNI investigators is available at http://adni.loni.usc.edu/wp-content/uploads/how_to_apply/ADNI_Acknowledgement_List.pdf.

Email addresses: paulogirardi@estudante.ufscar.br (Paulo Matheus da Costa Girardi), rferrari@ufscar.br (Ricardo José Ferrari)

las (em 48m_12m, $n = 120$: teto $\approx 0.76 \rightarrow 0.802 \pm 0.040$). Os escores clínicos de t_0 (sexo, idade, MMSE, ADAS, FAQ) atingem 0.812 ± 0.040 ; a RM hipocampal entra como adjunto estrutural.

Keywords: Longitudinal MRI, hippocampus, Mild Cognitive Impairment, Radiomics, Machine Learning, Nested cross-validation, Late fusion

1. Introdução

Introdução A Doença de Alzheimer (DA) e o Compromisso Cognitivo Ligeiro (CCL, *Mild Cognitive Impairment*, MCI) situam-se num continuum de declínio cognitivo [Petersen et al. \(1999\)](#). Identificar quais indivíduos com MCI permanecerão estáveis (sMCI) ou progredirão para demência (pMCI) é clinicamente relevante para enriquecimento de ensaios, aconselhamento e planeamento de intervenção precoce [Petersen et al. \(2009\)](#). A ressonância magnética (RM) estrutural ponderada em T1 permanece central neste problema, e a atrofia hipocampal está entre os marcadores de imagem mais consolidados de neurodegeneração [Scheltens et al. \(1992\)](#). Na fronteira sMCI/pMCI, contudo, a discriminação baseada numa única região anatômica é intrinsecamente difícil: as diferenças de grupo são subtis, a dinâmica de conversão é heterogênea e a alteração estrutural sobrepõe-se ao envelhecimento normal. Uma vasta literatura avançou, por isso, para representações mais ricas, incluindo morfometria de cérebro inteiro, fusão multimodal com scores cognitivos, radiômica e aprendizagem profunda longitudinal [Moradi et al. \(2015\)](#); [Ye et al. \(2012\)](#); [Zhang et al. \(2019\)](#); [Lin et al. \(2020\)](#); [Aghajanian et al. \(2025\)](#). Os valores reportados de área sob a curva ROC (AUC) podem ser elevados nestes contextos, mas a comparabilidade entre estudos é limitada. Coortes, definições de desfecho (p.ex. ncMCI/cMCI, MCI-para-DA num horizonte fixo), escala espacial (cérebro inteiro versus ROI regional), entrada temporal (só baseline versus visitas repetidas) e desenho de validação diferem amplamente. Além disso, muitos pipelines publicados aplicam harmonização, selecção de atributos, sintonização de hiperparâmetros ou limiares de decisão com informação do conjunto completo ou de partições de teste,

e nem todos impõem divisão estrita ao nível do paciente. Nestas condições, AUCs optimistas são difíceis de interpretar e podem não reflectir o desempenho atingível sob validação ao nível do paciente com ajuste do modelo por fold. Este estudo aborda essa lacuna com um fluxo de extremo a extremo, auditável, de extracção de atributos hipocampais e classificação prognóstica no ADNI (ADNI-1/2/GO). O hipocampo foi escolhido de propósito como a característica macroscópica de atrofia mais consolidada na investigação em DA, fornecendo um banco de ensaio focado para avaliação longitudinal, sem reivindicar cobertura prognóstica de cérebro inteiro. Partindo de volumes T1 brutos, o pipeline combina pré-processamento, controlo de qualidade, parcelamento, registo baseado em templates e extracção de atributos volumétricos, morfométricos, texturais, de primeira ordem e de campo de deslocamento no hipocampo. O desempenho prognóstico avalia-se sob validação cruzada (CV) aninhada ao nível do paciente, com filtragem por frequência de selecção ℓ_1 derivada de bootstrap confinada aos dados de treino em cada fold externo, e harmonização ComBat opcional por fold tratada como análise de sensibilidade. A novidade metodológica reside na arquitectura de avaliação, e não num novo classificador: elegibilidade temporal, apuração do desfecho, divisão ao nível do paciente, operações ajustadas por fold, selecção específica da representação, agregação de probabilidades e comparações estatísticas especificam-se como cadeia auditável. Este desenho permite avaliação *like-for-like* das representações Q4 (`t1_d21_d32`), só primeira visita (`t1_only`), preditores clínicos e fusão *late*, e identifica quais componentes aparentemente úteis permanecem informativos após controlos de fuga de informação e correcção por multiplicidade. As principais contribuições para avaliação reproduzível de aprendizagem automática em neuroimagem longitudinal são:

- um protocolo auditável que separa visitas preditoras em estágio MCI da apuração do desfecho e documenta o limite de ajuste de cada operação dependente da amostra sob validação aninhada ao nível do paciente;
- uma matriz controlada de avaliação que abrange cinco famílias de atributos hipocampais (volume, forma, textura GLCM, primeira ordem, desloca-

mento), fusão *late* (três especificações), representações Q4 versus `t1_only`, SVM como classificador primário (RF e elastic-net em sensibilidade), harmonização por fold, preditores clínicos e fusão clínica-imagem sob um estimando comum de AUC ao nível do paciente;

- uma auditoria explícita da frequência de selecção de atributos e inferência para além de estimativas pontuais, incluindo testes de permutação ao nível do paciente, intervalos de confiança bootstrap pareados e correcção da taxa de falsas descobertas;
- evidência de suporte à decisão mostrando que as variáveis clínicas devem permanecer o sinal prognóstico de primeira linha nesta coorte, enquanto a RM hipocampal deve tratar-se como adjunto estrutural cujo valor incremental tem de ser demonstrado, e não presumido.

O endpoint primário é a classificação binária sMCI versus pMCI. O restante do artigo organiza-se assim: a Secção 3 descreve a coorte, a extracção de atributos e os protocolos de validação; a Secção ?? reporta resultados prognósticos e comparativos, incluindo contextualização na literatura; a Secção ?? discute achados e limitações; a Secção ?? conclui.

A doença de Alzheimer (AD) e o comprometimento cognitivo leve (MCI) situam-se num contínuo de declínio [Petersen et al. \(1999\)](#). Identificar quais indivíduos com MCI permanecerão estáveis (sMCI) e quais progredirão para demência (pMCI) interessa a enriquecimento de ensaios, aconselhamento e planeamento de intervenção [Petersen et al. \(2009\)](#). A RM estrutural T1-ponderada permanece central nesse problema, e a atrofia hipocampal é um dos marcadores macroscópicos mais consolidados [Scheltens et al. \(1992\)](#). Na fronteira sMCI/pMCI, contudo, a discriminação a partir de uma única região é intrinsecamente difícil: as diferenças de grupo são subtis, a dinâmica de conversão é heterogénea e a alteração estrutural sobrepõe-se ao envelhecimento.

Uma literatura ampla recorreu a representações mais ricas — morfometria de cérebro inteiro, fusão com escores cognitivos, radiómica e aprendizagem profunda longitudinal [Moradi et al. \(2015\)](#); [Ye et al. \(2012\)](#); [Zhang et al. \(2019\)](#);

Lin et al. (2020); Aghajanian et al. (2025). As AUC reportadas podem ser altas, mas a comparabilidade é limitada. Coortes, definições de desfecho (p.ex. ncMCI/cMCI, conversão MCI→AD num horizonte fixo), escala espacial (cérebro inteiro versus ROI), entrada temporal (só baseline versus visitas repetidas) e desenho de validação diferem. Além disso, muitos pipelines aplicam selecção de atributos, ajuste de hiperparâmetros ou limiar de decisão com informação do conjunto completo ou das partições de teste, e nem todos impõem divisão estrita no nível do paciente. Sob essas condições, AUC otimistas são difíceis de interpretar e podem não reflectir o desempenho atingível com validação no paciente e ajuste fold-wise.

Este estudo avalia um fluxo auditável de extração de atributos hipocámpais e classificação prognóstica na ADNI (ADNI-1/2/GO). O hipocampo foi escolhido de propósito como marcador canónico de atrofia e como banco de teste longitudinal, não como cobertura prognóstica de cérebro inteiro. A cadeia documentada cobre pré-processamento T1, controlo de qualidade, parcelamento, registo a templates e extração de atributos volumétricos, morfométricos, texturais e de campo de deslocamento no hipocampo. O desempenho avalia-se com validação cruzada aninhada no paciente; o modo `l1_stable` (pool L1 por frequência; Sec. 3.12) restringe-se ao treino de cada dobra externa. O classificador canónico é um único SVM, para isolar o contraste entre representações (estática vs longitudinal vs união tardia) de vieses de algoritmo. A novidade está na arquitectura de avaliação, não num classificador novo: elegibilidade temporal, apuração do desfecho, divisão por paciente, operações ajustadas só no treino, selecção específica da representação, agregação de probabilidades e comparações com correcção de multiplicidade formam uma cadeia auditável. Esse desenho permite comparar, no mesmo estimando, `t1_d21_d32` versus `t1_only` em cada família, a união tardia de cinco SVMs, e o conjunto de atributos que `l1_stable` retém em cada dobra.

Perguntas.. No hipocampo, para sMCI versus pMCI: (1) Q4 (`t1_d21_d32`: T1, D21, D32) agrega AUC relativamente a `t1_only` dentro de cada famí-

lia? (2) quais atributos `l1_stable` retém (frequência em 50 avaliações externas), em vez de uma assinatura única? (3) a fusão tardia (três especificações pré-especificadas) supera o teto unimodal? Quantifica-se $\Delta\text{AUC} = \text{AUC}(\text{Q4}) - \text{AUC}(\text{t1_only})$ nas cinco famílias e nas quatro células do fatorial janela clínica $\times$ intervalo entre imagens.

Contribuições para avaliação reprodutível em neuroimagem longitudinal:

- protocolo que separa visitas preditoras em estágio MCI da apuração do desfecho e documenta a fronteira de ajuste de cada operação dependente da amostra sob validação aninhada no paciente;
- matriz controlada em cinco famílias hipocampais, `t1_only` versus Q4, quatro coortes e fusão tardia (sem concatenação precoce da união), sob o mesmo estimando de AUC no paciente e o mesmo SVM;
- leitura por papéis: a forma satura no t_0 ; volume, textura e primeira ordem agregam no tempo; a união tardia é o contraste que passa o teto unimodal;
- evidência de apoio à decisão: variáveis clínicas baratas permanecem competitivas nesta coorte; a RM hipocampal é adjunto estrutural cuja contribuição incremental deve ser demonstrada, não presumida.

O desfecho primário é a classificação binária sMCI versus pMCI. O restante do artigo organiza-se assim: a Secção 2 descreve coorte, extração de atributos e validação; a Secção 4 reporta os resultados prognósticos e comparativos; a Secção 5 discute achados e limitações; a Secção 7 conclui.

1.1. Trabalhos relacionados

A previsão automatizada de estabilidade ou conversão do MCI tem sido estudada com conjuntos de atributos, esquemas de validação e janelas de desfecho muito diferentes. Na investigação prognóstica baseada no ADNI, MCI estável e progressivo designam-se frequentemente ncMCI/cmCI ou MCInc/MCIc, clinicamente análogos a sMCI e pMCI, respectivamente. O desempenho depende,

portanto, não só do classificador, mas também de os preditores serem clínicos, estruturais, multimodais, regionais ou de cérebro inteiro, e de a informação temporal se limitar ao baseline ou abranger várias visitas de seguimento. Vários estudos mostram que o seguimento cognitivo denso pode ser altamente informativo mesmo sem RM. [Bucholt et al. \(2023\)](#) propuseram um enquadramento de ensemble híbrido na coorte do National Alzheimer’s Coordinating Center (NACC) para prever a conversão de MCI para demência a partir de trajectórias cognitivas e funcionais longitudinais. Embora a acurácia de classificação tenha atingido 85,0–87,5%, a AUC do ensemble no teste retido permaneceu perto de 0,60, ao passo que modelos de floresta aleatória atingiram AUC até 0,76 quando quatro visitas estavam disponíveis. [Grassi et al. \(2019\)](#) previram conversão a 3 anos no ADNI usando apenas variáveis sociodemográficas e neuropsicológicas e reportaram AUROC de 0,88 (IC bootstrap 95%: 0,85–0,91), com sensibilidade 77,7% e especificidade 79,9% no ponto de operação de melhor acurácia equilibrada. Estes resultados indicam que o rastreio clínico transporta sinal prognóstico substancial e constitui um comparador forte para modelos só de imagem. Estudos de RM estrutural apoiam-se frequentemente em representações de cérebro inteiro de alta dimensão ou em fusão com scores cognitivos. [Moradi et al. \(2015\)](#) aplicaram *low-density separation* a RM T1 de baseline do ADNI para previsão precoce de conversão em MCI, reportando AUC 0,766 com morfometria baseada em voxel isolada e AUC 0,902 quando a RM se combinou com um agregado cognitivo de baseline. [Ye et al. \(2012\)](#) usaram um enquadramento esparsos de *stability selection* (Biosignature-15) para prever conversão MCI-para-DA em quatro anos, alcançando AUC 0,859 com validação cruzada leave-one-out (LOOCV) em dados ADNI de baseline. [Casanova et al. \(2013\)](#) combinaram atributos de RM em grande escala baseados em tecido com informação cognitiva num enquadramento de aprendizagem automática para avaliação de risco no ADNI. Tais estudos demonstram que AUCs elevadas obtêm-se mais frequentemente com desenhos de cérebro inteiro ou multimodais e com definições de desfecho que podem diferir da discriminação estrita sMCI/pMCI de horizonte curto. Quando o âmbito espacial se reduz a uma única ROI, o desem-

penho tipicamente diminui. [Cuingnet et al. \(2011\)](#) compararam dez métodos de classificação no ADNI e reportaram que a discriminação conversor versus não-conversor em MCI, incluindo atributos de volume hipocampal, não excedeu significativamente o acaso. [Guo et al. \(2017\)](#) estudaram atributos de espessura cortical relacionados com conversão para discriminação sMCI versus cMCI, reportando 98,84% de acurácia com sensibilidade/especificidade de 97,5/100 sob LOOCV, mas sem reportar AUC. Estes achados são consistentes com a visão de que restringir a análise a uma região anatômica focal, seja hipocampo ou córtex, produz desempenho prognóstico mais conservador do que modelos voxel de cérebro inteiro. Trabalho mais recente incorpora informação temporal de RM via aprendizagem de dicionário, aprendizagem profunda ou radiômica. [Zhang et al. \(2019\)](#) analisaram RM estrutural longitudinal para classificação DA/MCI, [Lin et al. \(2020\)](#) usaram aprendizagem de dicionário longitudinal para prever progressão MCI-para-DA, e [Aghajanian et al. \(2025\)](#) combinaram aprendizagem profunda com radiômica de RM estrutural longitudinal para previsão de progressão. Estas abordagens evidenciam interesse crescente na modelação temporal, mas também variam na definição de coorte, no controlo de fugas de informação e na comparação com baselines clínicos. Perante este enquadramento, o presente trabalho **não** visa reproduzir o estado da arte multimodal de cérebro inteiro. Em vez disso, especifica e stress-testa um pipeline prognóstico focado no hipocampo no ADNI, com configuração primária pré-especificada (atributos de imagem por família, SVM, filtragem por frequência de selecção ℓ_1 derivada de bootstrap, sem ComBat; estimando de AUC ao nível do paciente) e ablações sistemáticas ao longo de modalidades, representação longitudinal Q4 versus `t1_only`, preditores clínicos e fusão *late*. A contribuição original é o protocolo de avaliação coordenado: todas as representações candidatas avaliam-se sob elegibilidade temporal explícita, validação aninhada ao nível do paciente, ajuste por fold, estimando OOF comum e comparações sensíveis à multiplicidade. Isto transforma ablações negativas e positivas em evidência de desenho para futuros pipelines de suporte à decisão prognóstica, em vez de tratar a AUC máxima observada como único resultado. Análises de sensibilidade com regressão logís-

tica elastic-net e ComBat por fold, bem como scores clínicos de primeira visita, reportam-se na Secção ?? sob o mesmo estimando. A Tabela 12 resume literatura representativa ao lado dos nossos resultados, sob definições de tarefa explicitamente heterogêneas mas clinicamente análogas. Ajustes face ao inglês (não só tradução):

«wide» / early fusion / quatro famílias → Q4, late, cinco famílias configuração primária volumétrica «wide» → por família + SVM + L1 bootstrap, sem ComBat AUCs 0,680 / $\approx 0,71$ / $\approx 0,76$ retiradas até haver CSVs do rerun; aponta para Results

A previsão automática de estabilidade ou conversão do MCI foi estudada com conjuntos de atributos, esquemas de validação e janelas de desfecho muito distintos. Na investigação prognóstica baseada na ADNI, MCI estável e progressivo aparecem também como ncMCI/cMCI ou MCInc/MCIc, clinicamente análogos a sMCI e pMCI. O desempenho depende, portanto, não só do classificador, mas de os preditores serem clínicos, estruturais, multimodais, regionais ou de cérebro inteiro, e de a informação temporal limitar-se ao baseline ou cobrir várias visitas de seguimento.

Vários estudos mostram que o acompanhamento cognitivo denso pode ser informativo mesmo sem RM. Bucholt et al. (2023) propuseram um ensemble híbrido no National Alzheimer’s Coordinating Center (NACC) para prever conversão MCI→demência a partir de trajectórias cognitivas e funcionais. A acurácia de classificação atingiu 85,0–87,5%, mas a AUC do ensemble no teste retido ficou perto de 0.60, ao passo que florestas aleatórias chegaram a AUC até 0.76 quando havia quatro visitas. Grassi et al. (2019) previram conversão a 3 anos na ADNI só com variáveis sociodemográficas e neuropsicológicas e reportaram AUROC 0.88 (IC bootstrap 95%: 0.85–0.91), com sensibilidade 77,7% e especificidade 79,9% no ponto de melhor acurácia balanceada. Esses resultados indicam que o rastreio clínico carrega sinal prognóstico substancial e constitui um comparador forte para modelos só de imagem.

Estudos de RM estrutural recorrem frequentemente a representações de cérebro inteiro de alta dimensão ou a fusão com escores cognitivos. Moradi et al.

(2015) aplicaram *low-density separation* a T1 de baseline da ADNI para previsão precoce de conversão em MCI, com AUC 0.766 em morfometria voxel-a-voxel isolada e AUC 0.902 ao combinar RM com um agregado cognitivo de baseline. Ye et al. (2012) usaram selecção estável esparsa (Biosignature-15) para prever conversão MCI→AD em quatro anos, com AUC 0.859 em validação leave-one-out (LOOCV) na ADNI de baseline. Casanova et al. (2013) combinaram atributos de RM em larga escala, baseados em tecido, com informação cognitiva num quadro de avaliação de risco por aprendizagem automática na ADNI. Tais estudos mostram que AUC altas surgem sobretudo com desenhos de cérebro inteiro ou multimodais, e com definições de desfecho que podem diferir da discriminação sMCI/pMCI em horizonte curto e regras estritas.

Quando o âmbito espacial se reduz a uma única ROI, o desempenho em geral cai. Cuingnet et al. (2011) compararam dez métodos de classificação na ADNI e reportaram que a discriminação conversor versus não conversor, inclusive com atributos de volume hipocampal, não excedeu o acaso de forma significativa. Guo et al. (2017) estudaram espessura cortical relacionada com conversão para sMCI versus cMCI, com acurácia 98,84% e sensibilidade/especificidade 97,5/100 em LOOCV, mas sem reportar AUC. Esses achados são coerentes com a ideia de que restringir a análise a uma região focal — hipocampo ou córtex — produz desempenho prognóstico mais conservador do que modelos voxel de cérebro inteiro.

Trabalho mais recente incorpora RM temporal via aprendizagem de dicionários, redes profundas ou radiômica. Zhang et al. (2019) analisaram RM estrutural longitudinal para classificação AD/MCI, Lin et al. (2020) usaram aprendizagem de dicionários longitudinal para prever progressão MCI→AD, e Aghajanian et al. (2025) combinaram aprendizagem profunda com radiômica de RM estrutural longitudinal para previsão de progressão. Essas abordagens mostram interesse crescente em modelação temporal, mas diferem em definição de coorte, controlo de vazamento e comparação com baselines clínicos.

Neste contexto, o presente trabalho não visa reproduzir o estado da arte de cérebro inteiro multimodal. Visa especificar e estressar um pipeline prognós-

tico focado no hipocampo na ADNI, com configuração primária pré-especificada (SVM, `l1_stable`, AUC no paciente) e ablações sistemáticas: cinco famílias de atributos, `t1_only` versus Q4, quatro células janela×intervalo, e fusão tardia em três especificações pré-especificadas. A contribuição original é o protocolo de avaliação coordenado: todas as representações candidatas correm sob elegibilidade temporal explícita, validação aninhada no paciente, ajuste fold-wise e o mesmo estimando OOF. Ablações negativas e positivas tornam-se evidência de desenho para futuros sistemas de apoio à decisão, em vez de tratar a maior AUC observada como único resultado. Sob esse protocolo, a forma no t_0 atinge AUC paciente 0.761 ± 0.043 em `48m_12m`; a textura Q4 empata esse teto (0.762 ± 0.044); a fusão tardia Q4/âncora chega a 0.802 ± 0.040 ; os escores clínicos de t_0 permanecem competitivos (0.812 ± 0.040). A Tabela 12 resume literatura representativa ao lado destes resultados, sob definições de tarefa heterogêneas mas clinicamente análogas.

2. Material and Methods

Os dados utilizados neste estudo foram obtidos da base de dados da Alzheimer’s Disease Neuroimaging Initiative (ADNI) [Petersen et al. \(2009\)](#); [Jack Jr. et al. \(2008\)](#). A ADNI foi lançada em 2003 como parceria público–privada para avaliar marcadores clínicos, genéticos, bioquímicos e de neuroimagem longitudinais da doença de Alzheimer (AD). Este estudo utilizou RM estrutural T1-ponderada adquirida com sequências tridimensionais Magnetization-Prepared Rapid Gradient-Echo (MP-RAGE) das fases ADNI-1, ADNI-2 e ADNI-GO, coletadas em centros nos Estados Unidos e no Canadá em scanners de 1.5 T e 3 T da GE Healthcare, Philips Medical Systems e Siemens Medical Solutions.

A coleção ADNI inicial compreendia 15,016 imagens de 1,495 participantes. Duas imagens de um participante com designação de sexo inválida foram excluídas, restando 15,014 imagens de 1,494 participantes.

O controle de qualidade foi aplicado a esse conjunto completo de volumes T1, ainda sem rótulos diagnósticos e antes da construção das coortes. Métri-

cas de qualidade de imagem (IQMs) de referência livre foram calculadas com MRQy (Sadri et al., 2020). Candidatos a outliers foram rastreados com as métricas VRX, COL, NUM, CPP, PSNR, SNR7, CNR, CVP, CJV, EFC e FBER, escolhidas pela relevância a recorte de FOV, geometria de aquisição, ruído e degradação relacionada a movimento ou artefato. Para cada métrica, outliers foram definidos pelas cercas de Tukey (Tukey, 1977),

$$[Q_1 - \alpha \text{IQR}, Q_3 + \alpha \text{IQR}], \quad \text{IQR} = Q_3 - Q_1, \quad (1)$$

com $\alpha = 1.5$ e direcionalidade específica da métrica (valores baixos indesejáveis, altos indesejáveis, ou bilateral). Cada volume recebeu uma pontuação de não conformidade igual ao número de IQMs sinalizadas; volumes com pontuação ≥ 3 entraram em uma lista curta (69/15,014; 0.46%). Os quartis e os limites de IQR foram estimados uma única vez a partir desse conjunto de 15,014 volumes, sem rótulos diagnósticos, antes da construção das coortes e da validação cruzada; não foram recalculados nas partições externas. Esse rastreio ao nível do conjunto de dados foi, portanto, distinto da modelagem ajustada por partição. Todos os casos da lista curta foram inspecionados visualmente no ITK-SNAP (Yushkevich et al., 2006) (v4.2.0). A inspeção confirmou 12 identificadores de aquisição para exclusão por FOV incompleto, aquisições danificadas ou faixas de ruído estruturado.

Em seguida procedeu-se à construção da coorte clínica. Na ADNI, o diagnóstico associado à primeira visita (baseline) não acompanha necessariamente a progressão longitudinal; por isso, cada exame de RM foi alinhado ao diagnóstico clínico e às escalas cognitivas/funcionais (ADAS, CDR, MMSE, FAQ) por correspondência temporal, exigindo distância absoluta ≤ 3 meses (± 90 dias) entre a data de aquisição e a data da avaliação clínica, de modo que o rótulo corresponda o mais possível ao momento da imagem. Assim, imagens do mesmo paciente podem receber rótulos clínicos distintos ao longo do tempo. Antes do pareamento imagem–diagnóstico, os registros diagnósticos longitudinais foram filtrados: removeram-se demências diferentes da doença de Alzheimer, diagnósticos ou datas em falta, e reversões clinicamente implausíveis nas fases contínuas

da AD — MCI→CN ou AD→MCI/CN. Esse rastreio identificou 40 participantes com reversão a partir de AD e, após a sua remoção, mais 128 com reversão MCI→CN, totalizando 168 participantes únicos excluídos; destes, 112 estavam representados na coleção de imagem e correspondiam a 1,325 imagens. O pareamento RM–diagnóstico na janela de ± 90 dias excluiu mais 666 imagens, e a exigência de escores clínicos completos excluiu outras 92, resultando em 12,931 imagens rotuladas de 1,304 participantes. Dos 12 identificadores rejeitados pelo controle visual de qualidade, 10 ainda estavam presentes após o pareamento clínico e foram removidos nesta etapa; os outros dois já tinham sido eliminados pelos filtros diagnósticos precedentes. A tabela após o controle de qualidade continha, portanto, 12,921 imagens. A remoção de 3,757 aquisições cuja descrição ADNI as identificava como repetições (*repeats*) reduziu o conjunto a 9,164 candidatas longitudinais utilizáveis. Esse pool de 9,164 imagens é o ponto de partida para a formação dos conjuntos longitudinais descritos a seguir; ainda não coincide com a coorte final de análise (Tabela 4), que resulta da exigência de exatamente três imagens por paciente sob as regras de janela clínica e intervalo entre aquisições.

2.0.1. Formação dos conjuntos

A formação de cada conjunto longitudinal segue duas etapas em sequência, para que o rótulo clínico não dependa de qual imagem acabou sendo escolhida como preditora.

Etapa 1 — rótulo clínico.. Para cada paciente, ordenam-se todas as suas RM pela data de aquisição. A data da primeira RM define o instante de referência t_0 (baseline). Sobre esse instante fixa-se uma **janela de observação clínica** de 36 ou 48 meses, com término em $t_{\text{end}} = t_0 + \text{janela}$. Olhando toda a trajetória diagnóstica do paciente (não apenas três imagens), decide-se se ele é CN, sMCI, pMCI, AD, ou se deve ser excluído. Só depois dessa decisão passa-se à escolha das imagens que alimentarão o modelo.

Etapa 2 — três imagens preditoras.. Cada paciente contribuirá com exatamente três RM preditoras

$$i = \{i_1, i_2, i_3\}, \quad t(i_1) < t(i_2) < t(i_3), \quad (2)$$

isto é, uma imagem inicial, uma intermediária e uma final. Três é o menor número que ainda permite descrever uma trajetória temporal (início, meio e fim) sem exigir séries longas, raras em repositórios públicos. A escolha é cronológica e usa um intervalo nominal entre aquisições (6 ou 12 meses) com tolerância ± 2 meses:

1. i_1 é a primeira RM elegível no baseline (t_0);
2. i_2 é a **próxima** RM, em ordem de data, cujo intervalo em relação a i_1 cai dentro da faixa de tolerância;
3. i_3 é a **próxima** RM após i_2 cujo intervalo em relação a i_2 cai na **mesma** faixa.

Não se trata de “três imagens *depois* do baseline” (o que seriam quatro visitas): são três no total — o baseline e duas visitas seguintes que respeitam o espaçamento.

As faixas adotadas (± 2 meses) são disjuntas e evitam ambiguidade no bordo dos 9 meses. Com tolerância ± 3 , o intervalo de 6 meses cobriria $[3, 9]$ e o de 12 meses cobriria $[9, 15]$, compartilhando o mês 9: uma imagem adquirida nove meses após a anterior poderia pertencer a qualquer um dos dois esquemas. Com ± 2 :

Intervalo nominal	Faixa admitida (meses)
6 m	[4, 8]
12 m	[10, 14]

Tabela 1: Intervalos nominais entre aquisições e faixas de tolerância.

Combinando as duas durações de janela clínica com os dois intervalos entre imagens obtêm-se **quatro coortes** de análise: 36 meses com intervalo de

6 meses, 36 meses com intervalo de 12 meses, 48 meses com intervalo de 6 meses e 48 meses com intervalo de 12 meses (notação 36m_6m, 36m_12m, 48m_6m, 48m_12m).

Definição dos grupos clínicos..

- **CN:** toda a trajetória diagnóstica é exclusivamente CN, e existe pelo menos uma visita com data $\geq t_{\text{end}}$ que confirma a estabilidade após o fim da janela. As três preditoras i_1, i_2, i_3 são então escolhidas entre imagens CN até t_{end} , respeitando a faixa de intervalo.
- **sMCI:** o baseline é MCI, não há diagnóstico de AD até t_{end} , existe pelo menos uma visita com data $\geq t_{\text{end}}$, e a **primeira** dessas visitas pós-janela permanece MCI. Se a primeira visita após t_{end} for AD (ou outro diagnóstico não-MCI), o paciente é excluído: o desfecho ficou “no meio” da margem de confirmação e não se classifica de forma limpa. Se não houver visita após t_{end} , também é excluído por falta de confirmação. Essa definição **não** afirma que o paciente nunca converterá a AD; exige apenas ausência de conversão no horizonte pré-especificado, com confirmação na primeira avaliação após o fim da janela. A visita de confirmação **não** precisa respeitar a faixa ± 2 meses — essa faixa serve apenas para escolher i_1, i_2, i_3 (todas MCI, até t_{end}).
- **pMCI:** o baseline é MCI e ocorre pelo menos um diagnóstico de AD com data $\leq t_{\text{end}}$. Preferencialmente selecionam-se três preditoras ainda em estágio MCI, antes do primeiro AD (MCI, MCI, MCI), desde que exista conversão documentada dentro da janela. Quando não há três aquisições MCI com o espaçamento exigido antes da conversão, admite-se uma regra de inclusão ampliada: MCI, MCI, AD, em que i_3 é o **primeiro** AD (único AD no conjunto preditor). Não se admite MCI, AD, AD: apenas o primeiro AD define o desfecho; um segundo AD no preditor afastaria o último MCI do horizonte e misturaria alterações estruturais já pós-conversão.
- **AD:** toda a trajetória é exclusivamente AD; as três preditoras são AD, escolhidas na faixa de intervalo até t_{end} .

Em resumo: primeiro classifica-se o paciente pela história clínica na janela; depois escolhem-se, em ordem temporal, três imagens cujo espaçamento cai na faixa de tolerância. Pacientes que não fornecem três imagens elegíveis sob essas regras ficam de fora da coorte correspondente, mesmo que o rótulo clínico esteja definido.

2.0.2. Coortes de estudo

A Tabela 2 resume as contagens sMCI/pMCI após a formação dos conjuntos em cada combinação janela×intervalo.

Janela	Intervalo entre imagens	sMCI / pMCI
36 m	6 ± 2 [4, 8]	125 / 106
36 m	12 ± 2 [10, 14]	121 / 33
48 m	6 ± 2 [4, 8]	73 / 120
48 m	12 ± 2 [10, 14]	72 / 48

Tabela 2: Contagens sMCI/pMCI em conjuntos (tolerância ± 2 meses).

As 9,164 candidatas longitudinais não coincidem com o total da Tabela 4: esta última é a **união** das imagens únicas presentes em pelo menos uma das quatro coortes de análise (CN, sMCI, pMCI e AD), após a exigência de exatamente três aquisições e sem duplicar a mesma imagem quando ela entra em mais de uma combinação janela×intervalo — 2,038 imagens de 560 participantes, estratificadas por fase ADNI de aquisição.

A Tabela 3 resume demografia e escores cognitivos/funcionais nas três visitas preditoras (t_0 , t_1 , t_2) para sMCI e pMCI nas quatro coortes. CN/AD e CDR global foram omitidos (continuum de sanidade / constante 0,50 no baseline MCI). Valores contínuos: média $\pm$ desvio-padrão; n apenas na coluna de pacientes.

Também se exploraram as bases **AIBL** e **OASIS** sob a mesma lógica de elegibilidade, mas sem número suficiente de conjuntos longitudinais com três imagens.

Coorte	Grupo	Slot	<i>n</i>	Sexo M/F	Idade	MMSE	ADAS	CDR-SB	FAQ
36m_6m	sMCI	<i>t</i> ₀	125	80/45	72.63 ± 7.18	27.78 ± 1.75	9.05 ± 3.61	1.22 ± 0.64	1.93 ± 3.09
		<i>t</i> ₁	125	80/45	73.16 ± 7.16	28.04 ± 1.77	8.79 ± 3.64	1.23 ± 0.77	2.22 ± 3.33
		<i>t</i> ₂	125	80/45	73.67 ± 7.19	27.99 ± 1.88	8.47 ± 4.11	1.36 ± 0.95	2.53 ± 3.56
	pMCI	<i>t</i> ₀	106	56/50	74.39 ± 7.33	26.64 ± 1.74	13.54 ± 4.49	1.94 ± 1.00	5.34 ± 4.42
		<i>t</i> ₁	106	56/50	74.90 ± 7.26	25.32 ± 2.65	14.84 ± 5.00	2.44 ± 1.01	6.79 ± 4.75
		<i>t</i> ₂	106	56/50	75.44 ± 7.30	24.68 ± 2.70	15.75 ± 5.83	3.19 ± 1.41	8.95 ± 5.66
36m_12m	sMCI	<i>t</i> ₀	121	80/41	73.15 ± 7.06	27.80 ± 1.74	9.05 ± 3.60	1.21 ± 0.63	1.85 ± 3.01
		<i>t</i> ₁	121	80/41	74.21 ± 7.07	28.02 ± 1.87	8.62 ± 4.20	1.33 ± 0.88	2.58 ± 3.48
		<i>t</i> ₂	121	80/41	75.22 ± 7.05	27.85 ± 2.17	9.08 ± 4.54	1.51 ± 1.20	2.70 ± 3.65
	pMCI	<i>t</i> ₀	33	22/11	74.30 ± 7.35	27.00 ± 1.62	12.30 ± 2.85	2.09 ± 1.17	5.45 ± 4.90
		<i>t</i> ₁	33	22/11	75.33 ± 7.34	25.88 ± 2.13	13.31 ± 4.07	2.67 ± 1.19	7.55 ± 4.94
		<i>t</i> ₂	33	22/11	76.39 ± 7.34	23.33 ± 2.91	17.24 ± 4.78	4.45 ± 1.40	12.76 ± 6.02
48m_6m	sMCI	<i>t</i> ₀	73	48/25	72.29 ± 6.80	27.89 ± 1.65	8.80 ± 3.53	1.11 ± 0.61	1.88 ± 3.32
		<i>t</i> ₁	73	48/25	72.84 ± 6.74	28.30 ± 1.40	8.33 ± 3.40	1.09 ± 0.71	2.07 ± 3.40
		<i>t</i> ₂	73	48/25	73.30 ± 6.81	28.16 ± 1.84	7.83 ± 3.49	1.16 ± 0.95	2.30 ± 3.36
	pMCI	<i>t</i> ₀	120	62/58	74.35 ± 7.20	26.65 ± 1.71	13.20 ± 4.41	1.89 ± 0.98	5.17 ± 4.46
		<i>t</i> ₁	120	62/58	74.85 ± 7.15	25.43 ± 2.60	14.44 ± 4.99	2.37 ± 1.00	6.46 ± 4.81
		<i>t</i> ₂	120	62/58	75.40 ± 7.18	24.89 ± 2.65	15.38 ± 5.65	3.04 ± 1.43	8.53 ± 5.81
48m_12m	sMCI	<i>t</i> ₀	72	49/23	72.88 ± 6.70	28.00 ± 1.63	8.71 ± 3.40	1.07 ± 0.59	1.85 ± 3.30
		<i>t</i> ₁	72	49/23	73.93 ± 6.73	28.32 ± 1.69	8.07 ± 3.65	1.17 ± 0.89	2.43 ± 3.37
		<i>t</i> ₂	72	49/23	74.96 ± 6.68	28.29 ± 1.86	8.65 ± 3.59	1.29 ± 1.03	2.26 ± 3.26
	pMCI	<i>t</i> ₀	48	28/20	73.98 ± 6.83	26.94 ± 1.56	12.18 ± 2.95	1.93 ± 1.10	4.83 ± 4.88
		<i>t</i> ₁	48	28/20	75.00 ± 6.83	25.90 ± 1.95	13.24 ± 3.79	2.45 ± 1.18	6.77 ± 5.36
		<i>t</i> ₂	48	28/20	76.06 ± 6.86	23.90 ± 2.81	16.44 ± 4.81	3.76 ± 1.61	10.56 ± 6.51

Nota: Inclusão ampliada de pMCI (último preditor = primeiro AD): 46 em 36m_6m/48m_6m; 33 em 36m_12m/48m_12m. MMSE: Mini-Mental State Examination; ADAS: Alzheimer's Disease Assessment Scale; CDR-SB: Clinical Dementia Rating – Sum of Boxes; FAQ: Functional Activities Questionnaire. As quatro coortes entram como células do fatorial janela×intervalo; 36m_6m tem o maior *n*.

Tabela 3: Características clínicas sMCI/pMCI nas quatro coortes (tolerância ±2; inclusão ampliada de pMCI ativa).

Fase ADNI	Imagens	Pacientes	Sexo (M/F)	Idade (anos)	Campo (1.5T / 3T)	Fabricante (n)
ADNI 1	1349	370	203/167	76.14 $\pm$ 6.91	1261 / 88	GE (768); Siemens (579); Philips (2)
ADNI GO	51	27	16/11	70.61 $\pm$ 6.76	0 / 51	Siemens (44); Philips (7)
ADNI 2	638	190	101/89	73.63 $\pm$ 7.02	0 / 638	Siemens (483); Philips (155)
Total	2038	560	304/256	75.21 $\pm$ 7.07	1261 / 777	GE (768); Siemens (1106); Philips (164)

Nota: Contagens sem duplicar a mesma imagem entre coortes (sobreposição janela $\times$ intervalo). Idade = média $\pm$ DP no momento da aquisição. Sexo por paciente único dentro de cada fase (um paciente pode contribuir imagens a mais de uma fase; 370 + 27 + 190 = 587 > 560). Modelos de equipamento (n imagens): ADNI 1 — SIGNA EXCITE (445), Symphony (233), SIGNA HDx (196), Sonata (146), GENESIS_SIGNA (123), Avanto (100), Trio (34), SymphonyTim (25), Allegra (17), SonataVision (13), TrioTim (11); ADNI GO — Verio (25), TrioTim (18), Intera (4), Achieva (3), Skyra (1); ADNI 2 — TrioTim (297), Achieva (95), Verio (95), Skyra (90), Intera (38), Ingenia (17).

Tabela 4: Imagens T1w MP-RAGE por fase ADNI (união das quatro coortes de análise; imagens únicas por identificador de aquisição).

A tarefa principal é a classificação **sMCI versus pMCI**. O mesmo pipeline (três T1 hipocampais, SVM, `11_stable`, AUC no paciente) aplica-se a **quatro cenários** do fatorial janela clínica $\times$ intervalo entre imagens — não a uma coorte semente e três expansões. A janela (36 ou 48 meses) define o horizonte do rótulo; o intervalo nominal (6 ou 12 meses, ± 2) define a cadência das preditoras. As quatro células entram no contraste unimodal Q4 versus `t1_only` no mesmo nível: o objectivo é ver se o padrão de famílias se replica quando mudam horizonte e espaçamento, não coroar a célula com maior Δ AUC. As populações sobrepõem-se e **não** são réplicas independentes; diferem n , balanço sMCI/pMCI e, nos intervalos de 12 meses, a fracção de pMCI com i_3 já em AD. Relato complementar (não substitui o fatorial): demografia sobretudo em `36m_6m` (maior n); nomes de atributos, clínico, leaky e CN $\times$ AD em `48m_12m` (palco das ablações que não se repetem nas quatro células). A fusão tardia reporta-se nas **quatro** células.

Janela de 36 versus 48 meses no mesmo intervalo entre imagens.. Não se deve esperar AUC idêntica em `36m_6m` versus `48m_6m` (nem em `36m_12m` versus `48m_12m`) apenas porque a representação `t1_only` usa a visita de baseline.

Na **interseção** de pacientes presentes nas duas coortes com o mesmo espaçamento nominal, o identificador de aquisição de t_0 coincide (e o triplo $t_0-t_1-t_2$ também), com o mesmo rótulo de grupo. Contudo as **populações não são as mesmas**: a duração da janela clínica altera a elegibilidade (quem entra ou sai). Exemplos no protocolo atual (tolerância ± 2): sMCI 125 versus 73 (intervalo 6 meses) e 121 versus 72 (intervalo 12 meses), com dezenas de identificadores exclusivos de uma das janelas. Logo diferem n , balanço sMCI/pMCI, partições de validação cruzada e AUC — inclusive em **t1_only** — mesmo com sobreposição de baselines.

2.1. Representação longitudinal

Cada sujeito contribui três aquisições T1 nas visitas T_1 , T_2 e T_3 (intervalos nominais 6 ou 12 meses). O baseline **t1_only** usa só os atributos de T_1 . A representação longitudinal oficial **t1_d21_d32** (Q4) concatena *níveis* das três visitas: colunas T1, D21 e D32, em que D21 e D32 são os mesmos descritores medidos em T_2 e T_3 , não diferenças $T_b - T_a$. Não se usam **wide/abs**, **t1_deltas** nem médias móveis como claim temporal: Q4 testa se *estados* sucessivos acrescentam discriminação ao t_0 , sem reparametrizar mudança.

2.2. Pré-processamento

Após obtenção dos dados brutos de RM na base ADNI, os volumes foram submetidos a um pipeline de pré-processamento próprio. Essas operações foram aplicadas de forma independente a cada imagem, com configurações de software fixas: modelos pré-treinados foram usados para extração de crânio e parcelamento; o denoising e a correção de campo de viés estimaram quantidades específicas de cada imagem; a normalização de intensidade e o alinhamento espacial usaram imagens de referência e parâmetros algorítmicos fixos. Nenhum parâmetro de pré-processamento foi estimado por agrupamento das imagens sMCI e pMCI.

A Figura 1 resume o arcabouço: pré-processamento de RM **T1-w**, controle de qualidade, parcellation, construção de template *groupwise*, registro baseado

em campo de deslocamento, extração multimodal de atributos, harmonização opcional, agregação tabular *wide* e classificação aninhada com seleção estável de atributos.




Figura 1: Pipeline.

2.3. Definição da coorte

Em seguida, todos os volumes ponderados em T1 passaram por uma cadeia fixa de pré-processamento no ecossistema ANTsX [Tustison et al. \(2021\)](#), composta pelos seguintes passos sequenciais:

Extração de crânio: Executada com um modelo de extração encefálica por aprendizagem profunda treinado em T1, da biblioteca ANTsPyNet (`antspynet.brain_extraction, modality="t1"`) [Tustison et al. \(2021\)](#).

Denoising: Médias não locais adaptativas para ruído ricianiano [Manjón et al. \(2010\)](#), implementadas com `ants.denoise_image` usando `noise_model="Rician"`, raio de patch $p = 2$, raio de busca $r = 3$ e `mask=None`. O parâmetro específico do ANTs `shrink_factor=1` desativa o downsampling interno e é um controle de implementação, não parte da formulação original.

Correção de campo de viés bias field: Correção N4ITK [Tustison et al. \(2010\)](#) com `ants.n4_bias_field_correction`, usando `shrink_factor=3`, `convergence={iters: [50, 50, 50, 50], tol: 1×10-7}` (quatro níveis de multi-resolução), `spline_param=200`, `rescale_intensities=True` e `mask=None`.

histogram matching ****Histogram matching.**** As intensidades da RM T1 foram padronizadas por ***histogram matching*** [Nyul et al. \(2000\)](#) ao template fixo MNI152 2009c [Fonov et al. \(2011\)](#), implementado com `'ants.histogram_match_image2'`

(‘transform_domain_size=128’, ‘match_points=16’), após normalização min-max ****independente**** das imagens fonte e de referência. Máscaras encefálicas da fonte e da referência foram estimadas com ‘ants.get_mask’; as intensidades correspondidas foram em seguida reescaladas pelo percentil 99,9 dos voxels encefálicos na referência. O procedimento correu ****por imagem****; não se estimaram parâmetros de intensidade ao nível da coorte. O matching reduz heterogeneidade grosseira de escala, mas ****não**** modela efeitos de lote de scanner ou fabricante ao nível do atributo: o NeuroComBat por fold [Fortin et al. \(2018\)](#) ficou como análise de sensibilidade opcional.

****Parcelamento e segmentação tecidual.**** Os mapas de ROI foram obtidos com ‘antspynet.desikan_killiany_tourville_labeling’ (‘modality="t1"’, ‘do_preprocessing=True’), incluindo os hipocampos (rótulos DKT 17 e 53) e as restantes regiões usadas na extração. A segmentação em LCR, substância cinzenta e substância branca (rótulos 1, 2 e 3) veio de ‘antspynet.deep_atropos’, mesma modalidade e mesma **flag** de pré-processamento. Embora a cadeia ANTsX externa já incluísse extração de crânio, denoising, N4, **histogram matching** e alinhamento rígido ao MNI, reteve-se o pré-processamento ****interno**** da biblioteca para coincidir com o domínio dos pesos pré-treinados do ANTsPyNet — o que pode duplicar, em parte, normalização de intensidade ou espacial. Os rótulos serviram só para definir ROIs e fracções teciduais; as transformações internas do ANTsPyNet ****não**** foram tratadas como estágio treinável adicional.

Alinhamento espacial: As imagens clínicas foram registradas rigidamente ao espaço de referência MNI152 2009c [Fonov et al. \(2009, 2011\)](#) com `ants.registration` do ANTsPy [Avants et al. \(2011\)](#); [Tustison et al. \(2021\)](#), corrigindo o alinhamento global e padronizando a orientação espacial. Parágrafo para Methods (bate com ‘2_resample.py’ tal como está):

O alinhamento espacial consistiu num registo ****rígido**** (6 graus de liberdade: rotação e translação; sem componente afim nem deformável) de cada volume T1, já submetido a extração de crânio, denoising, correção N4 e **histogram matching**, ao template fixo MNI152 2009c em grelha isotrópica de 1,0 mm. O

template serviu apenas como **grelha de referência** (espaçamento e orientação canónicos), não como alvo de normalização anatómica. A estimação e a interpolação da T1 foram feitas com ‘ants.registration’ (‘type_of_transform="Rigid", interpolador "linear"’): imagem **fixa** = template MNI; imagem **móvel** = T1 clínica; o volume deformado (‘warpedmovout’) foi gravado no espaço do template. A transformada directa resultante (‘fwdtransforms’) foi em seguida aplicada, com ‘ants.apply_transforms’, aos mapas nativos de parcelamento DKT (‘_regions.nii.gz’), de classes teciduais (‘_seg.nii.gz’) e à máscara encefálica (‘_brain_mask.nii.gz’), usando o T1 já reamostrado como imagem de referência espacial e interpolador **nearestNeighbor**, de modo a preservar os identificadores inteiros dos rótulos. Assim, intensidade e máscaras partilham a mesma pose, a mesma grelha e a mesma afinidade; a anatomia do sujeito permanece inalterada a menos de uma isometria e de uma única interpolação. O PyRadiomics não reamostra (‘resampledPixelSpacing’ omitido), evitando uma segunda interpolação antes da extração de atributos.

Discretização binning

DEFAULT_BIN_COUNT = 64 → RadiomicsFeatureExtractor(binCount=64); binWidth omitido (evita default CT binWidth=25). FBN por ROI. normalize=False (default)

Extração dos atributos O inglês que colaste **não** descreve o código actual: ‘binWidth=25’, DVF no domínio clínico, clínico=fixed. Pipeline oficial é **3_feat_gen_dvf_v2.py** + **3_feat_dvf_v2.py** (template=fixed). Abaixo: armazém (o que os scripts extraem). Classificador corta depois.

Extração de atributos. Por aquisição extraem-se cinco famílias sobre as mesmas 20 ROIs DKT (L/R: hipocampo, amígdala, tálamo, núcleo accumbens, ventrículo lateral inferior, cíngulo posterior, ístmo do cíngulo, cíngulo anterior rostral, orbitofrontal medial, ínsula), cada rótulo intersectado com a máscara encefálica; ROI vazia grava-se NaN. Volume, forma, textura e primeira ordem vivem no espaço MNI 1 mm da T1 rígida; o deslocamento vive no espaço do template CN groupwise.

****Volumetria ('3_feat_vol.py').**** Com 'regions', 'seg' (LCR=1, GM=2, WM=3) e 'brain_mask' na mesma grelha, o volume do voxel é o produto dos *zooms* NIFTI. Por ROI: 'mask_mm3' ($\text{ROI} \cap \text{cérebro}$); 'gm_mm3', 'wm_mm3', 'csf_mm3'; fracções ****dentro da ROI**** 'gm_norm' = $V_{\text{GM}}/V_{\text{ROI}}$ (análogo WM/LCR); 'tissues_mm3' e 'tissues_norm' (soma das três classes / V_{ROI}). A linha '__global__' guarda o ICV como 'mask_mm3' da máscara encefálica. No pós-processamento, descritores de tamanho em mm^3 (incluindo malha/eixos do PyRadiomics) dividem-se por esse ICV; as fracções ****não**** se renormalizam pelo ICV.

****Radiómica ('3_feat_rad.py').**** PyRadiomics '3.1.1.dev111+g8ed579383'; nomes IBSI da biblioteca, sem phantom de conformidade. Só tipo 'Original' (sem LoG/wavelet). Discretização ****FBN**** 'binCount=64' ('binWidth' omitido; evita o default CT 'binWidth=25'). Sem resample extra ('resampled-PixelSpacing' omitido); 'normalize=False'; textura 3D ('force2D=False', 'distances=[1]', 'symmetricalGLCM=True'). Grelha/afim imagem-máscara: atol 10^{-5} . Por ROI e visita o armazém tem ****107**** descritores: 18 first-order, 14 shape, 24 GLCM, 16 GLRLM, 16 GLSZM, 5 NGTDM, 14 GLDM.

****Deslocamento normativo ('3_feat_gen_dvf_v2.py', '3_feat_dvf_v2.py').**** Template CN do sexo e da década em T_1 , constante em T_2 e T_3 ; DIAG/GROUP não escolhem o atlas. SyN com ****fixed = template CN****, ****moving = T1 clínica**** 1 mm, interpolador 'bspline'; gravam-se affine, warp e inverse warp. O campo constrói-se no ****domínio do template****: $I_t = [\text{affine}, \text{inverse warp}]$ aplicado às coordenadas físicas $x \in \Omega_{\text{CN}}$,

$$\mathbf{u}_t(x) = I_t(x) - x.$$

ROIs e máscara do sujeito transportam-se ao template pela cadeia directa (Warp+Affine, NN). De $\mathbf{u}_t$: $\log J$, $\|\mathbf{u}\|$, divergência, (u_x, u_y, u_z) , $\|\text{rot } \mathbf{u}\|$; escalares de Green-Lagrange ('strain_trace', 'strain_det', 'strain_fro', 'strain_vol', 'strain_dev_norm', 'strain_shear_max', 'strain_l1/12/13', 'strain_shear_ratio', 'strain_shear_energy'); e $\|\varepsilon\|_F$ da deformação infinitesimal $\varepsilon = \frac{1}{2}(H + H^T)$. Por ROI: n , média, desvio-padrão, p05/p50/p95; para 'logjac', 'mag' e 'strain_fro'

(este último nos momentos com ε infinitesimal, não com o Frobenius de Green–Lagrange) também variância amostral, assimetria e curtose de Fisher. Sem mapas $T_a \rightarrow T_b$.

****O que entra no classificador (denylist, não é o extracto cru).**** Volume: ‘gm_norm’, ‘wm_norm’, ‘csf_norm’, ‘original_shape_MeshVolume’ (/ICV). Forma: 12 ‘original_shape_’ excepto ‘MeshVolume’ e ‘VoxelVolume’. Textura: só 24 ‘original_glcmm_’. First-order: 16 ‘original_firstorder_’ excepto ‘Energy’ e ‘TotalEnergy’. DVF: prefixos ‘mag_’, ‘logjac_’, ‘strain_fro_’, sem ‘_n’ nem percentis.

As imagens T1 utilizadas neste estudo já tinham sido submetidas, fora deste repositório, a extração de crânio, denoising por médias não locais e correção de campo de viés N4. O alinhamento espacial aqui aplicado consiste em registro rígido ao template MNI152 2009c [Fonov et al. \(2011\)](#) em grelha isotrópica de 1,0 mm (`2_resample.py`), com interpolação linear da intensidade e vizinho mais próximo para as máscaras de ROI, a segmentação tecidual e a máscara encefálica.

Os hipocampus esquerdo e direito (rótulos DKT 17 e 53) foram parcelados com `antspynet.desikan_killiany_tourville_labeling(modality="t1", do_preprocessing=True)`. A segmentação de classes teciduais — líquido cefalorraquidiano (LCR), substância cinzenta (GM) e substância branca (WM) (rótulos 1, 2 e 3) — foi obtida com `antspynet.deep_atropos`, com a mesma modalidade e a mesma flag de pré-processamento. Embora a cadeia externa ANTsX já incluísse extração de crânio, denoising, N4, matching de histograma e alinhamento rígido ao MNI, reteve-se o pré-processamento interno da biblioteca para coincidir com o domínio esperado pelos pesos pré-treinados do ANTsPyNet. Os rótulos foram usados apenas para definição de ROI e fracções teciduais; as transformações internas do ANTsPyNet não foram tratadas como estágio treinável adicional.

2.4. Construção de templates groupwise estratificados

Para reduzir o viés de um único sujeito de referência [Reuter et al. \(2012\)](#) e fornecer um espaço normativo demograficamente adequado, construíram-se templates volumétricos médios a partir de imagens T1 pré-processadas de indiví-

duos cognitivamente normais (CN). Os templates foram estratificados por sexo e década de idade (50,9–59,9, 60,9–69,9, $\dots$, 90,9–99,9 anos) e serviram como referências de envelhecimento saudável para o registro deformável visita a visita. Para cada estrato sexo–década, reteve-se até $N_{\max} = 20$ aquisições CN. Quando havia mais de 20 exames CN elegíveis, aplicou-se amostragem aleatória sem reposição com semente fixa `RANDOM_SEED=7`, para reprodutibilidade. A escolha $N_{\max} = 20$ equilibra representatividade demográfica e custo computacional. A amostra de referência CN foi selecionada uma única vez, antes da validação cruzada, e a seleção não foi repetida nos folds externos. Nenhum participante sMCI ou pMCI contribuiu para a construção dos templates. Para o desfecho primário sMCI/pMCI, os templates resultantes foram portanto tratados como referências normativas fixas, provenientes de um grupo disjunto de ambas as classes prognósticas, e não como transformações ajustadas por fold. O alinhamento groupwise começou com um pré-registro global mascarado de cada imagem selecionada a um alvo comum, aplicando transformações rígidas seguidas de afins. O template inicial $T^{(0)}$ foi definido como a média aritmética dessas imagens pré-alinhadas, reamostradas no espaço do alvo. Seguiu-se refinamento não linear por Symmetric Normalization (SyN) [Avants et al. \(2014\)](#) ao longo de cinco iterações: em cada iteração, todas as imagens do estrato foram registradas de forma não linear ao template corrente sob máscaras encefálicas, e o template foi actualizado pela média das imagens deformadas. Após a última iteração SyN, o template groupwise foi pós-processado para consistência de atlas: recomputou-se uma máscara encefálica sobre o template médio, e as intensidades intracranianas foram reescaladas de forma robusta, recortando aos percentis 2–98 e mapeando linearmente esse intervalo para $[0, 1]$. Este passo padroniza o contraste visual entre estratos e não altera as transformações deformáveis usadas no pipeline prognóstico.

2.5. Registro normativo visita a visita

Os atributos de deslocamento derivam de *registro normativo visita a visita*, não de mapas de diferença inter-visita. Para cada participante, o template

groupwise CN foi fixado pelo sexo e pela década de idade na primeira visita de entrada do modelo (T_1), independentemente do diagnóstico clínico corrente Wyman et al. (2013). Essa atribuição de template ancorada em T_1 manteve-se constante em T_2 e T_3 , independentemente da progressão clínica subsequente. Em cada visita $t \in \{T_1, T_2, T_3\}$, realizou-se um registro SyN independente no espaço de 1,0 mm, com o volume T1 clínico pré-processado como imagem **fixa** e o template CN atribuído como imagem **móvel** (`ants.registration`). O ANTs estimou, portanto, uma transformação template→clínico F_t (móvel → fixa) e a sua inversa I_t (fixa → móvel). Affine, warp directo e warp inverso foram armazenados por imagem. A informação longitudinal entra no classificador pela representação Q4: mapas escalares dos três registros template→clínico separados concatenam-se como slots T1, D21 e D32. **Não** se compuseram warps entre visitas (p.ex. $I_{T_2} \circ F_{T_1}$) e **não** se calcularam campos de deslocamento baseline→follow-up para os atributos prognósticos reportados. Cada visita quantifica o desvio anatómico relativamente a uma referência normativa CN comum naquele instante, não uma mudança morfológica inter-visita explícita.

2.6. Extração de atributos

Por aquisição extraem-se cinco famílias: volume, forma, textura GLCM, primeira ordem e deslocamento normativo. O armazém guarda o bloco IBSI completo e os mapas do DVF. O classificador recebe a *classe* de cada família após uma denylist só de definição (`keep_*_feat` em `ablation_prep.py`; Tabela 7): não há lista permitida de 4–5 nomes. A selecção amostral (variância, correlação, pool `l1_stable`) corre depois, só no treino externo.

2.6.1. Atributos volumétricos

Por ROI intersectada com a máscara encefálica, `3_feat_vol.py` regista volumes em mm^3 e fracções *dentro da ROI*: `gm_norm` = $V_{\text{GM}}/V_{\text{ROI}}$ (análogo para WM e LCR). O ICV (`ICV_mask_mm3`) é o volume da máscara encefálica (linha `__global__`). No pós-processamento, descritores de tamanho (mm^3 e malha/eixos do PyRadiomics) dividem-se por esse ICV; as fracções **não** se re-

normalizam pelo ICV — não são volumetria clássica em mm^3 [Wyman et al. \(2013\)](#). Entram `gm_norm`, `wm_norm`, `csf_norm` e `original_shape_MeshVolume` (já /ICV). Saem volumes crus em mm^3 . O volume de malha fica no bloco de volume, não no de forma.

2.6.2. Atributos radiômicos (PyRadiomics)

2.6.3. Atributos radiômicos (PyRadiomics)

Forma, textura e primeira ordem extraem-se com PyRadiomics 3.1.1.dev111+g8ed579383 [van Griethuysen et al. \(2017\)](#). Nomes e definições seguem a terminologia IBSI da biblioteca [Zwanenburg et al. \(2020\)](#); não se reivindica validação IBSI independente.

A extração é independente por ROI e aquisição (`3_feat_rad.py`), sobre volumes T1 já registados rigidamente ao MNI152 2009c em grelha isotrópica de 1,0 mm (interpolação linear na imagem; vizinho mais próximo nas máscaras). O PyRadiomics não reamostra (`resampledPixelSpacing` omitido), evitando segunda interpolação. Grelha e afinidade imagem/máscara verificam-se com tolerância absoluta 10^{-5} . Cada rótulo anatómico intersecta a máscara encefálica; ROI ausente grava-se NaN. Só o tipo de imagem `Original` (sem LoG nem wavelet). Discretização por contagem fixa de bins (`binCount=64`; `binWidth` omitido), adequada a unidades MRI arbitrárias e para evitar o default CT `binWidth=25`. Controlos restantes nos defaults da biblioteca (`normalize=False`, `force2D=False`, `distances=[1]`, `symmetricalGLCM=True`).

Por ROI e visita o **armazém** guarda 107 descritores: 18 de primeira ordem, 14 de forma, 24 GLCM, 16 GLRLM, 16 GLSZM, 5 NGTDM e 14 GLDM. Nas ablações hipocampais oficiais, após `denylist` só de definição (`ablation_prep.py`), entram três subcategorias radiômicas (Tabela 5):

- **primeira ordem:** 16 `original_firstorder_*` excepto `Energy` e `TotalEnergy` (escalam com o número de voxels);
- **forma:** 12 `original_shape_*` excepto `MeshVolume` e `VoxelVolume` (tamanho fica no bloco volumétrico; `MeshVolume` entra já /ICV);

- **textura:** os 24 `original_glcm_*` (GLCM Original); saem GLRLM, GLSZM, GLDM, NGTDM e filtros wavelet/LoG.

Cada sufixo conta $\times$ L e R; em `t1_only` $\times$ 1 visita e em Q4 (`t1_d21_d32`) $\times$ 3 slots. Contagens L+R *antes* do L1: Tabela 7.

Subcategoria	<i>n</i>	Atributos (sufixo)
Primeira ordem	16	10Percentile, 90Percentile, Entropy, InterquartileRange, Kurtosis, Maximum, Mean, MeanAbsoluteDeviation, Median, Minimum, Range, RobustMeanAbsoluteDeviation, RootMeanSquared, Skewness, Uniformity, Variance
Forma	12	SurfaceArea, SurfaceVolumeRatio, Sphericity, Elongation, Flatness, LeastAxisLength, MajorAxisLength, MinorAxisLength, Maximum2DDiameterColumn, Maximum2DDiameterRow, Maximum2DDiameterSlice, Maximum3DDiameter
Textura (GLCM)	24	Autocorrelation, ClusterProminence, ClusterShade, ClusterTendency, Contrast, Correlation, DifferenceAverage, DifferenceEntropy, DifferenceVariance, Id, Idm, Idmn, Idn, Imc1, Imc2, InverseVariance, JointAverage, JointEnergy, JointEntropy, MCC, MaximumProbability, SumAverage, SumEntropy, SumSquares
Total	52	—

Tabela 5: Atributos PyRadiomics retidos nas ablações hipocampais (após denylist). Prefixo `original_` omitido na coluna de nomes para legibilidade; no CSV o nome completo inclui `original_firstorder_`, `original_shape_` ou `original_glcm_`.

2.6.4. Atributos de deslocamento

A referência é o atlas groupwise CN do sexo e da década em T_1 , independente do diagnóstico Wyman et al. (2013), e mantém-se em T_2 e T_3 . Em cada visita, SyN com template CN **fixo** e T1 clínico **móvel** (`3_feat_gen_dvf_v2.py`). Os mapas vivem no domínio do template. O campo obtém-se aplicando $I_t = [\text{affine}, \text{inverse warp}]$ às coordenadas físicas do template (fixed $\rightarrow$ moving):

$$\mathbf{u}_t(x) = I_t(x) - x, \quad x \in \Omega_{\text{CN}}. \quad (3)$$

ROIs e máscara encefálica do sujeito transportam-se ao template pela cadeia directa (Warp+Affine, vizinho mais próximo). De $\mathbf{u}_t$ derivam-se $\log J$, $\|\mathbf{u}\|$, divergência, (u_x, u_y, u_z) , rotacional, escalares de Green–Lagrange e $\|\varepsilon\|_F$ da deformação infinitesimal $\varepsilon = \frac{1}{2}(H + H^\top)$ Bouke and Abdullah (2023). Não há mapas $T_a \rightarrow T_b$: T_2 e T_3 são desvio ao mesmo âncora CN, não deformação inter-visita. Por ROI hipocampal no template agregam-se média, desvio-padrão, percentis e, para $\log J$, $\|\mathbf{u}\|$ e $\|\varepsilon\|_F$, variância, assimetria e curtose.

Entram momentos de `mag_`, `logjac_` e `strain_fro_` (15 sufixos por lado na representação longa). Saem componentes `ux/uy/uz`, sufixos `_n` e percentis. `strain_fro_mean` resume a norma de Frobenius de Green–Lagrange; `strain_fro_variance` a da ε infinitesimal — tensores distintos.

2.7. Representações temporais

Nome	Papel	Definição
<code>t1_only</code>	baseline	só t_0 (coluna T1)
<code>t1_d21_d32 (Q4)</code>	longitudinal	concatenação de <i>níveis</i> T1, D21 e D32 (os mesmos descritores em T_1, T_2, T_3)

Tabela 6: Representações temporais oficiais.

Sem denylist, só o bloco IBSI dá $107 \times 2 = 214$ colunas em `t1_only` e 642 em Q4; $n \in [120, 231]$. A Tabela 7 é o espaço que `l1_stable` vê. Ainda $p \sim n$ (ou $p > n$) em várias células; o L1 continua necessário. Não há modalidade

Família	Entra (denylist)	t1_only	Q4
vol	gm/wm/csf_norm, MeshVolume (sai mm ³ cru)	8	24
shape	12 original_shape_* (sai Mesh/VoxelVolume)	24	72
texture	24 original_glcmm_* (sai GLRLM/GLSZM/GLDM/NGTDM)	48	144
firstorder	16 original_firstorder_* (sai Energy, TotalEnergy)	32	96
disp	15 momentos mag_/logjac_/strain_fro_ (sai $u_{x,y,z}$, _n, percentis)	30	90

Tabela 7: Atributos por família *antes* da seleção (L+R; denylist de definição, não lista permitida de nomes). Q4 = 3× o baseline: cada sufixo em T1, D21 e D32.

all (concatenação precoce das cinco famílias) no contraste oficial: esse desenho reproduz $p \gg n$ e mistura papéis no mesmo SVM.

2.8. Desenho experimental

O desfecho é sMCI versus pMCI nas quatro células do fatorial janela clínica × intervalo (Tabela 2): 36m_6m 125/106, 36m_12m 121/33, 48m_6m 73/120, 48m_12m 72/48. Cada conjunto exige três T1 com hipocampo bilateral em T_1, T_2, T_3 , intervalo na faixa ± 2 meses e desfecho clínico na janela correspondente (Sec. ??). Inclusão ampliada de pMCI (i_3 = primeiro AD): 46 nos intervalos de 6 meses e 33 nos de 12 meses. Não há hold-out fixo nem *downsampling* de classe. A generalização avalia-se só no paciente: as três visitas do mesmo sujeito ficam juntas no treino ou no teste. O n é o preço de três preditoras elegíveis, intervalo clínico observado e QC; reduz a amostra e impede follow-up incompleto ou informação pós-desfecho de facilitar a tarefa.

Não existe uma coorte única de 243 participantes (153/90) com $\text{gap} \geq 6$ — esse era o protocolo legado. Demografia sobretudo em 36m_6m ($n = 231$). Nomes de atributos, clínico, leaky e CN×AD em 48m_12m ($n = 120$). A fusão tardia (três especificações) corre nas quatro células.

Distinguem-se operações *fixas por imagem* de operações *dependentes da amostra*. Pré-processamento, parcelamento, registro e extração correm uma vez por volume, com algoritmos, referências e software fixos; não usam o rótulo

sMCI/pMCI nem parâmetros estimados ao agrupar as duas classes. Filtros de correlação/variância, z -score, selecção, hiperparâmetros e limiar de Youden ajustam-se só no treino externo e aplicam-se ao teste da mesma dobra. Limites de QC e templates CN calculam-se uma vez antes da CV.

2.8.1. Métrica primária e estimadores de AUC

2.8.2. Métricas de avaliação

Seja $s_{ir} \in [0, 1]$ a única probabilidade OOF do participante i na repetição $r \in \{1, \dots, R\}$ com $R = 10$, obtida concatenando os cinco folds de teste externos disjuntos dessa repetição. Escreva-se $\text{AUC}(\{(y_k, t_k)\})$ para a AUC de Mann–Whitney de qualquer colecção de scores comparáveis $\{t_k\}$. Dois resumos ao nível da repetição distinguem-se do estimador primário:

$$\widehat{\text{AUC}}^{(r)} = \text{AUC}(\{(y_i, s_{ir})\}_{i=1}^n), \quad \overline{\text{AUC}} = \frac{1}{R} \sum_{r=1}^R \widehat{\text{AUC}}^{(r)}. \quad (4)$$

O estimador primário medeia primeiro as probabilidades,

$$\bar{s}_i = \frac{1}{R} \sum_{r=1}^R s_{ir}, \quad \widehat{\text{AUC}}_{\text{agg}} = \text{AUC}(\{(y_i, \bar{s}_i)\}_{i=1}^n), \quad (5)$$

e depois expande a forma de Mann–Whitney de $\widehat{\text{AUC}}_{\text{agg}}$. Seja $s_i \equiv \bar{s}_i$, $n_+ = \sum_i y_i$ e $n_- = n - n_+$. O estimando primário foi

$$\text{AUC}_{\text{patient}} \equiv \widehat{\text{AUC}}_{\text{agg}} = \frac{1}{n_+ n_-} \sum_{i: y_i=1} \sum_{j: y_j=0} (\mathbb{I}(s_i > s_j) + \frac{1}{2} \mathbb{I}(s_i = s_j)), \quad (6)$$

em que $\mathbb{I}(\cdot)$ é a função indicadora. Quatro resumos relacionados mantêm-se conceptualmente distintos. Uma AUC de fold calcula-se só num fold de teste externo; a sua média e desvio-padrão descrevem variação entre os 50 modelos de fold e *não* são a incerteza amostral de $\widehat{\text{AUC}}_{\text{agg}}$. Concatenar os cinco folds retidos numa repetição produz $\{s_{ir}\}_{i=1}^n$ e portanto $\widehat{\text{AUC}}^{(r)}$ na Eq. (8). A AUC paciente primária é $\widehat{\text{AUC}}_{\text{agg}}$ nas Eqs. (9)–(10), estimador distinto de $\overline{\text{AUC}}$. Como resumo de sensibilidade, a AUC *pooled* concatena todas as predições retidas de todas as repetições antes de calcular a AUC, retendo R registos por participante em vez

de os mediar. Intervalos de confiança bootstrap e testes pareados calcularam-se sobre os scores agregados $\{\bar{s}_i\}$, não sobre o desvio-padrão entre folds. Para métricas dependentes de limiar, o ponto de operação τ escolheu-se nos scores OOF do *outer-training* maximizando o índice de Youden,

$$J(\tau) = \text{TPR}(\tau) + \text{TNR}(\tau) - 1, \quad \tau^* = \arg \max_{\tau \in [0,1]} J(\tau), \quad (7)$$

em que TPR e TNR são as taxas de verdadeiros positivos e verdadeiros negativos. Todos os classificadores avaliados produziram probabilidades via `predict_proba` (SVM após escala de Platt com `probability=True`); scores de `decision_function` nunca serviram para limiar. O domínio de procura permaneceu $\tau \in [0, 1]$, não $\tau \in \mathbb{R}$. Um limiar de Youden τ^* distinto foi ajustado em cada fold externo a partir das OOF do treino desse fold e aplicado só ao teste correspondente. Acurácia, sensibilidade, especificidade e F1 calcularam-se portanto por fold, com limiares próprios, e resumiram-se como média $\pm$ DP nas 50 avaliações externas. Quando se agregaram contagens de confusão, concatenaram-se predições binárias já produzidas sob o τ^* de cada fold; nunca se reestimou um limiar global em scores misturados de folds diferentes. Constantes fixas da análise: semente 42; filtro de correlação $|\rho| > 0,85$ (uma vez no *outer-training*; pares T1/D21/D32 com a mesma chave anatômica não se eliminam mutuamente); filtro de variância $< 0,01$; pool de estabilidade ℓ_1 com $B = 50$ réplicas bootstrap ordinárias, $C = 0,1$ e frequência mínima $\pi = 70\%$ (`stable-pool-min-pct=70`); `stable-pool-min-timepoints=0`. O sintonizador primário foi Optuna TPE (`optuna-trials=10`), não grelha exaustiva.

Métrica primária: AUC no paciente sobre probabilidades OOF médias por sujeito. Em cada repetição $r \in \{1, \dots, R\}$ ($R = 10$), os cinco testes externos disjuntos cobrem cada participante exatamente uma vez e devolvem $s_{ir} = \widehat{\Pr}(y = 1 \mid x_i)$ via `predict_proba` (SVM: Platt). Agrega-se a média de todos os scores OOF do sujeito (fold $\times$ repeat); com folds disjuntos isso coincide com a média das $R = 10$ probabilidades. Seja $\text{AUC}(\{(y_k, t_k)\})$ a AUC de

Mann-Whitney (`roc_auc_score`; empates a 1/2).

$$\widehat{\text{AUC}}^{(r)} = \text{AUC}(\{(y_i, s_{ir})\}_{i=1}^n), \quad \overline{\text{AUC}} = \frac{1}{R} \sum_{r=1}^R \widehat{\text{AUC}}^{(r)}. \quad (8)$$

O estimador primário média primeiro as probabilidades calibradas,

$$\bar{s}_i = \frac{1}{R} \sum_{r=1}^R s_{ir}, \quad \widehat{\text{AUC}}_{\text{agg}} = \text{AUC}(\{(y_i, \bar{s}_i)\}_{i=1}^n), \quad (9)$$

ou, com $s_i \equiv \bar{s}_i$, $n_+ = \sum_i y_i$ e $n_- = n - n_+$,

$$\text{AUC}_{\text{patient}} \equiv \widehat{\text{AUC}}_{\text{agg}} = \frac{1}{n_+ n_-} \sum_{i: y_i=1} \sum_{j: y_j=0} (\mathbb{I}(s_i > s_j) + \frac{1}{2} \mathbb{I}(s_i = s_j)). \quad (10)$$

Quatro resumos distintos: (i) AUC de *uma* dobra externa (média±SD das 50 descreve variação entre modelos, **não** é incerteza de $\widehat{\text{AUC}}_{\text{agg}}$); (ii) $\widehat{\text{AUC}}^{(r)}$ da repetição; (iii) $\widehat{\text{AUC}}_{\text{agg}}$, o primário; (iv) AUC *pooled*: concatena as R previsões por sujeito sem as mediar (sensibilidade). O SD nas tabelas de ponto é o desvio bootstrap de $\widehat{\text{AUC}}_{\text{agg}}$ (2000 reamostragens na compilação das planilhas), não o SD das 50 dobras. IC95% e testes de ΔAUC usam bootstrap pareado nos $\{\bar{s}_i\}$ ($B_{\text{boot}} = 5000$).

Métricas com limiar usam Youden no treino externo,

$$J(\tau) = \text{TPR}(\tau) + \text{TNR}(\tau) - 1 = \text{TPR}(\tau) - \text{FPR}(\tau), \quad \tau^* = \arg \max_{\tau} J(\tau). \quad (11)$$

Os classificadores devolvem `predict_proba` (SVM: Platt com `probability=True`); não se limiariza `decision_function`. τ^* é o limiar da curva ROC (`roc_curve`) que maximiza J nas OOF `predict_proba` do treino externo (`cross_val_predict` no CV interno) e aplica-se só ao teste correspondente. Acurácia, sensibilidade, especificidade e F1: média±SD nas 50 avaliações. A AUC primária não usa limiar.

Constantes: semente 42 (repetição r : $42 + 1000r$; inner-fold: $42 + 1000r + \text{fold}$); $k_{\text{out}} = k_{\text{in}} = 5$; $|\rho| > 0.85$; variância < 0.01 ; $\tau = 70\%$ em π_g (grupo, não coluna); $B = 50$ bootstraps; $C = 0.1$ na L1 de rastreio; `stable-pool-min-timepoints=0`. (**Não** $\theta = 0.50$.)

2.8.3. Classificadores e análises comparativas

O classificador primário foi uma SVM com núcleo linear ou de base radial (RBF) (Cortes and Vapnik, 1995), escolhido na validação interna. A SVM foi ajustada com `probability=True`; os valores de decisão converteram-se em probabilidades pela escala de Platt interna do `SVC`. Esta calibração reajustou-se em cada treino, incluindo os ajustes que geram OOF do *outer-training* e o ajuste final na partição completa de treino externo. Pacientes de teste externo nunca entraram na calibração. Os scores reportados da SVM vieram de `predict_proba`, não de `decision_function`. Esta escolha foi pré-especificada e define o estimando inferencial principal. A selecção de atributos usou sempre filtragem por frequência de selecção ℓ_1 em bootstrap, independente do classificador a jusante, separando o rastreio esparsa da regra de decisão. A SVM é também a referência convencional em estudos ADNI de volume hipocampal (Cuingnet et al., 2011). Florestas aleatórias (RF) (Breiman, 2001) e regressão logística elastic-net (Zou and Hastie, 2005) ficaram só em análises exploratórias de ranking e sensibilidade, não no endpoint primário. O endpoint volumétrico pré-especificado ilustra-se na Figura ?? . NeuroComBat por fold reservou-se a análises de sensibilidade; o endpoint primário é `combat false`. As análises comparativas oficiais foram: (i) cinco famílias unimodais (volume, forma, textura GLCM, primeira ordem, deslocamento) em `t1_only` versus a representação longitudinal Q4 `t1_d21_d32` (níveis T1, D21 e D32 concatenados; **não** diferenças $T_b - T_a$, nem `wide/abs/t1_deltas`); (ii) fusão *late* de cinco SVMs (média de scores), com três especificações: todas as famílias em `t1_only`; todas em Q4; âncora `shape:t1_only` e as restantes em Q4; (iii) as quatro coortes de janela. Não se usou fusão *early* (`-modality all`) no paper. Preditores clínicos da primeira visita (sexo, idade, MMSE, ADAS, FAQ) e a sua concatenação com imagem ficaram em análises extra. Os experimentos prognósticos usaram dez repetições de CV estratificada de cinco folds (50 avaliações externas), com a mesma semente, de modo que `t1_only` e Q4 partilham as partições externas. A inferência estatística usou as probabilidades OOF mediadas por paciente. Testes contra

o acaso foram permutações de rótulos sobre estes scores congelados: o vector de desfecho foi baralhado $B_{\text{perm}} = 5000$ vezes com os scores fixos; o pipeline aninhado (selecção, escala, sintonização, reajuste) *não* se reexecutou em cada permutação. O p unilateral usou $p = (r + 1)/(B_{\text{perm}} + 1)$, em que r é o número de permutações com AUC pelo menos tão grande como a observada. Contrastes pareados de protocolo (p.ex. Q4 versus `t1_only`) usaram bootstrap pareado ao nível do paciente da diferença de AUC, com $B_{\text{boot}} = 5000$ reamostragens de participantes com reposição, intervalos de confiança percentis a 95% e a mesma correcção $(r + 1)/(B_{\text{boot}} + 1)$ para o p bootstrap. As quantidades reamostradas foram os scores pareados por paciente das duas configurações, não AUCs de fold. Como a superioridade direccional do pipeline longitudinal não foi pré-registada, os p bootstrap bilaterais trataram-se como primários; os unilaterais só como sensibilidade. Quando cinco modalidades se testaram em conjunto, calcularam-se q -valores FDR de Benjamini–Hochberg sobre os p bilaterais e reportaram-se explicitamente.

Todos os contrastes reportados usam o **mesmo** SVM [Cortes and Vapnik \(1995\)](#). O objecto do estudo é o biomarcador (família $\times$ representação temporal $\times$ união tardia), não uma arquitectura nova de aprendizagem. Fixar o classificador isola esses contrastes de vieses algorítmicos (capacidade, regularização implícita, importância de atributos). O SVM é o padrão em discriminação ADNI com p da ordem de n e n moderado [Cuingnet et al. \(2011\)](#): margem máxima, kernels linear ou RBF, resistente a $p \approx n$. Na célula mais apertada (36m_12m, 33 pMCI) um ensemble não linear decoraria ruído de treino; não se varre RF, elastic-net nem redes. O modo `l1_stable` corre a *montante* do SVM e não é o stability selection clássico (sem PFER; Sec. [3.12](#)).

Kernel linear ou RBF escolhido no CV interno. Optuna TPE, 10 ensaios, semente da dobra, maximiza a AUC média interna — não grid search. $C \in [10^{-2}, 10]$ (log), $\gamma = \text{scale}$, `class_weight` $\in \{\text{None}, \text{balanced}\}$, `max_iter` = 2000. Calibração Platt reajustada em cada fit de treino (OOF do treino externo e fit final no treino completo); o teste externo não entra na calibração.

Comparações oficiais: (i) Q4 versus `t1_only` nas cinco famílias, nas quatro

coortes; (ii) fusão tardia em três especificações pré-especificadas (tudo t_0 ; tudo Q4; âncora $\text{forma}@t_0 \cup \text{restante Q4}$). Extra em 48m_12m, mesmo SVM: clínico de t_0 ; clínica+forma **t1_only**; CN×AD (sanidade); leaky (apêndice). A fusão precoce entre famílias de imagem (**-modality all**) **não** entra: concatena classes completas e reproduz $p \gg n$.

Inferência sobre $\{\bar{s}_i\}$. Teste contra o acaso: permutação de rótulos $B_{\text{perm}} = 5000$ com scores congelados — a pipeline nested **não** se reexecuta. $p = (r + 1)/(B_{\text{perm}} + 1)$. Contrastes pareados (Q4 vs **t1_only**; late vs teto unimodal): bootstrap de participantes $B_{\text{boot}} = 5000$, IC percentílico 95%, mesma correcção $(r + 1)/(B + 1)$. As duas representações partilham o protocolo 10×5 ; o emparelhamento é nos scores agregados por paciente, não nas AUCs de dobra. No contraste temporal unimodal, o p (quando reportado) é **unilateral** (H_1 : $\text{AUC}(\text{Q4}) > \text{AUC}(\text{t1_only})$); o q é FDR de Benjamini–Hochberg nas **cinco** famílias da mesma coorte. p bilateral reserva-se a contrastes sem direcção pré-especificada (p.ex. imagem vs clínico). Os pontos das Tabelas 8–11 são $\widehat{\text{AUC}}_{\text{agg}}$; testes pareados do Δ ficam para a compilação estatística sobre estes CSVs e não se herdaram do protocolo **t1_deltas**.

2.9. Validação aninhada no paciente

2.10. Validação aninhada ao nível do paciente e âmbito do ajuste por fold

Os modelos prognósticos avaliaram-se com CV aninhada ao nível do paciente, para limitar fugas de informação na fase de modelação (Figura 2). Embora a matriz de modelação use uma linha larga por participante (três visitas já concatenadas como colunas em Q4; uma visita em **t1_only**), os folds definem-se pelo identificador do participante, não pela imagem nem pela linha, de modo que T_1 , T_2 e T_3 do mesmo sujeito nunca atravessam treino e teste. Esta partição é a salvaguarda padrão contra fuga longitudinal. Um ciclo externo estratificado de cinco folds (cerca de 80%/20%) repetiu-se dez vezes com sementes derivadas da semente 42, rendendo 50 avaliações externas por configuração. Os efectivos exactos de treino/teste por fold dependem da coorte e da estratificação (153 e 90 não são divisíveis por 5 no draft de 36 meses; actualizar com o n real). Dentro de

cada fold externo, NeuroComBat opcional e a selecção de atributos ajustaram-se só nos pacientes de treino. O pool de frequência de selecção construiu-se uma vez nessa partição, com até $B = 50$ réplicas bootstrap, segundo as Eqs. (14)–(15). Os hiperparâmetros do classificador a jusante sintonizaram-se no treino externo com um ciclo interno estratificado de cinco folds via Optuna TPE (configuração primária; grelha só como alternativa de implementação). Em cada split interno, filtros de correlação e variância e o z -score reajustaram-se nos dados de treino interno restritos ao pool; o pool **não** se reconstruiu em cada split interno. O pipeline seleccionado reajustou-se no conjunto completo de treino externo; cada fold externo obteve o seu τ^* (Eq. 11) a partir das OOF de treino, aplicado só aos pacientes de teste desse fold. Dentro de cada repetição, os cinco folds de teste concatenaram-se para um vector OOF completo com exactamente uma predição por participante. As dez probabilidades por participante mediavam-se antes da AUC paciente primária na Eq. (10). A AUC pooled, sem média por paciente, reteve-se só como estimador de sensibilidade. O procedimento aninhado cobriu portanto todas as operações de modelação dependentes da amostra, mas não o processamento de imagem fixo, o QC nem os templates normativos descritos acima.

CV aninhada no identificador do paciente (**StratifiedKFold**). A matriz de classificação é uma linha por paciente (colunas T1/D21/D32 já no wide da representação); as dobras partem-se por paciente, não por imagem: as três visitas do mesmo i ficam todas no treino ou todas no teste. Loop externo: $k_{\text{out}} = 5 \text{ folds} \times R = 10 \text{ repetições} = 50 \text{ avaliações por configuração}$. Semente da repetição r : $42 + 1000r$; o **StratifiedKFold** externo usa essa semente. Loop interno, em cada dobra externa: $k_{\text{in}} = 5$, semente $42 + 1000r + \text{fold}$.

Por dobra externa, nesta ordem, só no treino:

1. Pool **l1_stable**: constrói-se **uma vez** neste treino externo ($B = 50$; Sec. 3.12); **não** se reconstrói em cada split interno.
2. Pipeline sklearn: **CorrVarSelector** (correlação $|\rho| > 0.85$ depois variância < 0.01 , restrito ao pool) $\rightarrow$ **StandardScaler** $\rightarrow$ **SVM** (**probability=True**).




Figura 2: Validação cruzada aninhada ao nível do paciente.

3. Optuna TPE, 10 ensaios, maximiza a AUC média das cinco inner-folds (scores `predict_proba`).
4. τ^* (Eq. 11) estima-se com `cross_val_predict` no treino externo (mesmo k_{in}) e aplica-se só ao teste desta dobra.
5. A pipeline vencedora refaz-se no treino externo completo (filtros, z -score e Platt reajustados); o teste recebe só `transform/predict_proba`.

No split interno, `CorrVarSelector` e `StandardScaler` **reajustam-se** no inner-train, restritos ao pool da dobra; o L1 de rastreio não corre de novo. Se os filtros internos zerarem o espaço, o `CorrVarSelector` devolve o pool (não a classe inteira). A nested cobre o modelamento sample-dependent (pool `l1_stable`, filtros, z -score, hiperparâmetros, Youden, Platt). Não cobre pré-processamento de imagem, QC nem templates CN — esses correm uma vez antes da CV.

2.11. Normalização e selecção de atributos

Os atributos volumétricos por ROI hipocampal usados na prognose foram as fracções teciduais *dentro da ROI* (`gm_norm`, `wm_norm`, `csf_norm`) e o volume de malha `original_shape_MeshVolume`, este último já dividido pelo ICV no pós-processamento. Os volumes absolutos em mm^3 (`mask_mm3`, `gm_mm3`, etc.) não entram nos modelos volumétricos. Descritores de tamanho radiômicos (malha, eixos, área de superfície) também se normalizam pelo ICV no armazém longo; as fracções teciduais **não** se renormalizam pelo ICV. Forma (exceto malha/voxel, que ficam no bloco volume), textura GLCM, primeira ordem e deslocamento usam os descritores da denylist de definição, sem segunda correcção de ICV ao nível do classificador.

As tabelas longitudinais pivotam-se para uma linha por participante. No protocolo longitudinal oficial Q4 (`t1_d21_d32`), os atributos hipocampais de T_1 , D21 e D32 concatenam-se como colunas distintas (níveis nas três visitas, **não** diferenças $T_b - T_a$). O controlo de primeira visita (`t1_only`) usa só as colunas de T_1 . As modalidades avaliaram-se **individualmente** (volume, forma, textura, deslocamento, primeira ordem) e, em análises multimodais oficiais, por fusão *late* (cinco SVMs, média de scores), **não** por concatenação *early* de todas

as famílias. Todos os experimentos de imagem restringiram-se ao hipocampo bilateral.

Utilizou-se um filtro descritivo de frequência de selecção ℓ_1 derivado de bootstrap, relacionado com ideias de selecção por reamostragem (Bach, 2008; Meinshausen and Bühlmann, 2010), mas **não** o procedimento clássico de *stability selection* de Meinshausen and Bühlmann (2010) e, portanto, sem a garantia de Per-Family Error Rate (PFER). Para cada partição de treino externo, padronizaram-se as colunas (`StandardScaler` só nessa amostra) e aplicaram-se **uma vez** filtros de correlação ($|\rho| > 0,85$) e de variância ($< 0,01$), com prioridade pelo $|\text{correlação}|$ com o rótulo; pares T1/D21/D32 com a mesma chave anatômica nunca se eliminam mutuamente. Estes limiares foram fixados *a priori* como higiene para remover colunas redundantes e ruído quase constante antes do rastreio ℓ_1 , reduzindo o espaço de procura e o custo; **não** foram sintonizados no ciclo Optuna interno. Sobre o espaço já podado, em cada uma de $B = 50$ réplicas amostraram-se n_{train} índices **com reposição** (bootstrap clássico; duplicados **não** se colapsam). Réplicas com uma só classe de desfecho foram saltadas. O procedimento não foi estratificado e não usou pesos de classe. Em cada réplica retida, os candidatos restantes foram rastreados com regressão logística penalizada em ℓ_1 ,

$$\hat{\beta}^{(b)} = \arg \min_{\beta} \left\{ - \sum_{i=1}^{n_{\text{train}}^{(b)}} \left[y_i \log p_i^{(b)} + (1 - y_i) \log (1 - p_i^{(b)}) \right] + \lambda \|\beta\|_1 \right\}, \quad (12)$$

$$p_i^{(b)} = \sigma(\mathbf{x}_i^\top \beta),$$

em que $\sigma(\cdot)$ é a sigmóide logística, $\mathbf{x}_i$ o vector de atributos do paciente i na matriz larga de treino externo (já filtrada), e $n_{\text{train}}^{(b)}$ o número de linhas da réplica b (igual a n_{train} , com possíveis pacientes repetidos). A regressão de selecção usou o *solver* **SAGA** do scikit-learn com um único valor de regularização inversa $C = 0,1$ em todas as réplicas; não houve grelha de C nem CV interna nesta etapa. Este parâmetro de rastreio é distinto dos hiperparâmetros do classificador a jusante, sintonizados por Optuna na CV interna. Seja $\mathcal{M}^{(b)} = \{j : |\hat{\beta}_j^{(b)}| > 10^{-9}\}$ o conjunto activo na réplica b . Se um ajuste ℓ_1 não produziu nenhum

coeficiente activo, essa réplica **não** entra em B_{eff} (não há fallback “manter todas as colunas do filtro”). A frequência de selecção bootstrap do atributo j foi

$$\pi_j = \frac{1}{B_{\text{eff}}} \sum_{b=1}^{B_{\text{eff}}} \mathbb{I}(j \in \mathcal{M}^{(b)}), \quad (13)$$

em que $B_{\text{eff}} \leq 50$ é o número de réplicas biclasse com conjunto activo não vazio. As colunas específicas de visita agruparam-se por ROI, hemisfério e nome-base do atributo após remoção do prefixo temporal (chave anatômica; p.ex. `hippocampus_L_T1_gm_norm` e `hippocampus_L_D21_gm_norm` partilham o mesmo grupo). Para o grupo g , seja $\mathcal{C}_g$ o conjunto das suas colunas temporais disponíveis. A frequência ao nível do grupo definiu-se como $\pi_g = B_{\text{eff}}^{-1} \sum_{b=1}^{B_{\text{eff}}} \mathbb{I}(\mathcal{M}^{(b)} \cap \mathcal{C}_g \neq \emptyset)$. Um grupo entrou no pool quando $\pi_g \geq \theta$, com $\theta = 70\%$ (`stable-pool-min-pct=70`), e **todas** as suas colunas de visita disponíveis passaram à filtragem e classificação posteriores por fold. Não se exigiu estabilidade em duas ou mais visitas (`stable-pool-min-timepoints=0`). Na representação `t1_only`, $\mathcal{C}_g$ contém só a coluna T_1 correspondente. Se nenhum grupo atingiu θ , o código **não** restaura a classe completa: primeiro tenta o fallback das colunas que sobreviveram ao corr/var (`corr_fallback`); se esse conjunto também for vazio, retém a única coluna de maior variância no treino externo (`var_fallback`), para evitar matriz de desenho vazia sem reintroduzir todo o espaço original. A implementação não persistiu os tamanhos dos conjuntos activos por réplica, pelo que a sua média não se reporta retrospectivamente sem rerodar a etapa de selecção.

2.12. Selecção de atributos (`l1_stable`)

Volume prognóstico: fracções teciduais *dentro da ROI* e `original_shape_MeshVolume` já /ICV. Deslocamento não leva ICV. Tabelas long $\rightarrow$ uma linha por paciente; só hipocampo L/R. Representações oficiais: `t1_only` e Q4 (`t1_d21_d32`). A chave `anatomical_key` colapsa o instante: ROI + lado + basename (T1/D21/D32 retirados). Exemplo: `hippocampus_L_T1_gm_norm` e `hippocampus_L_D21_gm_norm` partilham a mesma chave.

Todos os números reportados usam o modo `l1_stable`. É um filtro descritivo de frequência ℓ_1 por bootstrap [Bach \(2008\)](#); [Meinshausen and Bühlmann \(2010\)](#):

não é o stability selection clássico e **não** herda PFER. Por dobra externa o modo corre **uma vez** no outer-train e devolve um *pool* de colunas; o SVM nunca vê a classe completa. O CV interno **não** reconstrói este pool — só reajusta `CorrVarSelector` e `StandardScaler` restritos a ele.

Cadeia no outer-train, pela ordem:

1. *z*-score de **todas** as colunas no outer-train (média e DP só deste treino).
2. Correlação $|\rho| > 0.85$ *uma vez*, greedy: em cada par colinear fica a coluna de maior $|\text{corr}(x, y)|$ com o rótulo y . Pares com o mesmo `anatomical_key` (T1 vs D21 vs D32 do mesmo descritor) **nunca** se removem nesta poda — o filtro não trata tempos do mesmo biomarcador como mecanismos rivais.
3. Limiar de variância < 0.01 nas colunas já *z*-score; se o filtro zerar o espaço, retêm-se colunas com $\text{var} > 0$ (**não** se restaura a classe).
4. $B = 50$ amostras com reposição sobre o espaço já podado. Réplica com uma só classe: descartada. Cada réplica biclasse: *z*-score *da própria amostra* e logística ℓ_1

$$\hat{\beta}^{(b)}, \hat{\beta}_0^{(b)} = \arg \min_{\beta, \beta_0} \left\{ \sum_{i=1}^{n_{\text{train}}^{(b)}} \ell(y_i, \sigma(\mathbf{x}_i^\top \beta + \beta_0)) + C^{-1} \|\beta\|_1 \right\}, \quad (14)$$

$$\ell(y, p) = -y \log p - (1 - y) \log(1 - p),$$

solver SAGA, $C = 0.1$ fixo (sklearn: C inverso da força; intercepto β_0 sem penalidade ℓ_1). $\mathcal{M}^{(b)} = \{j : |\hat{\beta}_j^{(b)}| > 10^{-9}\}$. Réplica com $\mathcal{M}^{(b)} = \emptyset$: descartada (não entra em B_{eff} ; não é keep-filters).

A frequência é **por grupo**, não por coluna. $B_{\text{eff}} \leq 50$ conta só réplicas biclasse com $\mathcal{M}^{(b)} \neq \emptyset$. O grupo g conta na réplica b se *alguma* coluna de g está em $\mathcal{M}^{(b)}$:

$$\pi_g = \frac{1}{B_{\text{eff}}} \sum_{b=1}^{B_{\text{eff}}} \mathbb{I}(g \cap \mathcal{M}^{(b)} \neq \emptyset). \quad (15)$$

Com `stable-pool-min-timepoints` = 0, entra no pool todo g com $\pi_g \geq \tau = 0.70$. Se g passa, o pool inclui **todas** as colunas originais desse `anatomical_key` (T1, D21 e D32 quando existem), mesmo as que a L1 não escolheu e as que *corr/var* tinham cortado antes do bootstrap. Por isso Q4 de primeira ordem

tende a $n = 3$ por descritor aceite: o grupo entra e os três instantes voltam juntos.

Se nenhum grupo passa (inclui $B_{\text{eff}} = 0$): *corr_fallback* — nomes que sobreviveram a corr+var no outer-train z -score, nunca a classe inteira. Se esse conjunto também é vazio: *var_fallback* — uma coluna de máxima variância no outer-train bruto. Entre colineares de chaves distintas **l1_stable** escolhe um representante, não o “melhor Haralick”.

Depois do pool, a pipeline sklearn **repete** corr ($|\rho| > 0.85$) depois var (< 0.01), agora nos valores *brutos* do conjunto em que o **fit** corre (inner-train no Optuna; outer-train no fit final), restrita ao pool; em seguida o **StandardScaler**. Se essa segunda poda zerar o espaço, devolve-se o pool, não a classe. O CV interno não reconstrói o bootstrap L1.

2.13. Protocolo de modelagem

Protocolo oficial: SVM com **probability=True** (Platt), **l1_stable**, nested estratificada 5 folds $\times$ 10 repetições (semente 42+1000*r*), 50 avaliações externas. Dobras por identificador de paciente.

Hiperparâmetros.. Optuna TPE, 10 ensaios, AUC média do CV interno. SVM: $C \in [10^{-2}, 10]$ (log), kernel $\in \{\text{linear}, \text{RBF}\}$, $\gamma = \text{scale}$, **class_weight** $\in \{\text{None}, \text{balanced}\}$, **max_iter** = 2000. Um único classificador em todos os contrastes; não se varre RF nem elastic-net.

Youden.. τ^* maximiza $J = \text{TPR} + \text{TNR} - 1$ nas OOF do treino externo e aplica-se só ao teste dessa dobra. A AUC primária não usa limiar.

AUC no paciente.. Média de todos os scores OOF do sujeito (fold $\times$ repeat); com 5 testes disjuntos isso é a média das $R = 10$ probabilidades. Uma AUC de Mann–Whitney nos n pares $(y_i, \bar{s}_i)$ (Eqs. 9–10). O $\pm$ nas tabelas de ponto é o SD bootstrap dessa AUC paciente (2000 reamostragens), **não** o DP das 50 dobras.

2.14. Fusão multimodal e preditores clínicos

Fusão tardia (*late fusion*). A multimodalidade oficial não concatena atributos de famílias distintas num único classificador (*early fusion* / `-modality all`), o que, em Q4, produziria centenas de colunas com n pequeno e misturaria escalas heterogêneas (fracções volumétricas, GLCM, momentos do DVF) num só rastreio ℓ_1 Kittler et al. (1998); Kuncheva (2004). Em vez disso, adoptou-se fusão tardia por média de scores: cada família (volume, forma, textura GLCM, primeira ordem, deslocamento) treina a sua própria SVM sob o mesmo protocolo unimodal (CV aninhada ao nível do paciente, `l1_stable`, `Optuna`, `combat false`), e as probabilidades OOF por paciente são combinadas *a posteriori* Kittler et al. (1998); Dietterich (2000). Assim, a dimensionalidade efectiva cresce com o número de modelos, não com a união do espaço de atributos; a forma não “vê” 144 colunas GLCM, nem o volume compete com first-order no mesmo pool.

Especificações. Três especificações de slots `modalidade:representação` foram pré-definidas (`run_ablation_full.sh`):

- tudo em `t1_only`: `vol:t1_only,shape:t1_only,texture:t1_only,disp:t1_only,firstorder:t1_onl`
- tudo em Q4: as cinco famílias com `t1_d21_d32`;
- âncora: `shape:t1_only` e as restantes em `t1_d21_d32` (default de `DEFAULT_LATE_FUSION_SPEC`).

Cada especificação corre nas quatro coortes de janela. O identificador de protocolo é um *fingerprint* estável do conjunto de slots (`late_{fp}`); a saída grava-se em `ablation_results_late_fusion/{fingerprint}/`.

Implementação. O script `5_ablation_late_fusion.py` invoca `run_late_fusion_ablation_suite`. Por omissão (`-reuse-disk`), cada branch lê o CSV unimodal já gerado (`ablation_results_* / {mod} / ablation_results_all.csv`), filtrado por tarefa, modelo, ComBat e modo de selecção — as mesmas partições externas (semente 42, 10 repetições $\times$ 5 folds) que o mono, para alinhamento fold a fold. Só com `-run-missing` se reexecuta a CV aninhada de uma branch ausente. Exigem-se ≥ 2 branches; a intersecção de chaves (`task`, `model`, `combat`, `selection`, `repeat_id`,

fold) deve ser não vazia (caso contrário o alinhamento temporal/espacial das partições falhou).

Para cada fold comum, as listas `test_id_pts`, `test_y_true` e `test_scores` de cada branch são expandidas e alinhadas por ID_PT (*inner join*): pacientes em falta numa branch saem desse fold. Sejam s_{ik} a probabilidade OOF (`predict_proba`) do paciente i na branch $k = 1, \dots, K$ e pesos $w_k \geq 0$ com $\sum_k w_k = 1$. A configuração primária usa `-combine mean` (pesos uniformes $w_k = 1/K$); `weighted` exige `-weights` explícitos e não entra no claim. O score fundido é

$$\bar{s}_i = \sum_{k=1}^K w_k s_{ik}. \quad (16)$$

Não há meta-classificador empilhado (*stacking*) nem re-treino sobre os scores das branches Wolpert (1992): a fusão é só agregação de decisões probabilísticas já calibradas por Platt em cada SVM.

Métricas e limiar. AUC, average precision e métricas com limiar recalculam-se sobre $\bar{s}_i$ no fold. O limiar binário herdado no CSV late é o threshold da **primeira** branch da especificação (não se reestima Youden sobre $\bar{s}$); a AUC paciente primária depende só das probabilidades mediadas e não desse limiar. A auditoria `selected_features` concatena os atributos escolhidos em todas as branches (soma de cardinalidades em `n_features_*`), para rastreio, sem significar um único espaço concatenado.

Parâmetros do paper (COMMON_FUSION em `run_ablation_full.sh`): `smci_pmci`, `11_stable`, SVM, `combat false`, 10 repetições, Optuna 10 trials, pool $\pi \geq 70\%$, $B = 50$, $C = 0.1$, `stable-pool-min-timepoints=0`, `-combine mean`, `-reuse-disk`.

A fusão tardia **não** retreina um meta-classificador. Reutiliza os scores OOF `predict_proba` dos cinco SVMs unimodais já ajustados no mesmo nested (mesma semente $\Rightarrow$ mesmos splits). Por (repetição r , dobra f), alinhamento inner-join em ID_PT e média simples

$$s_{i,r,f}^{\text{late}} = \frac{1}{5} \sum_{k=1}^5 s_{i,r,f}^{(k)}. \quad (17)$$

A AUC paciente (Eqs. 9–10) calcula-se sobre $\{s_{i,r,f}^{\text{late}}\}$ como nas famílias isoladas. Pesos iguais; sem stacking, sem SVM de segundo nível, sem **weighted**. Cada ramo tem o seu pool **l1_stable**, scaler, Optuna e Platt; forma não vê 144 GLCM e $p \gg n$ da concatenação não se aplica. Três especificações **pré-especificadas** (não escolhidas a posteriori): tudo **t1_only**; tudo Q4; âncora **forma em t1_only $\cup$ volume, textura, deslocamento e primeira ordem em Q4** (cinco ramos, não seis: shape não entra também em Q4). A AUC primária da fusão não usa limiar. Sens/Esp da linha late, se reportadas, herdam o τ^* do primeiro ramo da spec (não se reestima Youden no score médio). A fusão precoce entre famílias de imagem está fora do paper.

Preditores clínicos de t_0 (extra, mesmo SVM): sexo, idade, MMSE, ADAS e FAQ (sem CDR global). A fusão clínica+imagem concatena, no treino externo, esses cinco escores z -score à forma em **t1_only**; um único SVM. O protocolo *leaky* (apêndice) estima z -score, filtros e pool **l1_stable** no conjunto completo antes da CV.

2.15. Métrica primária e papéis do bootstrap

A métrica oficial é a AUC no paciente $\widehat{\text{AUC}}_{\text{agg}}$ (Eqs. 9–10), não a média das 50 AUCs de fold nem a AUC *pooled*. CV aninhada 5×10 no identificador do paciente: em cada repetição r o sujeito i cai uma vez no teste e recebe a probabilidade OOF s_{ir} (**predict_proba**; SVM com Platt). Primeiro tira-se a média,

$$\bar{s}_i = \frac{1}{10} \sum_{r=1}^{10} s_{ir},$$

e calcula-se uma única vez a AUC de Mann–Whitney nos n pares $(y_i, \bar{s}_i)$. A AUC primária não usa limiar de Youden.

Há **três** bootstraps, com papéis separados. Nenhum reexecuta a pipeline nested. A permutação de rótulos **não** é bootstrap.

A. **l1_stable** (*dentro da CV*).. Modo **l1_stable**, uma vez por treino externo: z -score $\rightarrow$ corr 0.85 $\rightarrow$ var 0.01 $\rightarrow B = 50$ L1 (Eqs. 14–15). Frequência π_g por **anatomical_key**; entra o grupo com $\pi_g \geq 70\%$ e **todos** os seus instantes.

Pool vazio $\rightarrow$ `corr_fallback`, nunca a classe inteira. Esse bootstrap **não** estima AUC: só escolhe colunas. Não é o stability selection clássico e não herda PFER [Bach \(2008\)](#); [Meinshausen and Bühlmann \(2010\)](#). Detalhe: Sec. 3.12.

B. Desvio nas tabelas e barras de erro (depois da CV).. Scores congelados $\{\bar{s}_i\}$. $B_{sd} = 2000$ reamostragens de pacientes com reposição; em cada uma recalcula-se $\widehat{AUC}_{agg}$. O $\pm$ reportado (Tabelas 8–11) é o desvio-padrão dessas 2000 AUCs,

$$\hat{\sigma}_{boot} = sd\{\widehat{AUC}_{agg}^{(b)}\}_{b=1}^{B_{sd}},$$

não o DP das 50 folds e **não** um intervalo de confiança a 95%.

C. Inferência do ΔAUC (depois da CV).. Contrastes pareados no mesmo sujeito (p.ex. Q4 vs `t1_only`): $B_{boot} = 5000$ reamostragens,

$$\Delta^{(b)} = \widehat{AUC}_{agg}(A^{(b)}) - \widehat{AUC}_{agg}(B^{(b)}).$$

IC95% percentílico [2,5, 97,5] da distribuição empírica de $\Delta^{(b)}$.

$$p_{unilateral} = \frac{\#\{\Delta^{(b)} \leq 0\} + 1}{B_{eff} + 1} \quad (H_1: AUC_A > AUC_B).$$

p bilateral = $2 \min(p_{uni}, 1 - p_{uni})$, reservado a contrastes sem direção pré-especificada (imagem vs clínico). No contraste temporal unimodal, o q é FDR de Benjamini–Hochberg nos cinco p unilaterais da mesma coorte.

Permutação contra o acaso.. Embaralha-se y com $\{\bar{s}_i\}$ fixos, $B_{perm} = 5000$; $p = (r + 1)/(B_{perm} + 1)$, em que r é o número de permutações com $AUC \geq$ a observada.

$\alpha = 0.05$. O contraste temporal principal é Q4 versus `t1_only` nas cinco famílias, nas quatro coortes. Pontos das tabelas de resultados são $\widehat{AUC}_{agg}$; p/q pareados destes CSVs não se herdaram do protocolo `t1_deltas`.

2.16. Testes estatísticos

Todos os contrastes de AUC usam os scores agregados por paciente, não as AUCs de dobra.

- Permutação de rótulos com scores congelados ($B_{\text{perm}} = 5000$): $p = (r + 1)/(B + 1)$; o pipeline nested **não** se reexecuta.
- Bootstrap pareado do ΔAUC ($B_{\text{boot}} = 5000$), IC percentílico a 95%, p unilateral ($H_1: \text{AUC}_A > \text{AUC}_B$) e bilateral.
- FDR de Benjamini–Hochberg sobre os p unilaterais das cinco famílias, dentro de cada coorte.
- Demografia em 36m_6m: Mann–Whitney na idade, χ^2 no sexo; classifica-dores univariados de idade e de sexo com permutação.

$\alpha = 0.05$.

3. Resultados

Apresentação: **uma matriz para as quatro células**, não quatro relatos paralelos. Protocolo fixo SVM + 11_stable. Métrica: AUC paciente $\widehat{\text{AUC}}_{\text{agg}}$; $\pm$ é SD bootstrap ($B = 2000$). $\Delta = \text{AUC}(\text{Q4}) - \text{AUC}(\text{t1_only})$. Claim multimodal e nomes de atributos: 48m_12m ($n = 120$); o fatorial testa se o padrão se replica.

3.1. Demografia

Em 36m_6m ($n = 231$), idade e sexo não diferem entre sMCI e pMCI (Mann–Whitney $p = 0.071$; χ^2 $p = 0.113$). Classificador só com idade: AUC 0.560; só com sexo: 0.452. A classificação hipocampal não se reduz a demografia (Tabela 3).

3.2. Uniclasse: Q4 versus t1_only nas quatro coortes

A Tabela 8 é o resultado principal unimodal.

Tabela 8: AUC no paciente, SVM. Em cada célula: $t1_only$ / $Q4$ / Δ . Negrito: maior das duas representações naquela família $\times$ coorte. n : 231, 154, 193, 120.

Família	36m_6m			36m_12m			48m_6m			48m_12m		
	t_0	$Q4$	Δ	t_0	$Q4$	Δ	t_0	$Q4$	Δ	t_0	$Q4$	Δ
vol	0.738 ± 0.032	0.752 ± 0.032	+0.014	0.707 ± 0.047	0.687 ± 0.052	-0.019	0.714 ± 0.038	0.759 ± 0.036	+0.045	0.632 ± 0.054	0.662 ± 0.051	+0.030
shape	0.789 ± 0.030	0.795 ± 0.030	+0.006	0.739 ± 0.046	0.732 ± 0.047	-0.006	0.801 ± 0.035	0.797 ± 0.035	-0.004	0.761 ± 0.043	0.755 ± 0.043	-0.006
texture	0.727 ± 0.034	0.739 ± 0.033	+0.012	0.724 ± 0.051	0.745 ± 0.051	+0.021	0.740 ± 0.037	0.759 ± 0.036	+0.019	0.711 ± 0.050	0.762 ± 0.044	+0.052
firstorder	0.752 ± 0.032	0.768 ± 0.031	+0.016	0.741 ± 0.051	0.760 ± 0.050	+0.020	0.773 ± 0.035	0.797 ± 0.033	+0.024	0.719 ± 0.048	0.737 ± 0.048	+0.019
disp	0.628 ± 0.036	0.501 ± 0.039	-0.127	0.476 ± 0.057	0.492 ± 0.056	+0.016	0.609 ± 0.043	0.571 ± 0.043	-0.038	0.524 ± 0.055	0.621 ± 0.052	+0.097

Leitura da matriz..

- **Textura e primeira ordem:** $\Delta > 0$ nas quatro células. Máximo de textura $+0.052$ em `48m_12m` ($0.711 \rightarrow 0.762$).
- **Volume:** $\Delta > 0$ em três células; quebra em `36m_12m` (-0.019).
- **Forma:** teto estático. Q4 nunca ganha de forma material ($|\Delta| \leq 0.006$). Melhor unimodal em `36m_6m/48m_6m/48m_12m` é shape- t_0 (ou empate com textura Q4 no claim: 0.762 vs 0.761).
- **Deslocamento:** fraco. Em intervalos de 12 meses o pool `l1_stable` esvazia-se na maioria das dobras (`corr_fallback`); o Δ positivo em `48m_12m` **não** se interpreta como selecção estável.

Q4 agrega nas famílias de intensidade/volume e **não** passa o teto shape- t_0 de forma consistente.

3.3. Quantos e quais atributos

A Tabela 9 é a média de colunas que o SVM vê após `l1_stable` (50 avaliações). A Tabela 10 lista os grupos com cobertura $\geq 20\%$ em `48m_12m`.

L1 corta a classe a poucas colunas (tipicamente 1–6), excepto deslocamento em 12 meses. Nomes = frequência, não assinatura única: `SurfaceVolumeRatio` e `csf_norm` são estáveis; `InverseVariance` e `Entropy/Uniformity` são os representantes de textura e primeira ordem.

3.4. Multimodal: fusão tardia nas quatro coortes

A Tabela 11 compara as três especificações ao teto unimodal da mesma célula (máximo da Tabela 8).

Late Q4 e âncora superam o teto unimodal nas quatro células. No claim, late t_0 **não** passa o teto (0.761 vs shape- t_0 0.761); quem passa é a união *com* Q4 (0.802). Âncora $\approx$ late Q4: a forma já saturava no baseline; o ganho é empilhar os papéis que se movem no tempo.

Fam.	enc	36m_6m		36m_12m		48m_6m		48m_12m	
		média	faixa	média	faixa	média	faixa	média	faixa
vol	t_0	1.00	1–1	1.18	1–4	1.08	1–2	2.14	1–5
vol	Q4	6.28	5–11	4.98	3–12	6.14	3–9	5.16	3–13
shape	t_0	1.64	1–2	1.76	1–12	2.00	1–3	1.52	1–3
shape	Q4	7.80	3–12	4.08	3–27	7.14	6–12	5.12	3–9
texture	t_0	1.66	1–4	2.22	1–8	1.52	1–3	1.62	1–10
texture	Q4	5.38	3–15	3.74	3–25	5.32	3–12	3.60	3–6
firstorder	t_0	3.00	1–4	1.62	1–7	2.84	2–4	1.00	1–1
firstorder	Q4	10.86	4–15	3.82	3–29	9.92	6–15	3.00	3–3
disp	t_0	1.50	1–2	13.90	1–18	1.42	1–2	15.74	1–18
disp	Q4	4.92	1–10	33.08	1–50	3.72	1–9	41.62	1–50

Tabela 9: Média de atributos seleccionados (min–máx nas 50 dobras). Entra: Tabela 7. Disp em 12 meses: maioria `corr_fallback`.

Família	enc	Grupo	cob. (%)	notas temporais
vol	t_0	R <code>csf_norm</code>	84	T1
vol	t_0	L <code>csf_norm</code>	50	T1
vol	Q4	L <code>csf_norm</code>	84	T1=D21=D32
vol	Q4	R <code>csf_norm</code>	68	T1=D21=D32
shape	t_0	L SurfaceVolumeRatio	68	T1
shape	t_0	R SurfaceVolumeRatio	64	T1
shape	Q4	R SurfaceVolumeRatio	82	$\approx$ três visitas
shape	Q4	L SurfaceVolumeRatio	78	$\approx$ três visitas
texture	t_0	L InverseVariance	62	T1
texture	Q4	L InverseVariance	52	T1=D21=D32
firstorder	t_0 /Q4	L Entropy / Uniformity	42 / 38	Q4: três visitas
disp	t_0 /Q4	momentos <code>mag/logjac/strain_fro</code>	$\sim$ 84–92	<code>corr_fallback</code>

Tabela 10: Grupos retidos em $\geq 20\%$ das 50 avaliações, 48m_12m. Cobertura = fracção de folds com o biomarcador (qualquer visita). Em Q4, T1/D21/D32 do mesmo `anatomical_key` tendem a entrar juntos.

Coorte	Teto uni.	Late t_0	Late Q4	Âncora
36m_6m	0.795	0.808 ± 0.029	0.814 ± 0.028	0.814 ± 0.029
36m_12m	0.760	0.769 ± 0.045	0.793 ± 0.039	0.792 ± 0.041
48m_6m	0.801	0.816 ± 0.035	0.828 ± 0.032	0.833 ± 0.032
48m_12m	0.762	0.761 ± 0.044	0.802 ± 0.040	0.802 ± 0.040

Tabela 11: AUC paciente da fusão tardia (média de cinco SVMs) versus teto unimodal. Âncora: shape@ $t_0 \cup$ vol/texture/disp/firstorder em Q4.

3.5. Clínico, sanidade e literatura

Em 48m_12m, SVM só com sexo, idade, MMSE, ADAS e FAQ em t_0 : 0.812 ± 0.040 . Fusão precoce clínica+forma **t1_only**: 0.843 ± 0.036 . A RM hipocampal isolada não supera o clínico; acrescentá-la sobe o ponto sem ser o claim das perguntas 1–3.

CN versus AD no mesmo stack (volume Q4, 48m_12m): 0.833 ± 0.030 — a tarefa fácil funciona; sMCI/pMCI permanece a difícil. Leaky (volume Q4, selecção global): 0.660 versus nested 0.662.

A Tabela 12 situa o teto unimodal e a fusão tardia face a estudos sMCI/pMCI representativos. Os números **não** são comparáveis: diferem horizonte, ROI, preditores clínicos e validação.

Tabela 12: Comparação indicativa de desempenho prognóstico publicado em sMCI versus pMCI e dos resultados ADNI deste estudo sob validação aninhada no paciente.

Estudo	Base	Atributos	Validação	AUC	Sens / Esp (%)
Bucholz et al. (2023)	NACC	Cognitivo + funcional	3 visitas; CV retido	0.601 $\pm$ 0.054	95.4 $\pm$ 1.8 / 24.7 $\pm$ 12.0
Bucholz et al. (2023)	NACC	Cognitivo + funcional	4 visitas; CV retido	0.756 $\pm$ 0.103	92.9 $\pm$ 4.6 / 58.3 $\pm$ 19.1
Grassi et al. (2019)	ADNI	Sociodemográfico + clínico	Baseline; CV 10 folds	0.88	77.7 / 79.9
Moradi et al. (2015)	ADNI	Densidade de GM (cérebro inteiro)	Baseline; CV 10 folds	0.766	88.9 / 51.6
Moradi et al. (2015)	ADNI	GM (cérebro inteiro) + cognitivo	Baseline; CV 10 folds	0.902	86.7 / 73.6
Ye et al. (2012) [§]	ADNI	Cérebro inteiro + cognitivo	Baseline; stability selection	0.859	— / —
Casanova et al. (2013) [¶]	ADNI	Tecidos (cérebro inteiro) + cognitivo	Baseline; CV aninhada	—	45.8 / 75.5
Guo et al. (2017)	ADNI	Córtex	Baseline; LOOCV	—	85.0 / 84.8
Cuingnet et al. (2011)	ADNI	Volume hipocampal	Baseline; LOOCV	—	62.0 / 69.0
Este trabalho (teto t_0)[†]	ADNI	Forma hipocampal	t_0 ; nested CV (SVM)	0.761 $\pm$ 0.043	70.5 $\pm$ 15.4 / 63.7 $\pm$ 12.7
Este trabalho (Q4 unimodal)	ADNI	Textura GLCM (níveis T1+D21+D32)	3 visitas; nested CV	0.762 $\pm$ 0.044	68.3 $\pm$ 17.8 / 67.3 $\pm$ 15.1
Este trabalho (fusão tardia)[‡]	ADNI	Âncora / late Q4 (5 SVMs)	3 visitas; nested CV	0.802 $\pm$ 0.040	74.2 $\pm$ 18.3 / 66.8 $\pm$ 14.8
Este trabalho	ADNI	Clínico (sexo, idade, MMSE, ADAS, FAQ)	t_0 ; nested CV (SVM)	0.812 $\pm$ 0.040	70.0 $\pm$ 14.2 / 70.9 $\pm$ 14.1
Este trabalho	ADNI	Clínico + forma t_0	nested CV (SVM)	0.843 $\pm$ 0.036	77.1 $\pm$ 13.0 / 73.2 $\pm$ 13.6

Nota: Linhas próprias: coorte 48m_12m ($n = 120$). [†]Teto unimodal de baseline (forma, t1_only). [‡]Fusão tardia; Sens/Esp da linha late Q4 (Youden por dobra). Antes de $\pm$ na AUC: estimando paciente; depois: SD bootstrap (2000). Sens/Esp: média $\pm$ SD nas 50 avaliações externas.

4. Discussão

A pergunta era se níveis longitudinais hipocampais agregam discriminação sMCI/pMCI além do t_0 . A resposta depende do *papel* da família e de uniclasse versus união.

Uniclasse agrega, não passa o teto.. Q4 sobe volume, textura e primeira ordem; a forma já discrimina no t_0 e Q4 é redundante (o filtro de correlação nem deixa T1 competir com D21/D32 do mesmo descritor como se fossem mecanismos distintos). Nenhuma família Q4 substitui de forma consistente o teto shape- t_0 .

União tardia passa o teto.. Cinco SVMs, média de scores: forma não vê 144 GLCM; volume não vê firstorder. Late Q4 e a âncora superam o máximo unimodal nas quatro células. No claim, late só- t_0 empata o teto; o ganho exige os braços Q4. A âncora é o desenho que o unimodal pede: geometria no baseline, o resto no tempo.

Fatorial, não crowning.. As quatro coortes não são réplicas independentes, mas o padrão (shape- t_0 teto; Q4 em texture/FO/vol; late > teto) sobrevive a janela e intervalo. Não se coroa **wide**, deltas nem early fusion.

Atributos.. **l1_stable** reduz a classe a poucos representantes (SurfaceVolumeRatio, **csf_norm**, InverseVariance, Entropy/Uniformity). Frequência across folds, não biomarcador único. Deslocamento em 12 meses cai em **corr_fallback**: DVF normativo continua um negativo útil, não um claim.

Clínico.. Escores de t_0 (0.812) permanecem competitivos face à imagem hipocampal isolada, alinhado com [Grassi et al. \(2019\)](#); [Moradi et al. \(2015\)](#). A RM entra como adjunto; o claim das perguntas 1–3 é interno à imagem.

5. Limitações

- **Uma fonte, caso completo.** Só a ADNI fornece n viável com três RM e rótulo sMCI/pMCI nas janelas 36/48 meses.

- **Soft pMCI.** 46 (intervalos de 6 meses) e 33 (12 meses) têm i_3 igual ao primeiro AD.
- **Sobreposição e n .** Coortes não independentes; 48m_12m tem 120 sujeitos.
- **Q4 são níveis, não taxas.** Não se modela $T_b - T_a$.
- **Fallback L1.** Disp em 12 meses não é pool $\pi \geq 70\%$.
- **Inferência pareada.** Os p/q destes CSVs ainda não substituem a tabela FDR do protocolo `t1_deltas`; os pontos e o Δ são o resultado reportado.
- **ROI única.** Hipocampo de propósito.
- **Operações pré-CV.** QC do MRQy e templates CN estimam-se uma vez no conjunto.

6. Conclusões

Sob validação aninhada no paciente, Q4 (`t1_d21_d32`) **agrega** discriminação unimodal em volume, textura e primeira ordem, mas **não** supera o teto da forma em t_0 . A união tardia das cinco famílias — em especial a âncora `forma@t0` $\cup$ restante Q4 — **supera** esse teto nas quatro células do fatorial ($0.76 \rightarrow 0.80$ em 48m_12m). `l1_stable` retém poucos representantes estáveis, não uma assinatura única. Escores clínicos de t_0 permanecem competitivos; a RM hipocampal é adjunto estrutural. O contributo é o protocolo auditável e esta leitura por papéis, não um classificador novo.

Agradecimentos

A recolha e a partilha dos dados foram financiadas pela Alzheimer’s Disease Neuroimaging Initiative (ADNI).

Financiamento

O presente trabalho foi realizado com apoio da Coordenação de Aperfeiçoamento de Pessoal de Nível Superior – Brasil (CAPES) – Código de Financiamento 001.

Conflito de interesses

Os autores declaram não haver conflito de interesses.

Referências

- Aghajanian, S., Mohammadifard, F. et al., 2025. Longitudinal structural MRI-based deep learning and radiomics features for predicting Alzheimer’s disease progression. *Alzheimer’s Research & Therapy* 17, 1–13. doi:[10.1186/s13195-025-01827-2](https://doi.org/10.1186/s13195-025-01827-2).
- Avants, B.B., Tustison, N.J. et al., 2011. A reproducible evaluation of ANTs similarity metric performance in brain image registration. *NeuroImage* 54, 2033–2044. doi:[10.1016/j.neuroimage.2010.09.025](https://doi.org/10.1016/j.neuroimage.2010.09.025).
- Avants, B.B., Tustison, N.J. et al., 2014. The Insight ToolKit image registration framework. *Frontiers in Neuroinformatics* 8, 1–41. doi:[10.3389/fninf.2014.00044](https://doi.org/10.3389/fninf.2014.00044).
- Bach, F.R., 2008. Bolasso: model consistent Lasso estimation through the bootstrap, in: *Proceedings of the 25th International Conference on Machine Learning*, New York, NY, USA. pp. 33–40. doi:[10.1145/1390156.1390161](https://doi.org/10.1145/1390156.1390161).
- Bouke, M.A., Abdullah, A., 2023. An empirical study of pattern leakage impact during data preprocessing on machine learning-based intrusion detection models reliability. *Expert Systems with Applications* 230, 120715. doi:[10.1016/j.eswa.2023.120715](https://doi.org/10.1016/j.eswa.2023.120715).
- Breiman, L., 2001. Random Forests. *Machine Learning* 45, 5–32. doi:[10.1023/A:1010933404324](https://doi.org/10.1023/A:1010933404324).

- Bucholz, M., Titarenko, S. et al., 2023. A hybrid machine learning approach for prediction of conversion from mild cognitive impairment to dementia. *Expert Systems with Applications* 217, 119541. doi:[10.1016/j.eswa.2023.119541](https://doi.org/10.1016/j.eswa.2023.119541).
- Casanova, R., Hsu, F.C. et al., 2013. Alzheimer’s Disease Risk Assessment Using Large-Scale Machine Learning Methods. *PLOS ONE* 8, 1–13. doi:[10.1371/journal.pone.0077949](https://doi.org/10.1371/journal.pone.0077949).
- Cortes, C., Vapnik, V., 1995. Support-vector networks. *Machine learning* 20, 273–297. doi:[10.1007/BF00994018](https://doi.org/10.1007/BF00994018).
- Cuingnet, R., Gerardin, E. et al., 2011. Automatic classification of patients with Alzheimer’s disease from structural MRI: A comparison of ten methods using the ADNI database. *NeuroImage* 56, 766–781. doi:[10.1016/j.neuroimage.2010.06.013](https://doi.org/10.1016/j.neuroimage.2010.06.013).
- Dietterich, T.G., 2000. Ensemble methods in machine learning, in: *International workshop on multiple classifier systems*, Berlin, Heidelberg. pp. 1–15.
- Fonov, V., Evans, A. et al., 2009. Unbiased nonlinear average age-appropriate brain templates from birth to adulthood. *NeuroImage* 47, S102. doi:[10.1016/S1053-8119\(09\)70884-5](https://doi.org/10.1016/S1053-8119(09)70884-5). organization for Human Brain Mapping 2009 Annual Meeting.
- Fonov, V., Evans, A.C. et al., 2011. Unbiased average age-appropriate atlases for pediatric studies. *NeuroImage* 54, 313–327. doi:[10.1016/j.neuroimage.2010.07.033](https://doi.org/10.1016/j.neuroimage.2010.07.033).
- Fortin, J., Cullen, N. et al., 2018. Harmonization of cortical thickness measurements across scanners and sites. *NeuroImage* 167, 104–120. doi:[10.1016/j.neuroimage.2017.11.024](https://doi.org/10.1016/j.neuroimage.2017.11.024).
- Grassi, M., Rouleaux, N. et al., 2019. A Novel Ensemble-Based Machine Learning Algorithm to Predict the Conversion From Mild Cognitive Impairment

- to Alzheimer’s Disease Using Socio-Demographic Characteristics, Clinical Information, and Neuropsychological Measures. *Frontiers in Neurology* 10, 1–15. doi:[10.3389/fneur.2019.00756](https://doi.org/10.3389/fneur.2019.00756).
- van Griethuysen, J., Fedorov, A. et al., 2017. Computational Radiomics System to Decode the Radiographic Phenotype. *Cancer Research* 77, e104–e107. doi:[10.1158/0008-5472.CAN-17-0339](https://doi.org/10.1158/0008-5472.CAN-17-0339).
- Guo, S., Lai, C. et al., 2017. Conversion Discriminative Analysis on Mild Cognitive Impairment Using Multiple Cortical Features from MR Images. *Frontiers in Aging Neuroscience* 9, 1–14. doi:[10.3389/fnagi.2017.00146](https://doi.org/10.3389/fnagi.2017.00146).
- Jack Jr., C.R., Bernstein, M.A. et al., 2008. The Alzheimer’s disease neuroimaging initiative (ADNI): MRI methods. *Journal of Magnetic Resonance Imaging* 27, 685–691. doi:[10.1002/jmri.21049](https://doi.org/10.1002/jmri.21049).
- Kittler, J., Hatef, M. et al., 1998. On Combining Classifiers. *IEEE Transactions on Pattern Analysis and Machine Intelligence* 20, 226–239. doi:[10.1109/34.667881](https://doi.org/10.1109/34.667881).
- Kuncheva, L.I., 2004. *Combining Pattern Classifiers: Methods and Algorithms*. USA. Wiley-Interscience.
- Lin, Y., Huang, K. et al., 2020. Predicting the progression of mild cognitive impairment to Alzheimer’s disease by longitudinal magnetic resonance imaging-based dictionary learning. *Clinical Neurophysiology* 131, 2429–2439. doi:[10.1016/j.clinph.2020.07.016](https://doi.org/10.1016/j.clinph.2020.07.016).
- Manjón, J.V., Coupé, P. et al., 2010. Adaptive non-local means denoising of MR images with spatially varying noise levels. *Journal of Magnetic Resonance imaging* 31, 192–203. doi:[10.1002/jmri.22003](https://doi.org/10.1002/jmri.22003).
- Meinshausen, N., Bühlmann, P., 2010. Stability selection. *Journal of the Royal Statistical Society Series B: Statistical Methodology* 72, 417–473. doi:[10.1111/j.1467-9868.2010.00740.x](https://doi.org/10.1111/j.1467-9868.2010.00740.x).

- Moradi, E., Pepe, A. et al., 2015. Machine learning framework for early MRI-based Alzheimer’s conversion prediction in MCI subjects. *NeuroImage* 104, 398–412. doi:[10.1016/j.neuroimage.2014.10.002](https://doi.org/10.1016/j.neuroimage.2014.10.002).
- Nyul, L., Udupa, J., Zhang, X., 2000. New variants of a method of MRI scale standardization. *IEEE Transactions on Medical Imaging* 19, 143–150. doi:[10.1109/42.836373](https://doi.org/10.1109/42.836373).
- Petersen, R.C., Aisen, P. et al., 2009. Alzheimer’s Disease Neuroimaging Initiative (ADNI). *Neurology* 74, 201–209. doi:[10.1212/wnl.0b013e3181cb3e25](https://doi.org/10.1212/wnl.0b013e3181cb3e25).
- Petersen, R.C., Smith, G.E. et al., 1999. Mild cognitive impairment: clinical characterization and outcome. *Archives of neurology* 56, 303–308. doi:[10.1001/archneur.56.3.303](https://doi.org/10.1001/archneur.56.3.303).
- Reuter, M., Schmansky, N.J. et al., 2012. Within-subject template estimation for unbiased longitudinal image analysis. *NeuroImage* 61, 1402–1418. doi:[10.1016/j.neuroimage.2012.02.084](https://doi.org/10.1016/j.neuroimage.2012.02.084).
- Sadri, A.R., Janowczyk, A. et al., 2020. Technical Note: MRQy — An open-source tool for quality control of MR imaging data. *Medical Physics* 47, 6029–6038. doi:[10.1002/mp.14593](https://doi.org/10.1002/mp.14593).
- Scheltens, P., Leys, D. et al., 1992. Atrophy of medial temporal lobes on MRI in “probable” Alzheimer’s disease and normal ageing: diagnostic value and neuropsychological correlates. *Journal of Neurology, Neurosurgery, and Psychiatry* 55, 967–972. doi:[10.1136/jnnp.55.10.967](https://doi.org/10.1136/jnnp.55.10.967).
- Tukey, J., 1977. *Exploratory Data Analysis*. Addison-Wesley, Reading, MA.
- Tustison, N.J., Avants, B.B. et al., 2010. N4ITK: Improved N3 Bias Correction. *IEEE Transactions on Medical Imaging* 29, 1310–1320. doi:[10.1109/TMI.2010.2046908](https://doi.org/10.1109/TMI.2010.2046908).

- Tustison, N.J., Cook, P.A. et al., 2021. The ANTsX ecosystem for quantitative biological and medical imaging. *Scientific Reports* 11, 1–13. doi:[10.1038/s41598-021-87564-6](https://doi.org/10.1038/s41598-021-87564-6).
- Wolpert, D.H., 1992. Stacked generalization. *Neural Networks* 5, 241–259. doi:[10.1016/S0893-6080\(05\)80023-1](https://doi.org/10.1016/S0893-6080(05)80023-1).
- Wyman, B.T., Harveyb, D.J. et al., 2013. Standardization of analysis sets for reporting results from ADNI MRI data. *Alzheimer’s & Dementia* 9, 332–337. doi:[10.1016/j.jalz.2012.06.004](https://doi.org/10.1016/j.jalz.2012.06.004).
- Ye, J., Farnum, M. et al., 2012. Sparse learning and stability selection for predicting MCI to AD conversion using baseline ADNI data. *BMC Neurology* 12, 1–46. doi:[10.1186/1471-2377-12-46](https://doi.org/10.1186/1471-2377-12-46).
- Yushkevich, P.A., Piven, J. et al., 2006. User-Guided 3D Active Contour Segmentation of Anatomical Structures: Significantly Improved Efficiency and Reliability. *Neuroimage* 31, 1116–1128. doi:[10.1016/j.neuroimage.2006.01.015](https://doi.org/10.1016/j.neuroimage.2006.01.015).
- Zhang, Y., Liu, S., Yu, X., 2019. Longitudinal structural MRI analysis and classification in Alzheimer’s disease and mild cognitive impairment. *International Journal of Imaging Systems and Technology* 30, 421–433. doi:[10.1002/ima.22390](https://doi.org/10.1002/ima.22390).
- Zou, H., Hastie, T., 2005. Regularization and Variable Selection Via the Elastic Net. *Journal of the Royal Statistical Society Series B: Statistical Methodology* 67, 301–320. doi:[10.1111/j.1467-9868.2005.00503.x](https://doi.org/10.1111/j.1467-9868.2005.00503.x).
- Zwanenburg, A., Vallières, M. et al., 2020. The Image Biomarker Standardization Initiative: Standardized Quantitative Radiomics for High-Throughput Image-based Phenotyping. *Radiology* 295, 328–338. doi:[10.1148/radiol.2020191145](https://doi.org/10.1148/radiol.2020191145).